


TP557 - Tópicos avançados em IoT e Machine Learning: *Introdução ao curso*



Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

Quais as motivações por
trás deste curso?

Motivação: Modelos mais eficientes



- Os **avanços em IA** têm levado à criação de **grandes modelos** (como GPTs, DALL-E, Deep Seek, GroudingDINO, YOLOs entre outros), também chamados de *foundational models*.
- Esses modelos são usados para tradução de texto, assistência pessoal, detecção de objetos, geração de imagens, sons e vídeos sintéticos, etc.

Motivação: Modelos mais eficientes



- Para que tenham um **altíssimo desempenho**, esses modelos são **treinados em bases de dados massivas**.
- Além disso, devido à sua **complexidade e ao volume de parâmetros**, eles demandam **enormes recursos computacionais** – CPU, memória, armazenamento e energia – para treinamento e execução (também chamada de inferência).

Motivação: Modelos mais eficientes



- Por exigirem **recursos computacionais colossais**, isso os torna **proibitivamente caros**.
- Como resultado, a maioria dos usuários os acessa como **serviços baseados em nuvem**.
- Entretanto, o uso na **nuvem** resulta em **maior latência, alto consumo de energia, custos operacionais elevados e menor segurança** com relação aos dados dos usuários.

Motivação: Modelos mais eficientes



- Essa realidade torna inviável o uso desses e outros modelos em dispositivos com recursos limitados, como smartphones, *wearables* ou dispositivos IoT.




Motivação: Modelos mais eficientes



- Esses dispositivos são caracterizados por:
 - **Baixa capacidade de processamento:** microcontroladores ou processadores com poder de computação reduzido.
 - **Memória restrita:** pouca memória RAM e não volátil.
 - **Baixo consumo de energia:** devem ser energeticamente eficientes, sendo muitas vezes alimentados por baterias.
 - **Recursos de hardware simples:** dispõem de periféricos básicos e conectividade limitada.



Motivação: Modelos mais eficientes



- Nesse contexto, surgem os paradigmas edge e tinyML.
- Eles buscam *adaptar técnicas de ML para ambientes restritos*, permitindo a implementação de *modelos otimizados e eficientes* que podem ser executados localmente com baixo consumo de energia e memória.
 - O tinyML também é conhecido como embeddedML.


Objetivos do curso

- Apresentar os *principais algoritmos e técnicas de aprendizado de máquina* (em inglês, Machine Learning, ML) aplicados a *dispositivos com recursos computacionais limitados*.
- O curso terá duas partes, uma introdutória e outra prática.
- A primeira parte conterá aulas introdutórias sobre dispositivos embarcados, IoT e ML.
- A segunda parte conterá laboratórios e estudos dirigidos para fixação dos conceitos introduzidos, além de um projeto final.
- Ao final do curso, vocês deverão ser capazes de entender e aplicar os principais algoritmos e técnicas de ML em aplicações práticas utilizando dispositivos com restrições computacionais.

Teste de Python

- Grande parte do curso necessitará de conhecimentos sobre a linguagem de programação Python, os quais eu assumo que vocês já têm.
- Assim, como primeira atividade, peço que vocês resolvam alguns exercícios sobre programação Python como forma de avaliar seus conhecimentos.
- Caso vocês sintam dificuldades em resolvê-los, me procurem, pois posso sugerir cursos e livros.
- **Estes exercícios valem nota.**
- O link para resolução dos exercícios via Google Colab segue abaixo:
 - https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/exercises/Exerc%C3%ADcios_sobre_Programa%C3%A7%C3%A3o_em_Python.ipynb

Motivação: Quantidade



- Estima-se que teremos ***mais de 75 bilhões de dispositivos*** IoT até 2025.
- A grande maioria desses dispositivos estão ***equipados com microprocessadores ou microcontroladores, (vários) sensores e atuadores.***

Motivação: Economia



NVIDIA Ampere A100
Graphics Processing
Unit (GPU)
400 Watts
826 mm²



Apple A12 (iPhone)
System on a chip (SoC):
CPUs, GPU e Video Codec
3.64 Watts
83 mm²





Apple APL0778 (iWatch)
Application Processor
Unit (APU): CPU+GPU
< 0.78 Watts
32 mm²



Syntiant NDP100
Neural Decision
Processor (NDP)
140 μ Watts
2.52 mm²

- Se comparados com servidores, equipados com dezenas de CPUs e GPUs, os *processadores e microcontroladores* desses dispositivos *são muito menores e consomem muito menos energia e são mais baratos*, devido a alta demanda.

Motivação: Baixo consumo de energia



- O baixíssimo consumo de energia possibilita que os dispositivos:
 - ***Funcionem por longos períodos*** de tempo sem trocar a bateria (e.g., anos);
 - E executem aplicações “***Always On***”:
 - ✓ ***Aplicação constantemente ativa e monitorando o ambiente ao seu redor***, coletando informações, as processando e respondendo em tempo real, sem interrupção.
 - ✓ Característica muito importante em aplicações que exigem monitoramento constante, como sistemas de ***segurança***, ***monitoramento de saúde***, sistemas de ***automação industrial*** ou dispositivos de ***assistência virtual***.

Motivação: Sensores

- Dispositivos IoT, também chamados de ***endpoints***, possuem muitas vezes uma grande variedade de sensores!

Sensores de movimento

Giroscópios, radares (e.g., LiDAR), magnetômetros, acelerômetros.

Sensores de acústicos

Microfones, ultrassônicos, vibrômetros, geofones.

Sensores ambientais

Temperatura, humidade, pressão, infra-vermelho.

Sensores de toque

Capacitivos e Resistivos.

Sensores de imagem

RGB, Térmicos, LiDAR.

Sensores biométricos

impressão digital, batimento cardíaco, glicose.


Sensores de força

Pressão, deformação/tensão.

Sensores de rotação


Encoders rotativos, potenciômetros.

Cloud versus Edge Computing



- **Cloud Computing:** os dados são coletados na borda e o processamento é feito em data centers, muitas vezes distribuídos ao longo de várias localizações.
- **Edge Computing:** processamento e armazenamento de dados é feito *próximo ou nos dispositivos que coletam os dados* (ou seja, na borda da rede).

EdgeML versus TinyML



Nosso curso focará no uso de ambos os tipos de dispositivos.

- **EdgeML**: processamento de algoritmos de ML em *dispositivos de borda* (onde os dados são coletados ou gerados) *com recursos computacionais moderados*.
- **TinyML**: subconjunto do **EdgeML** onde os *dispositivos de borda possuem recursos computacionais bastante restritos*.
 - Dispositivos com *consumo de energia ultrabaixo* (alimentados por baterias).
 - Possibilitam *a execução contínua de modelos de ML* (i.e., dispositivos “*always on*”).

EdgeML versus TinyML

Hardware



TinyML

- CPU de baixo consumo (32 bits single core)
- Pouca memória (RAM/Flash)
- Bateria com baixa capacidade
- Foco na longa duração da bateria

Anomaly Detection
Sensor Classification
20 KB

KeyWord Spotting
Audio Classification
50 KB

Image
Classification
250 KB+



Rpi-Pico
(Cortex-M0+)



Arduino Nano
(Cortex-M4)



Arduino Pro
(Cortex-M7)



EdgeML

EdgeML

- CPU mais poderosa (64 bits e 2+ cores)
- GPU e/ou NPU
- + Memória (RAM/Flash)
- Bateria com maior capacidade
- Sem foco na longa duração da bateria

Object Detection
Complex Voice
Processing
1 MB+

Video
Classification
2 MB+



RaspberryPi
(Cortex-A)



SmartPhone
(Cortex-A)



Jetson Nano
(Cortex-A + GPU)


Diferenciação
de hardware e
terminologia

Mas o que são IA e ML?



- **IA:** técnicas que façam as *máquinas emularem as capacidades humanas*.
 - Visão,
 - Fala,
 - Aprendizado,
 - Movimentação,
 - etc.,
- **ML:** algoritmos que *aprendem uma tarefa sem serem explicitamente programados para tal*.


Mas o que são IA e ML?



- **RNAs:** modelos *inspirados no funcionamento do cérebro humano*.
- Consistem em **neurônios artificiais interconectados**, que são **organizados em camadas** e capazes de **aprender a partir de experiências prévias**.
- **DL:** modelos que aprendem padrões complexos usando redes neurais com várias camadas (i.e., profundas).
 - Por terem **maior capacidade, necessitam de grandes quantidades de dados** e **muitos recursos computacionais** para aprender.

***E se nós pudéssemos executar aplicações baseadas em ML
nesses dispositivos com restrições computacionais?***


O que poderíamos fazer?



Aplicações

Manutenção preventiva

- **Aplicação:** *monitoramento contínuo* de equipamentos com o objetivo de *prever falhas*.
- **Sensores que podem ser utilizados:** movimento, corrente, áudio e câmera.



Aplicações

Monitoramento e rastreio de bens

- **Aplicações:**
 - Monitoramento da saúde de animais e lavouras.
 - Detecção de doenças em plantações.
 - Detecção de incêndios.
- **Sensores que podem ser utilizados:**
movimento, temperatura, humidade, posição, acústico e câmara.



Aplicações


E-health

- **Aplicações:**
 - Detecção de fibrilação arterial em sinais eletrocardiograma.
 - Detecção de doenças pulmonares (e.g., COVID, pneumonia).
 - Detecção de apneia do sono.
 - Detecção de posturas incorretas.
 - Previsão de hospitalização por insuficiência cardíaca
- **Sensores que podem ser utilizados:** movimento, acústico, câmera e ECG.




Sobre o curso

- A difusão de *dispositivos de moderado a baixo poder computacional*, com *(ultra)baixo consumo de energia*, *equipados com sensores*, juntamente com a introdução de *bibliotecas de ML para microcontroladores*, têm permitido a criação de dispositivos *IoT Inteligentes*, ou seja, que executam algoritmos de ML.
- Esse novo paradigma é chamado de *TinyML ou EdgeML: IoT + Sensores + ML*.




Sobre o curso




- *O paradigma envolve a implementação de modelos de ML e ferramentas de otimização para a execução desses modelos em dispositivos com restrições computacionais.*
 - Como sensores IoT, wearables e dispositivos portáteis.
- Envolve o **uso de algoritmos de ML leves** e a **redução do tamanho dos modelos** com o intuito de **otimizar do uso dos recursos computacionais** dos dispositivos.

Sobre o curso




- O ***processamento local*** dos dados em ***dispositivos de borda*** traz alguns benefícios:
 - ***Menor latência***: não é necessário o envio dos dados para um servidor na nuvem, possibilitando aplicações que operem em ***tempo real***;
 - ***Maior privacidade***: dados sensíveis não são transferidos para servidores;

Sobre o curso



- O ***processamento local*** dos dados em ***dispositivos de borda*** traz alguns benefícios:
 - ***Menor dependência de conexões***: reduz ou elimina a necessidade de transferência de dados para servidores.
 - ***Maior autonomia energética***: o uso de microcontroladores com baixo consumo de energia reduz o consumo de energia, uso de recursos e custos.

Sobre o curso



- Portanto, o curso mistura ML com dispositivos IoT, cujas principais características são:
 - **Baixo poder computacional:** geralmente equipados com CPUs single core de 32 bits, poucos quilobytes de memória RAM e alguns megabytes de memória de longo prazo (*flash*).
 - **Baixíssimo consumo de energia:** são geralmente alimentados à bateria, as quais devem durar um longo período de tempo.
 - **Sensores:** temperatura, pressão, humidade, ópticos (e.g., câmeras RGB, térmicas), movimento (e.g., giroscópio e acelerômetro), biométricos (e.g., impressão digital, batimento cardíaco), etc.
- Nosso curso é baseado nos cursos de ***TinyML*** de Harvard e da UNIFEI.
 - <https://scholar.harvard.edu/vijay-janapa-reddi/classes/cs249r-tinyml>
 - <https://github.com/Mjrovai/UNIFEI-UESTI01-TinyML-2022.1>

Sobre o curso

- O curso será dividido em duas partes:
 - **Fundamentos:** Introdução e desafios do TinyML, paradigma do ML, introdução ao *Deep Learning*, modelos de DL para regressão e classificação, redes convolucionais, como evitar problemas de sobreajuste e introdução ao **Edge Impulse**;
 - **Aplicação prática dos fundamentos:** ciclo de vida e de trabalho de aplicações de ML, introdução às bibliotecas do TensorFlow, visão geral do kit de desenvolvimento, laboratórios práticos (usando o kit ou dispositivos pessoais) e apresentação de trabalhos práticos.



**EDGE
IMPULSE**



TensorFlow Lite



Sobre o curso

- **Pré-requisitos** (*não mandatórios*):

- Conceitos básicos de **álgebra linear** (e.g., matrizes e vetores), **cálculo** (e.g., algoritmos de otimização, como o gradiente descendente), **probabilidade e estatística** (e.g., distribuições de probabilidade, média, variância, desvio padrão) e **processamento de sinais** (e.g., FFT, filtragem);
- Conhecimentos de programação em C/C++ e Python.



**EDGE
IMPULSE**



TensorFlow Lite



Sobre o curso




Avaliações

- Atividades (A): 25%
 - Exercícios de programação
 - Quizzes
 - Proposta de projeto prático final (ao final do segundo mês)
- Relatórios dos Laboratórios (R): 25%
 - Laboratórios com experimentos práticos.
- Projeto final (P): 50%
 - *Projeto prático unindo IoT e ML.*
 - Até dois (2) alunos por projeto.
 - Tema deve ser escolhido por vocês.





$$NF = A * 25\% + R * 25\% + P * 50\%$$




Objetivos do curso


- Apresentar os ***fundamentos de IoT e ML***, bem como explorar a ***interseção*** entre essas áreas.
- ***Familiarizar*** os alunos com a ***literatura e os conceitos-chave da área de Edge/TinyML***.
- Capacitar os alunos a ***conceber, treinar e implantar aplicações Edge/TinyML em sistemas embarcados*** (e.g., smartphones e dispositivos IoT).
- Proporcionar ***experiência prática por meio de laboratórios e projetos***, permitindo que os alunos apliquem os conhecimentos adquiridos em cenários do mundo real.




O que vamos aprender?



- Focaremos no aprendizado de conceitos para a construção de ***aplicações*** que apresentem:
 - Baixa latência;
 - Maior autonomia energética;
 - Eficiência computacional;
 - Baixo consumo de memória.



O que vamos aprender?




- Trabalharemos na **interseção das três áreas ao lado**, dando origem ao **Edge/TinyML**.
- Para isso, devemos levar em consideração algumas questões importantes:
 - Quais **novos casos de uso são habilitados com o uso de Edge/TinyML**, que não eram possíveis antes?
 - Quais são os **desafios de implementar ML em dispositivos com recursos limitados**?
 - ✓ Temos que considerar restrições como **consumo de energia e memória** e **tempo de processamento**.

O que vamos usar?

Hardware

- Smartphones
- Arduino Nano 33 BLE Sense
- Kits de desenvolvimento
 - Raspberry Pi, Orange Pi, etc.
- Sensores



Software

- **Bibliotecas de ML:** Tensorflow, TFLite e TFLite Micro.
- **Ambientes de programação:** Google Colab (com Jupyter notebooks) e Arduino IDE.
- **Ambiente de desenvolvimento de ML:** Edge Impulse Studio.




O kit TinyML

O kit contém:

- 1 x Arduino Nano 33 BLE Sense **Lite***
- 1 x Shield
- 1 x Câmera OV7675
- 1 x Cabo USB A



Câmera de 0.3 Mega Pixels
Resoluções (pixels): 640x480 (VGA), 320x240 (QVGA) e 160x120 (QQVGA)
Frames por segundo: 30 (VGA), 60 (QVGA) e 240 (QQVGA)




* Sem sensor de temperatura e humidade.

Atividades práticas




Classificação de movimento ou atividade

Sensores: acelerômetro, giroscópio, magnetômetro




Detecção/previsão de anomalias

Sensores: câmera e/ou acelerômetro.



Classificação de imagens

Sensor: câmera



Keyword spotting

Sensor: microfone.



Visual wake imagens

Sensor: câmera.



Classificação de gestos

Sensores: câmera e/ou acelerômetro.



Referências

- [1] Daniel Situnayake and Pete Warden, *“TinyML: Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers”*, 1st ed., O'Reilly Media, 2019.
- [2] Aurélien Géron, *“Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems”*, 1st ed., O'Reilly Media, 2017.
- [3] Agus Kurniawan, *“IoT Projects with Arduino Nano 33 BLE Sense: Step-By-Step Projects for Beginners”*, Apress, 2020.
- [4] Stuart Russell and Peter Norvig, *“Artificial Intelligence: A Modern Approach”*, Prentice Hall Series in Artificial Intelligence, 3rd ed., 2015.
- [5] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *“Deep Learning”*, MIT Press, 2016.
- [6] Hakima Chaouchi, *“The Internet of Things: Connecting Objects”*, Wiley, 2010.
- [7] Jun Zheng and Abbas Jamalipour, *“Wireless Sensor Networks: A Networking Perspective”*, Wiley, 2009.
- [8] [Coleção de livros](#)

Avisos

- Todo material do curso está disponível no GitHub:
 - <https://github.com/zz4fap/tp557-iot-ml>
- Google Colab + Python Crash Course
 - https://www.youtube.com/watch?v=inN8seMm7UI&ab_channel=TensorFlow
 - <https://www.youtube.com/watch?v=inN8seMm7UI>
 - <https://www.youtube.com/watch?v=pq4NNIYar9o&list=PLRc6ZYt68prVXAhwY1JD6DFc3BJGmJriq&pp=gAQBiAQB>
- Introdução ao TensorFlow
 - https://www.youtube.com/watch?v=yjprpOoH5c8&ab_channel=TensorFlow
- Horário de Atendimento
 - Todas as quartas-feiras das 17:30 às 18:30.
 - Presencialmente ou remotamente.

Ideias para projetos finais

1. [Identificação de falhas em rolamentos](#)
2. [Identificação de doenças respiratórias](#)
3. [Detectando falhas em automóveis através de seu som](#)
4. [Identificação de pragas](#)
5. [Identificação de posturas incorretas](#)
6. [Inspeção automática de qualidade](#)
7. [Classificador de Vogais em Libras](#)
8. [Detecção de doença pulmonar](#)
9. [Detecção de algarismos em hidrômetros](#)
10. [Detecção de Roncos](#)

Ideias para projetos finais

1. [Detecção de tumores cancerígenos](#)
2. [Detecção e prevenção de abalos sísmicos](#)
3. [Detecção de incêndios](#)
4. [Detecção de COVID através da tosse](#)
5. [Detecção do uso de máscaras](#)
6. [Personal Trainer](#)
7. [Predição da qualidade do ar](#)
8. [Diabetic retinopathy detector](#)
9. <https://www.tensorflow.org/lite/examples?hl=pt-br>
10. https://experiments.withgoogle.com/collection/tfliteformicrocontroller_s

Ideias para projetos finais

1. “Explore real-world edge ML projects”, <http://tinyurl.com/tinymlprojects>

Atividades

- Quiz: “***TP557 – Introdução***”
- Exercícios: [Programação em Python](#).

Perguntas?

Obrigado!