



TP557 - Tópicos avançados em IoT e
Machine Learning:


*Desafios do TinyML:
Machine Learning*



Inatel


Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

Desafios da execução de ML em sistemas embarcados



- Anteriormente, falamos das *limitações de HW e SW quando usamos sistemas embarcados.*
- Agora, veremos os *desafios para execução algoritmos de ML*, mais especificamente de *Deep Learning*, nestes dispositivos
 - *pequenos,*
 - *com restrições de custo, de recursos computacionais e consumo.*


Deep Learning ou Aprendizado Profundo




Subárea do aprendizado de máquina que usa ***redes neurais artificiais com muitas camadas ocultas*** para aprender com dados.

Deep Learning ou Aprendizado Profundo

- Por terem uma ***grande capacidade de aprendizado***, em geral, precisam de uma ***grande quantidade de dados*** para aprenderem (i.e., encontrar uma solução geral).




Deep Learning




- Um exemplo muito comum de uso do *deep learning* é a **classificação de imagens**.
- Se tivermos uma base de dados com imagens de gatos e cachorros, podemos **treinar uma rede neural profunda para identificá-los** em imagens.
- O **objetivo** é obter um **modelo que generalize**, ou seja, que identifique gatos ou cachorros não vistos durante o treinamento.

O que é uma rede neural artificial?




- É uma **conexão de camadas de neurônios artificiais**, ou também chamados de nós.
- Os **neurônios artificiais** são **modelos matemáticos inspirados no funcionamento de um neurônio biológico**.
- Os **neurônios** das diferentes camadas **são conectados através dos pesos sinápticos**, que determinam a **força daquela conexão**.

Neurônio biológico




- São **células** que possuem **mecanismos eletroquímicos** para realizar a **transmissão de sinais elétricos** (i.e., informações) **ao longo do sistema nervoso**.
- Têm três partes fundamentais: os **dendritos**, o **axônio** e o **corpo celular**, também chamado de **soma**.
- Os **dendritos recebem estímulos** vindos **de outros neurônios** e os levam em direção ao **corpo celular**.

Neurônio biológico




- O **corpo celular** realiza a **integração** dos **estímulos e gera impulsos** caso um limiar seja ultrapassado.
- O **axônio** envia **impulsos** a outros neurônios através de seus **terminais**.
- Os neurônios se comunicam uns com os outros através das **sinapses**.
- **Sinapses** são os **pontos de contato** entre os **dendritos** de um neurônio e os **terminais do axônio** de outros neurônios.

Neurônio biológico



- Em termos bem simples, o funcionamento do **neurônio** pode ser explicado da seguinte forma:
 - Ele **recebe estímulos elétricos** através dos dendritos.
 - Esses **estímulos são integrados** no corpo celular (*soma*).
 - Se a **integração dos estímulos** exceder um certo **limiar de ativação**, o **neurônio** gera um **impulso** (ou **potencial de ação**) que é enviado pelos terminais do axônio a outros neurônios através das **sinapses**.


Neurônio artificial



$$y = f(g(\mathbf{x})) = f\left(\left(\sum_{i=1}^K w_i x_i\right) + b\right)$$

- Baseado no entendimento do funcionamento do neurônio biológico, a partir de meados da década de 40, pesquisadores propuseram o modelo matemático ao lado.
 - É uma **simplificação e abstração** do funcionamento do neurônio biológico.






Neurônio artificial



$$y = f(g(\mathbf{x})) = f\left(\left(\sum_{i=1}^K w_i x_i\right) + b\right)$$


- Os **estímulos**, $x_k, k = 1, \dots, K$, são multiplicados pelos **pesos sinápticos**, $w_k, k = 1, \dots, K$, somados com o **peso de bias**, b , e o resultado é passado por uma **função de ativação**, $f(\cdot)$.
- No contexto de redes neurais os estímulos são chamados de **atributos**.
- O **peso de bias**, b , controla o **ponto de ativação**.
- Os **pesos sinápticos** w_k dão a **força de cada conexão** e se ela é **excitatória ou inibitória**.

Neurônio artificial



- O **peso de bias**, b , permite **ajustar o limiar de ativação** (ou ponto de disparo) da função de ativação.
- No início dos estudos dos neurônios, a **função de ativação** era do tipo **tudo-ou-nada**, ou seja, ativava ou não (degrau unitário).
- Com o decorrer do tempo, outras funções com características diferentes foram propostas, tais como as funções sigmoide, tangente hiperbólica, *relu*, linear, etc.

Neurônio artificial




$$y = f \left(\left(\sum_{i=1}^K w_i x_i \right) + b \right)$$

Pesos ou
parâmetros

- O **objetivo** do **treinamento** de uma rede neural artificial é **encontrar os valores ideais dos pesos** (bias e sinápticos) **de todos os neurônios** de forma que a rede **resolva uma tarefa específica**, como, por exemplo, a classificação de imagens.

Neurônio artificial




$$y = f \left(\left(\sum_{i=1}^K w_i x_i \right) + b \right)$$

Pesos ou
parâmetros

- Se os atributos são os pixels das imagens e gatos e cachorros são representados por saídas iguais a 1 e 0, respectivamente, quais devem ser os valores dos pesos para classificar corretamente as imagens?

Neurônio artificial




$$y = f \left(\left(\sum_{i=1}^K w_i x_i \right) + b \right)$$

Pesos ou
parâmetros

- Os pesos são ajustados através de um **processo de otimização iterativo** chamado de **retropropagação do erro**, onde apresenta-se ao modelo as **entradas** e **saídas esperadas** e o processo **minimiza o erro** entre a **saída da rede** e os **valores de saída esperados**, chamados de **rótulos ou labels**.

Arquiteturas de redes neurais artificiais


- Diferentes **tipos de neurônios**, **quantidades de camadas** e de **neurônios** em cada uma delas e a **forma como eles são conectados**, resultam em **arquiteturas** diferentes.



Arquiteturas de redes neurais artificiais

A mostly complete chart of Neural Networks

©2019 Fjodor van Veen & Stefan Leijnen asimovinstitute.org



- **Deep Feed Forward (DFF) networks:** também chamadas de *dense neural networks* (DNNs).
- São redes ***densamente*** conectadas: ***todas as saídas de uma camada se conectam a todos os nós da próxima.***
- Para serem consideradas profundas (i.e., ***deep***), devem ter 2 ou mais camadas ocultas.

* Modelo que será muito usado no curso.

Arquiteturas de redes neurais artificiais

A mostly complete chart of Neural Networks

©2019 Fjodor van Veen & Stefan Leijnen asimovinstitute.org

- Input Cell
- Backfed Input Cell
- Noisy Input Cell
- Hidden Cell
- Probabilistic Hidden Cell
- Spiking Hidden Cell
- Capsule Cell
- Output Cell
- Match Input Output Cell
- Recurrent Cell
- Memory Cell
- Gated Memory Cell
- Kernel
- Convolution or Pool



Perceptron (P)




Feed Forward (FF)




Radial Basis Network (RBF)




Recurrent Neural Network (RNN)




Long / Short Term Memory (LSTM)




Gated Recurrent Unit (GRU)




Auto Encoder (AE)




Variational AE (VAE)




Denoising AE (DAE)




Sparse AE (SAE)




Markov Chain (MC)




Hopfield Network (HN)




Boltzmann Machine (BM)



Restricted BM (RBM)




Deep Belief Network (DBN)



- O termo ***feed forward*** vem do fato de que as conexões são sempre no sentido da ***entrada para a saída***, ou seja, ***não há realimentação***.
- São usadas em tarefas de ***aproximação de funções*** (i.e., regressão e classificação).


* Modelo que será muito usado no curso.

Arquiteturas de redes neurais artificiais



- **Convolutional Neural Networks (CNNs)** ou redes neurais convolucionais.
- São redes que utilizam *camadas de convolução*, que *aplicam filtros para extrair características relevantes* dos dados de entrada, que, em geral, são imagens.

Arquiteturas de redes neurais artificiais



- São usadas em aplicações de *visão computacional*, como
 - classificação de imagens,
 - processamento de vídeos,
 - detecção e segmentação de objetos em imagens ou vídeos.

Arquiteturas de redes neurais artificiais


A mostly complete chart of Neural Networks

©2019 Fjodor van Veen & Stefan Leijnen asimovinstitute.org


Perceptron (P)




Feed Forward (FF)




Radial Basis Network (RBF)



Deep Feed Forward (DFF)




Recurrent Neural Network (RNN)




Long / Short Term Memory (LSTM)




Gated Recurrent Unit (GRU)




Auto Encoder (AE)




Variational AE (VAE)




Denoising AE (DAE)




Sparse AE (SAE)




Markov Chain (MC)




Hopfield Network (HN)




Boltzmann Machine (BM)



Restricted BM (RBM)



Deep Belief Network (DBN)



- **Recurrent Neural Networks (RNNs)** ou *redes neurais recorrentes*.
- Possuem *conexões que formam loops*, permitindo que *informações anteriores sejam armazenadas e influenciem as entradas futuras*, ou seja, elas possuem *memória*.
- Ou seja, elas consideram o **contexto anterior** ao fazer previsões.

Arquiteturas de redes neurais artificiais


A mostly complete chart of Neural Networks

©2019 Fjodor van Veen & Stefan Leijnen asimovinstitute.org


Perceptron (P)




Feed Forward (FF)




Radial Basis Network (RBF)



Deep Feed Forward (DFF)




Recurrent Neural Network (RNN)




Long / Short Term Memory (LSTM)




Gated Recurrent Unit (GRU)




Auto Encoder (AE)




Variational AE (VAE)




Denoising AE (DAE)




Sparse AE (SAE)




Markov Chain (MC)




Hopfield Network (HN)




Boltzmann Machine (BM)



Restricted BM (RBM)



Deep Belief Network (DBN)



- Essa capacidade as torna especialmente úteis em ***tarefas que envolvem dados sequenciais ou temporais***, como

- ***análise de texto,***
- ***previsão de séries temporais e***
- ***processamento de fala e áudio.***

Arquiteturas de redes neurais artificiais


A mostly complete chart of Neural Networks

©2019 Fjodor van Veen & Stefan Leijnen asimovinstitute.org


Perceptron (P)




Feed Forward (FF)




Radial Basis Network (RBF)




Deep Feed Forward (DFF)




Recurrent Neural Network (RNN)




Long / Short Term Memory (LSTM)



Gated Recurrent Unit (GRU)




Auto Encoder (AE)




Variational AE (VAE)



Denoising AE (DAE)




Sparse AE (SAE)




AE


Markov Chain (MC)




Hopfield Network (HN)




Boltzmann Machine (BM)



Restricted BM (RBM)



Deep Belief Network (DBN)




- **Autoencoders (AEs)** têm como objetivo aprender uma *representação latente* dos dados de entrada.
- Eles aprendem características importantes, mas ocultas, nos dados.

Arquiteturas de redes neurais artificiais

A mostly complete chart of Neural Networks

©2019 Fjodor van Veen & Stefan Leijnen asimovinstitute.org



- Consistem em duas partes: **codificador** e **decodificador**.
- O **codificador mapeia** os dados de entrada em uma **representação latente** (de maior ou menor dimensão).
- O **decodificador reconstrói** os **dados originais** a partir da representação com maior ou menor dimensionalidade.

Arquiteturas de redes neurais artificiais

A mostly complete chart of Neural Networks


©2019 Fjodor van Veen & Stefan Leijnen asimovinstitute.org

- Input Cell
- Backfed Input Cell
- △ Noisy Input Cell
- Hidden Cell
- Probabilistic Hidden Cell
- △ Spiking Hidden Cell
- Capsule Cell
- Output Cell
- Match Input Output Cell
- Recurrent Cell
- Memory Cell
- △ Gated Memory Cell
- Kernel
- Convolution or Pool


Perceptron (P)




Feed Forward (FF)




Radial Basis Network (RBF)




Deep Feed Forward (DFF)




Recurrent Neural Network (RNN)




Long / Short Term Memory (LSTM)




Gated Recurrent Unit (GRU)




Auto Encoder (AE)




Variational AE (VAE)



Denoising AE (DAE)




Sparse AE (SAE)




AE


Markov Chain (MC)




Hopfield Network (HN)




Boltzmann Machine (BM)



Restricted BM (RBM)




Deep Belief Network (DBN)




- São usados em tarefas de
 - ***redução de dimensionalidade,***
 - ***remoção de ruído,***
 - ***compressão de dados,***
 - ***geração de dados sintéticos e***
 - ***adição de redundância.***

Arquiteturas de redes neurais artificiais


Deep Convolutional Network (DCN)




Deconvolutional Network (DN)




Deep Convolutional Inverse Graphics Network (DCIGN)




Generative Adversarial Network (GAN)




Liquid State Machine (LSM)




Extreme Learning Machine (ELM)




Echo State Network (ESN)




Deep Residual Network (DRN)




Differentiable Neural Computer (DNC)




Neural Turing Machine (NTM)




Capsule Network (CN)



Kohonen Network (KN)




Attention Network (AN)




- **Generative Adversarial Networks (GANs)** ou *redes adversárias generativas*.
- São um tipo especial de rede neural que consiste em ***duas redes, uma competindo com a outra.***
- Estas duas redes são chamadas de ***gerador e discriminador.***

Arquiteturas de redes neurais artificiais


Deep Convolutional Network (DCN)



Deconvolutional Network (DN)




Deep Convolutional Inverse Graphics Network (DCIGN)




Generative Adversarial Network (GAN)




Liquid State Machine (LSM)




Extreme Learning Machine (ELM)




Echo State Network (ESN)




Deep Residual Network (DRN)




Differentiable Neural Computer (DNC)




Neural Turing Machine (NTM)




Capsule Network (CN)



Kohonen Network (KN)




Attention Network (AN)



- O **gerador** *cria dados sintéticos* que se assemelham aos dados reais do conjunto de treinamento.
- O **discriminador** tenta *distinguir entre dados reais e sintéticos*.
- O **objetivo** do treinamento é fazer com que o **gerador engane o discriminador**.
- São usadas para **geração de imagens, vídeos e sons** realistas.


Arquiteturas de redes neurais artificiais




- **Attention Networks (ANs)** ou *redes de atenção*.
- São redes que *focam em partes importantes* dos dados de entrada, dando-lhes *maior peso durante* (i.e., *atenção*) o processamento.
- Por exemplo, ao ler um texto ou visualizar uma imagem, seu *cérebro foca nas partes mais relevantes para entender o contexto*.
- O mecanismo de atenção faz algo similar.

Arquiteturas de redes neurais artificiais


Deep Convolutional Network (DCN)




Deconvolutional Network (DN)




Deep Convolutional Inverse Graphics Network (DCIGN)




Generative Adversarial Network (GAN)




Liquid State Machine (LSM)




Extreme Learning Machine (ELM)




Echo State Network (ESN)




Deep Residual Network (DRN)




Differentiable Neural Computer (DNC)




Neural Turing Machine (NTM)




Capsule Network (CN)



Kohonen Network (KN)




Attention Network (AN)




- Elas *atribuem pesos* às diferentes *partes da entrada* (palavras ou regiões de uma imagem) e *dão mais importância às partes que ajudam a resolver* a tarefa em questão.

Arquiteturas de redes neurais artificiais


Deep Convolutional Network (DCN)




Deconvolutional Network (DN)




Deep Convolutional Inverse Graphics Network (DCIGN)




Generative Adversarial Network (GAN)




Liquid State Machine (LSM)




Extreme Learning Machine (ELM)




Echo State Network (ESN)




Deep Residual Network (DRN)




Differentiable Neural Computer (DNC)




Neural Turing Machine (NTM)




Capsule Network (CN)



Kohonen Network (KN)



Attention Network (AN)



- Propostas para lidar com a **dificuldade de RNNs** de lidar com **sequências longas** ou **entradas complexas**.
- São usadas em tarefas que envolvem sequências de dados, como
 - **tradução automática,**
 - **processamento de linguagem natural,**
 - **reconhecimento de fala e**
 - **visão computacional.**

Crescimento do tamanho dos modelos




- Ao longo dos anos, para resolver ***problemas mais e mais complexos*** com ***ótimos resultados***, as ***arquiteturas*** das redes neurais têm se ***tornado maiores e mais complexas***.
- OBS.: A ***capacidade*** de uma rede neural está ***relacionada*** com sua ***quantidade de camadas e nós*** (i.e., ***conexões***).
- A ***complexidade computacional*** de uma rede neural é ***diretamente proporcional*** ao seu ***número de conexões***.

Crescimento do tamanho dos modelos




- Portanto, **quanto mais camadas e nós, mais memória e cálculos matemáticos** são necessários e, **consequentemente, maior será o consumo de energia**.
- Até recentemente, **não havia** uma **preocupação com as eficiências computacional e energética** de soluções envolvendo IA.

Crescimento do tamanho dos modelos



- Os modelos não param de crescer!
- Isso se deve ao
 - aumento da **disponibilidade de dados**,
 - aumento do **poder computacional**
 - redução do **preço do hardware** e
 - desenvolvimento de **novas técnicas de aprendizado** (principalmente de aprendizado profundo).

Crescimento do tamanho dos modelos




- Vejamos o modelo de linguagem GPT:
 - O GPT-2 tinha aproximadamente 1.5 bilhão de parâmetros (i.e., pesos sinápticos e de bias).
 - Já os GPT-3/3.5 têm aproximadamente 175 bilhões de parâmetros.
 - E estima-se que o GPT-4 tenha 1.76 trilhão de parâmetros.

Se cada parâmetro corresponde a uma variável do tipo *float* (4 bytes), precisamos de $1.76 \times 10^{12} \times 4 \sim 7 \times 10^{12}$ bytes, ou seja, **7 Terabytes** para armazenar o modelo GPT-4!

Necessidades computacionais (2012 - Atual)


AlexNet to AlphaGo Zero: A 300,000x Increase in Compute (Log Scale)



Flops/s-day: quantidade de operações em ponto flutuante por segundo por dia necessárias para treinar o modelo.


- Nos últimos anos, o ***poder computacional*** necessário para treinar os modelos de ML amplamente usados hoje ***teve que crescer 300.000 vezes***.
- Essa tendência de redes imensas começou em 2012 com a AlexNet.
 - Rede neural convolucional desenvolvida na universidade de Toronto no Canadá para classificação de imagens.

Necessidades computacionais (2012 - Atual)




- **CNN** que **bateu** com folga todos os **recordes anteriores** do desafio *ImageNet Large Scale Visual Recognition* de 2012.
- Tem **60 milhões de parâmetros**, o que na época a tornou uma das **maiores e mais complexas redes neurais**.
- **Popularizou** o uso de **camadas convolucionais**, impulsionando a revolução do aprendizado profundo.

Necessidades computacionais (2012 - Atual)





- Introduziu o uso da *função de ativação ReLU*, que mitiga o problema do desaparecimento do gradiente.
- Foi uma das *primeiras redes neurais a usar GPUs* para reduzir o tempo de treinamento.
- Estabeleceu a *base para muitas arquiteturas de CNNs* subsequentes.

Necessidades computacionais (desde 1958)



- Nos últimos 10 anos, a quantidade de cálculos necessários cresceu extraordinariamente rápido.
- Na “primeira era” do ML, a quantidade de cálculos e, consequentemente, o **tamanho dos modelos, dobrava a cada dois anos** aproximadamente.
- Na “era moderna”, os requisitos de computação praticamente dobram a cada **3/4 meses**.



Necessidades computacionais (desde 1958)



O que aconteceu nesses últimos 10 anos que explica esse boom?





Necessidades computacionais (desde 1958)



- Disponibilidade de **grandes volumes de dados** devido à internet (> 100 TB/dia).
- **Aumento do poder de computacional** através de GPUs, FPGAs, ASICs especializados e CPUs com múltiplos cores.
- **Surgimento de novos algoritmos de ML**, como redes neurais profundas, redes adversárias generativas (GANs), redes de atenção, *transformers*, *deep reinforcement-learning*, etc.



Necessidades computacionais (desde 1958)



- Disponibilidade de **frameworks e bibliotecas amigáveis**, como TensorFlow e PyTorch, que facilitam o desenvolvimento de soluções com ML.
- O surgimento de **serviços de computação em nuvem** ofereceu **acesso econômico e escalável** a recursos de computação.



TensorFlow

PyTorch




Google Cloud

aws



Consequências do aumento da capacidade



- Entretanto, esses **modelos mais e mais complexos, necessitam**, consequentemente, de mais

- **capacidade de armazenamento,**
- **energia,**
- **poder de processamento e**

que acabam sendo **muito caros e ocupando grandes espaços.**



Cloud TPU




TinyML



TPU: Tensor Processing Unit, é um ASIC **altamente especializado para realizar operações tensoriais (ou arrays)**, o que acelera o treinamento e inferência de modelos de aprendizado de máquina, especialmente aqueles que usam o TensorFlow.


*Como podemos colocar tudo isso
em um dispositivo EdgeML?*

Evolução dos modelos de ML




- A figura ao lado mostra a **evolução dos modelos** de ML para a tarefa de **classificação de imagens** usando o conjunto de dados ImageNet-1K (1000 classes) como **benchmark**.
- O eixo x mostra o **custo computacional** do modelo (i.e., quantidade de **flops** necessárias para uma classificação).
- O eixo y mostra a **acurácia** (taxa de acertos).
- O tamanho de cada círculo corresponde à **complexidade** (i.e., quantidade de parâmetros) do modelo.

Evolução dos modelos de ML



- Para execução em dispositivos **EdgeML**, devemos procurar por modelos com:
 - **Poucos parâmetros** (i.e., círculos pequenos), pois a quantidade de parâmetros está associada à **quantidade de memória demandada pelo modelo**.
 - **Quantidade necessária de flops baixa**, pois a quantidade de operações está diretamente **relacionada ao consumo de energia**.
 - **Alta acurácia**.


Evolução dos modelos de ML



AlexNet (Universidade de Toronto, Canadá - 2012)


- Acurácia: 57.1%
- Tamanho: 61 MB
- Camadas: 5 convolucionais e 3 densas.

Evolução dos modelos de ML



AlexNet (Universidade de Toronto, Canadá - 2012)

- Acurácia: 57.1%
- **Tamanho: 61 MB**




RAM: 256 KB
Flash: 1 MB



RAM: até 16 GB
Flash: 64 a 256 GB


Evolução dos modelos de ML



VGG-16 (Universidade de Oxford, Reino Unido - 2014)

- Acurácia: 71.5%
- Tamanho: 528 MB
- Camadas: 13 convolucionais e 3 densas.
- Em dois anos, saímos de um modelo pequeno, requerendo poucos *flops* (baixo consumo), mas com baixa acurácia para modelos mais precisos, porém mais de 8 vezes maiores e requerendo 15 vezes mais *flops* (alto consumo).


Evolução dos modelos de ML



VGG-16 (Universidade de Oxford, Reino Unido - 2014)

■ **Acurácia: 71.5%**

■ **Tamanho: 528 MB**




RAM: 256 KB
Flash: 1 MB



RAM: até 16 GB
Flash: 64 a 256 GB


Evolução dos modelos de ML



ResNet-50 (Microsoft - 2015)

- Acurácia: 75.8%
- Tamanho: 22.7 MB
- Camadas: 48 convolucionais, 2 de *pooling* (agrupamento) e 1 densa.


Evolução dos modelos de ML



ResNet-50 (Microsoft - 2015)


- Arquitetura muito mais eficiente do que a VGGNet pois introduz
 - Dropout**: desliga aleatoriamente algumas das conexões da rede durante o treinamento para *evitar o sobreajuste*.
 - Blocos residuais**: são atalhos entre camadas convolucionais que *mitigam o problema do desaparecimento do gradiente*.
- Em *um ano*, saímos de um modelo *extremamente grande* e que *requer muitos flops*, mas razoavelmente preciso para um modelo *23 vezes menor, mais preciso* e necessitando de *3 vezes menos flops*.

Evolução dos modelos de ML



ResNet-50 (Microsoft - 2015)

- Acurácia: 75.8%
- Tamanho: 22.7 MB




RAM: 256 KB
Flash: 1 MB



RAM: até 16 GB
Flash: 64 a 256 GB


Evolução dos modelos de ML



MobileNetv1 (Google - 2015)

- **Acurácia: 70.6%**
- **Tamanho: 16.9 MB**
- Camadas: 27 convolucionais e 2 densas.
- Adequada para aplicações de visão computacional em **dispositivos móveis e embarcados**.


Evolução dos modelos de ML



MobileNetv1 (Google - 2015)

- Usa camadas de **convolução separável em profundidade** em vez de convolução tradicional.
- **Divide** a convolução tradicional em **duas etapas**: uma **convolução em profundidade** (que lida com canais) seguida de uma **convolução em ponto** (que lida com pixels individuais).
- Isso **reduz** drasticamente o **tamanho do modelo**, a **quantidade de cálculos** e **melhora sua eficiência computacional**.


Evolução dos modelos de ML



MobileNetv1 (Google - 2015)

■ **Acurácia: 70.6%**

■ **Tamanho: 16.9 MB**




RAM: 256 KB
Flash: 1 MB




RAM: até 16 GB
Flash: 64 a 256 GB

Evolução dos modelos de ML



- Os modelos até este ponto ainda eram muito grandes para dispositivos com recursos limitados.




RAM: 256 KB
Flash: 1 MB




RAM: até 16 GB
Flash: 64 a 256 GB

Como executar modelos de ML em dispositivos EdgeML?




- Nitidamente, mesmo os menores modelos, não cabem e/ou não conseguem ser executados de forma eficiente em dispositivos EdgeML, principalmente os TinyML.
- Portanto, surge uma pergunta.

Como executar modelos de ML em dispositivos EdgeML?




Como podemos *reduzir* esses modelos para que *caibam na memória* destes dispositivos, *possam ser executados* por eles e *consumam pouca energia*?

Como executar modelos de ML em dispositivos EdgeML?




- Podemos lançar mão de três abordagens:
 - Compressão dos modelos.
 - *Frameworks* mais enxutos e eficientes.
 - Hardwares específicos/customizados para ML.

Técnicas de compressão dos modelos




- Em geral, podemos utilizar quatro técnicas para reduzir o tamanho dos modelos sem perder muito de seu desempenho:
 - *Pruning* (ou poda);
 - Quantização;
 - *Clustering*;
 - *Knowledge Distillation* (ou destilação de conhecimento).

Pruning




- **Remove conexões** para **reduzir** a quantidade de **cálculos** necessários e diminuir o **tamanho do modelo**.
 - Reduz a demanda computacional.
- Essa remoção, em geral, se baseia na **magnitude dos pesos**.
 - **Pesos com magnitudes próximas de zero são removidos**, pois podem não influenciar no desempenho do modelo.
- Técnica aplicada após o treinamento.

Pruning




- A poda pode, também, acabar **removendo neurônios completamente**.
- O modelo final **pode** continuar com o **mesmo desempenho ou perder parte dele**.
- Portanto, é preciso **testar e encontrar um balanço** entre redução do modelo e seu desempenho.
- Ajuda a **mitigar problemas de sobreajuste**, melhorando a generalização do modelo.
 - Modelos complexos tendem a sobreajustar.


Quantização



- Outra técnica de compressão bastante usada é chamada de **quantização**.
- Ela **reduz a precisão numérica dos dados** usados para representar os parâmetros (pesos, ativações, etc.) dos modelos.
- A ideia é **mapear** o intervalo dos valores **float** para um **intervalo de inteiros**.




Quantização




- A **quantização** **reduz a quantidade de valores** que podem ser assumidos por uma variável.
- A quantização **aumenta a granularidade** da representação numérica.
- Com a quantização de float32 para int8, temos uma redução de 4 vezes.

Quantização




- A quantização **pode reduzir o desempenho do modelo**, mas, em muitos casos, ela **não é significativa** e **pode ser tolerada** quando desejamos utilizar dispositivos EdgeML.
- Aplicada após o treinamento.
- Entretanto, existem técnicas onde o modelo é treinado ciente da quantização, resultando em nenhuma ou redução mínima do desempenho.

Clustering ou compartilhamento de pesos



- O *clustering* de pesos reduz o ***tamanho de armazenamento e de transferência através da rede*** de modelos de ML.
- O *clustering* reduz o tamanho do modelo substituindo ***pesos semelhantes em uma camada por um mesmo valor*** (i.e., o centroide mais próximo).
- Assim, podemos ***armazenar os índices e os centroides***:
 - Neste caso, reduzimos o tamanho da matriz de 16 *floats* diferentes para 4 *floats* distintos e 16 índices de 2 bits.

Clustering ou compartilhamento de pesos



- No caso de armazenamento ou transferência do modelo, ferramentas de compactação, como o *zip*, aproveitam a redundância nos dados para obter maior compactação.
- Aplicado após o treinamento.

Clustering ou compartilhamento de pesos

Image classification


Model	Original		Clustered			
	Top-1 accuracy (%)	Size of compressed .tflite (MB)	Configuration	# of clusters	Top-1 accuracy (%)	Size of compressed .tflite (MB)
MobileNetV1	70.976	14.97	Selective (last 3 Conv2D layers)	16, 16, 16	70.294	7.69
			Selective (last 3 Conv2D layers)	32, 32, 32	70.69	8.22
			Full (all Conv2D layers)	32	69.4	4.43
MobileNetV2	71.778	12.38	Selective (last 3 Conv2D layers)	16, 16, 16	70.742	6.68
			Selective (last 3 Conv2D layers)	32, 32, 32	70.926	7.03
			Full (all Conv2D layers)	32	69.744	4.05

The models were trained and tested on ImageNet.




- A tabela ao lado mostra alguns resultados de *clustering*.
- Notem que os tamanhos são reduzidos, mas que há uma redução na acurácia.


Knowledge distillation ou destilação de conhecimento



- É técnica de treinamento de modelos de ML em que um **modelo maior e mais complexo** (i.e., de maior capacidade), conhecido como "**professor**", é usado para **ensinar** (treinar) um **modelo menor e mais simples**, conhecido como "**aluno**".




Knowledge distillation ou destilação de conhecimento




- A ideia principal é **transferir o conhecimento** do modelo grande para o menor, **mantendo o desempenho**, mas com
 - **menos parâmetros,**
 - **menor consumo de memória e**
 - **maior velocidade de inferência.**
- Em outras palavras, queremos que o aluno aprenda a **generalizar** como o professor, mas de **forma mais eficiente**.

Frameworks de ML




- Um **framework** de ML é uma biblioteca ou um conjunto de ferramentas que **fornece funcionalidades e abstrações que facilitam a criação, treinamento e implantação** (i.e., inferência) de modelos de ML.

Frameworks de ML




- Alguns exemplos populares de **frameworks** de ML incluem TensorFlow, PyTorch, Scikit-learn e MXNet, etc.
- Usaremos o **Tensorflow (TF)**, pois é focado no desenvolvimento de redes neurais (profundas), além de apresentar versões direcionadas ao desenvolvimento de aplicações EdgeML.

Frameworks de ML



- Quando trabalhamos com aplicações envolvendo modelos de ML em **computadores de uso geral**, além da aplicação, SO e HW, nós usamos a biblioteca **TensorFlow** para a **criação, treinamento e implantação dos modelos**.

Frameworks de ML



- O **TensorFlow** foi **projetado** para tarefas de **alto desempenho e uso intensivo dos recursos disponíveis** (como CPUs e/ou TPUs/GPUs), além de usar operações em **ponto flutuante**.
- Ou seja, não há preocupação com as eficiências **energética** e **computacional**.

Frameworks de ML



- Além disso, o *TensorFlow* é **muito grande**, **não foi pensado para execução em dispositivos embarcados** e **realiza mais tarefas do que precisamos**.
- Por exemplo, em geral, por não conseguirmos fazer o treinamento nos dispositivos, não é necessário a parte da biblioteca destinada ao treinamento.

Frameworks de ML



- O **objetivo** com dispositivos embarcados é apenas **fazer previsões** (i.e., inferências).
- Portanto, quando queremos **executar modelos de ML em dispositivos com recursos limitados**, precisamos de um **framework mais enxuto e eficiente**.

TensorFlow (TF) Lite



Less memory

Less compute power

Only focused on *inference*



- Agora conhecido como Lite Runtime (LiteRT).
- Usado em smartphones, tablets e sistemas embarcados.
- ***Subconjunto do TF***, portanto, é ***mais restrito e enxuto***.
- Projetado para ser ***leve e eficiente em termos de uso de CPU e memória***.
- Aproveita periféricos (GPUs, TPUs, NPUs, etc) e instruções específicas de CPUs (SIMD, MAC, etc.) para acelerar os modelos.

TensorFlow (TF) Lite



Less memory

Less compute power

Only focused on *inference*



TensorFlow Lite

- Suporta técnicas de otimização, como **quantização**, **pruning** e **clustering**.
- Realiza ***apenas inferência****.
 - O modelo deve ser treinados em uma máquina com mais recursos.
- ***Compatível com modelos treinados no TF, permitindo sua conversão.***
- Exemplos:
 - <https://github.com/tensorflow/examples/tree/master/lite/examples>

*apenas executa o modelo treinado.


Sequência de trabalho com o TF Lite



TensorFlow Lite


- É possível gerar um modelo com extensão TF Lite de 3 formas:
 - Usando um modelo pré-treinado do TF Lite.
 - ✓ <https://github.com/tensorflow/examples/tree/master/lite/examples>
 - Criando um modelo do TensorFlow Lite.
 - ✓ Para isso, podemos usar o [TensorFlow Lite Model Maker](#)
 - Convertendo um modelo do TF em um do TF Lite.

Sequência de trabalho com o TF e TF Lite




- O primeiro passo é *treinar um modelo criado com o TF* em um computador com muitos recursos computacionais.
- Após, usamos o *TF Lite converter para converter* esse modelo grande em um modelo pequeno.
 - Durante a conversão, podemos aplicar otimizações ao modelo.

Sequência de trabalho com o TF e TF Lite



- Esse processo gera um **arquivo com extensão .tflite**, o qual contém o modelo.
- Na sequência, **usamos este arquivo para implantar o modelo** em smartphones, tablets ou sistemas embarcados.
 - Basta carregar o arquivo com APIs específicas do TF Lite e realizar inferências.

TF Lite Micro



Even less memory


Even less compute power

Also, only focused on *inference*

?

- Agora conhecido como LiteRT para microcontroladores.
- O TF Lite é a solução ideal para dispositivos edgeML.
 - EdgeML: dispositivos com capacidade computacional maior.
- Mas e quando falamos do uso de ML em ***dispositivos com recursos extremamente limitados*** e que requerem ***baixíssimo consumo de energia***, como microcontroladores?

TF Lite Micro



Even less memory


Even less compute power

Also, only focused on *inference*

?

- Como habilitamos a inferência nesses dispositivos?
- Eles têm ***capacidades computacionais muito menores*** em comparação com smartphones e tablets.
- Portanto, ***eles requerem uma implementação ainda mais enxuta e eficiente.***

TF Lite Micro



Even less memory

Even less compute power


Also, only focused on *inference*



TensorFlow Lite
Micro

- O TF Lite Micro é uma versão ainda *mais leve e otimizada do TF Lite*.
- Projetado para *dispositivos embarcados com recursos computacionais extremamente limitados*, como microcontroladores.
- Escrito em C++ 17 e *roda apenas em plataformas de 32 bits*.
- Testado em sistemas com CPUs baseadas na série ARM Cortex-M e ESP32.

TF Lite Micro



Even less memory

Even less compute power


Also, only focused on *inference*




TensorFlow Lite
Micro

- Precisa apenas de **16 KB de memória**.
- **Não requer**
 - suporte de **sistema operacional**,
 - **bibliotecas** C ou C++ padrão ou
 - **alocação dinâmica de memória**.
- Após a conversão do modelo TF em TF Lite, ele é convertido para uma **array de bytes** (chamado de **flatbuffer**), que é **compilada junto ao programa**.

Pipeline de desenvolvimento




Hardware especializado



- Outra forma para habilitar o uso de ML em dispositivos embarcados é através de *hardwares otimizados* para a *execução eficiente dos modelos*.


Hardware especializado




- Vários fabricantes têm lançados *Systems-on-a-Chip* (SoCs) e microcontroladores equipados com **GPUs** e/ou **aceleradores de ML**, também chamados de **neural processing units** (NPUs) ou **neural engines** (NEs).

Graphics Processing Unit (GPU)

Difference between GPU and CPU Cores



- CPUs have few strong cores
- Suited for serial workloads
- Designed for general purpose calculations




- GPUs have thousands of weaker cores
- Suited for parallel workloads
- Specialize in graphics processing

CGDIRECTOR.COM


- Componente de HW especialmente **projetado para lidar com tarefas paralelas de computação** envolvendo grandes quantidades de dados.
 - Executam a mesma operação em paralelo em uma grande quantidade de dados.

Graphics Processing Unit (GPU)

Difference between GPU and CPU Cores



- CPUs have few strong cores
- Suited for serial workloads
- Designed for general purpose calculations




- GPUs have thousands of weaker cores
- Suited for parallel workloads
- Specialize in graphics processing

CGDIRECTOR.COM


- Isso as torna ideal para trabalhar com ***aplicações com processamento intensivo que envolvam cálculos matriciais***, como
 - processamento e renderização de vídeo,
 - simulações físicas,
 - modelagem 3D,
 - treinamento de modelos de DL,
 - etc.

Graphics Processing Unit (GPU)



- Possuem vários pequenos **(GPU) cores especializados em operações de multiplicação e acumulação** (*multiply and accumulate* - **MAC**).
- Isso torna as GPUs muito boas em **operações paralelas** de multiplicação e adição de matrizes.
- Essas operações são **essenciais para o processamento de redes neurais**.

Graphics Processing Unit (GPU)




- Alguns modelos de GPUs têm *cores mais especializados ainda* para operações envolvendo matrizes.
- No caso da NVIDIA, esses *cores* são chamados de *Tensor Cores*.



$$\mathbf{D} = \begin{pmatrix} \begin{matrix} A_{0,0} & A_{0,1} & A_{0,2} & A_{0,3} \\ A_{1,0} & A_{1,1} & A_{1,2} & A_{1,3} \\ A_{2,0} & A_{2,1} & A_{2,2} & A_{2,3} \\ A_{3,0} & A_{3,1} & A_{3,2} & A_{3,3} \end{matrix} & \begin{matrix} B_{0,0} & B_{0,1} & B_{0,2} & B_{0,3} \\ B_{1,0} & B_{1,1} & B_{1,2} & B_{1,3} \\ B_{2,0} & B_{2,1} & B_{2,2} & B_{2,3} \\ B_{3,0} & B_{3,1} & B_{3,2} & B_{3,3} \end{matrix} & + & \begin{matrix} C_{0,0} & C_{0,1} & C_{0,2} & C_{0,3} \\ C_{1,0} & C_{1,1} & C_{1,2} & C_{1,3} \\ C_{2,0} & C_{2,1} & C_{2,2} & C_{2,3} \\ C_{3,0} & C_{3,1} & C_{3,2} & C_{3,3} \end{matrix} \end{pmatrix}$$

FP16 or FP32 FP16 FP16 or FP32

Graphics Processing Unit (GPU)




$$D = \begin{pmatrix} A_{0,0} & A_{0,1} & A_{0,2} & A_{0,3} \\ A_{1,0} & A_{1,1} & A_{1,2} & A_{1,3} \\ A_{2,0} & A_{2,1} & A_{2,2} & A_{2,3} \\ A_{3,0} & A_{3,1} & A_{3,2} & A_{3,3} \end{pmatrix} \begin{pmatrix} B_{0,0} & B_{0,1} & B_{0,2} & B_{0,3} \\ B_{1,0} & B_{1,1} & B_{1,2} & B_{1,3} \\ B_{2,0} & B_{2,1} & B_{2,2} & B_{2,3} \\ B_{3,0} & B_{3,1} & B_{3,2} & B_{3,3} \end{pmatrix} + \begin{pmatrix} C_{0,0} & C_{0,1} & C_{0,2} & C_{0,3} \\ C_{1,0} & C_{1,1} & C_{1,2} & C_{1,3} \\ C_{2,0} & C_{2,1} & C_{2,2} & C_{2,3} \\ C_{3,0} & C_{3,1} & C_{3,2} & C_{3,3} \end{pmatrix}$$

FP16 or FP32 FP16 FP16 or FP32


- Enquanto os **GPU cores** executam **apenas uma operação MAC por ciclo de clock**, os **Tensor cores** executam **várias operações**.
 - Por exemplo, um Tensor core da NVIDIA executa uma operação MAC matricial (matrizes 4x4) por ciclo de *clock*.
- Assim, eles aceleram ainda mais o treinamento de redes neurais.

Neural processing units (NPU)




- NPUs ou NEs são **hardwares altamente especializados projetados para acelerar aplicações de ML**.
- Por serem altamente especializadas, oferecem uma execução muito mais rápida do que as CPUs e GPUs (sem *Tensor cores*).
- NPUs realizam **operações paralelas de MAC** e algumas suportam **compactação e descompactação de pesos**, ajudando a **minimizar o uso da memória** do sistema.


Exemplos de hardware especializado



Huawei's Kirin 970




Apple's M1




ARM's Cortex-M55, Ethos-U55, U65 e N78


Exemplos de hardware especializado



Apple's A12




Apple's A13




NVIDIA's Xavier SoC
(CUDA cores + Tensor cores)

Exemplos de hardware especializado



Tesla's FSD

NPU versus GPU





- Esses *HWs especializados* *habilitam aplicações mais complexas* como
 - detecção, segmentação e rastreamento de objetos,
 - reconhecimento de fala em tempo real.
- A figura ao lado mostra que a união de CPU+GPU+NPU no Kirin 970 da Huawei faz com que ele supere de longe a CPU+GPU do iPhone 7 plus na tarefa de *classificação de imagens*.




Atividades

- Quiz: “***TP557 - Desafios do TinyML - Machine Learning***”
- Assistir aos vídeos do Prof. Marcelo Rovai sobre Google Colab e Python.
 - **Google Colab intro:**
https://www.youtube.com/watch?v=m_Ueb88yd88&ab_channel=MarceloRovai
 - **Python review:**
https://www.youtube.com/watch?v=07tGfteD4_s&ab_channel=MarceloRovai
 - **Notebooks e documentos usados nos vídeos:**
https://github.com/Mjrovai/UNIFEI-UESTI01-TinyML-2022.1/tree/main/00_Curse_Folder/1_Fundamentals/Class_04a

Perguntas?

Obrigado!







$$y = f(g(x)) = f\left(\left(\sum_{i=1}^K w_i x_i\right) + b\right)$$



$$y = f\left(\left(\sum_{i=1}^K w_i x_i\right) + b\right)$$

Pesos ou
parâmetros







**Podando
sinapses**




**Podando
neurônios**





Professor




Aluno





Aplicação




Framework
de ML



TensorFlow

Sistema Operacional


Hardware
de uso geral



Dados não rotulados



Dados agrupados



✕ centroides

K-means



Matriz 4x4 com os pesos (*floats*)
de uma camada

0.86	-1.88	-1.49	-0.51
-1.7	1.58	0.12	-2.38
1.9	-2.19	1.37	-2.79
1.92	0.46	-2.85	0.61

Encontrar
centroides



Centroides
dos clusters

-2.85	0
-1.26	1
0.33	2
1.92	3


Atribuir
índices




Armazena apenas os índices e os
centroides

2	1	1	1
1	3	2	0
3	0	3	0
3	2	0	1

Dados não rotulados



Dados agrupados



K-means



x centroides

Matriz 4x4 com os pesos (*floats*)
de uma camada

0.86	-1.88	-1.49	-0.51
-1.7	1.58	0.12	-2.38
1.9	-2.19	1.37	-2.79
1.92	0.46	-2.85	0.61

Encontrar
centroides



Centroides
dos clusters

-2.85
-1.26
0.33
1.92

Atribuir
centroides



Armazena os centroides

0.33	-1.26	-1.26	-1.26
-1.26	1.92	0.33	-2.85
1.92	-2.85	1.92	-2.85
1.92	0.33	-2.85	-1.26