


TP557 - Tópicos avançados em IoT e  
Machine Learning:

# *O Paradigma do Aprendizado de Máquina*



***Inatel***

Felipe Augusto Pereira de Figueiredo  
felipe.figueiredo@inatel.br

# O que vamos ver?

- Nesta aula vamos explorar o que o aprendizado de máquina realmente é em um nível fundamental.
- Basicamente, o que vamos discutir é um ***novo paradigma***, onde ***ao invés de programar uma solução*** para um determinado problema, vamos ***ensinar um computador a aprender a solução*** através de experiências prévias.
- Esse novo paradigma tem o potencial para ***resolver problemas que não podem ou são muito difíceis de serem resolvidos programaticamente***.

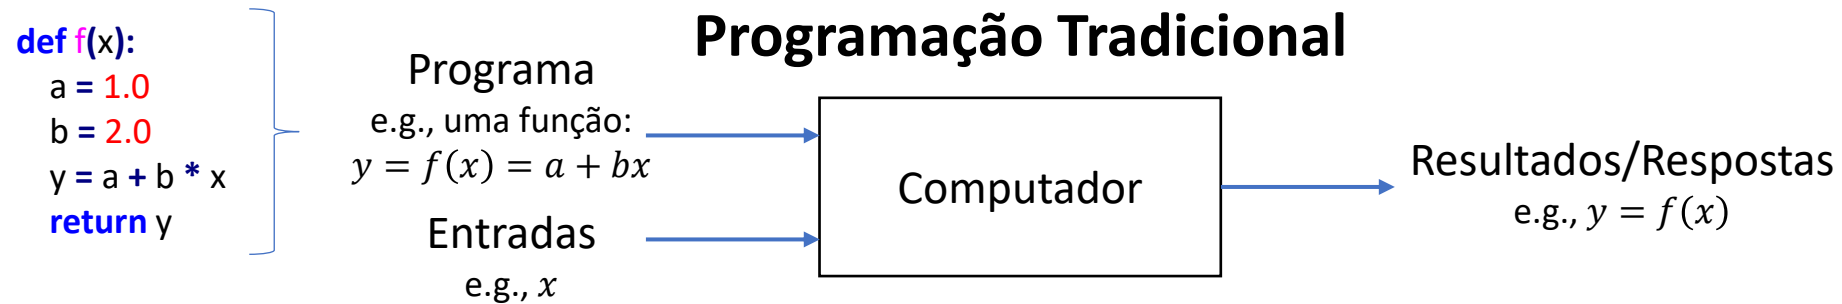
# O que é o Aprendizado de Máquina?



- É uma das subáreas da inteligência artificial.
- O termo foi cunhado em 1959, pelo cientista da computação Arthur Samuel, que o definiu como o  
*“Campo de estudo que dá aos computadores a habilidade de **aprender sem serem explicitamente programados.**”*
- Mas como eles aprendem?
  - Através de **experiências prévias, induz-se** conhecimento nas máquinas.
- Algoritmos de ML são **orientados a dados**, i.e., eles **aprendem automaticamente** (através de treinamento) uma **solução geral** a partir de **conjuntos de dados** fornecidos a eles.



# Programação tradicional



- Na programação tradicional, o programador analisa um problema e cria um código (ou programa) para resolvê-lo.
  - Código: sequência de regras que definem o comportamento do programa.
- Na sequência, o computador recebe o código e os dados (i.e., entradas), o aplica aos dados e retorna os valores de saída.

# Programação tradicional



```
if(speed<4){  
    status=WALKING;  
}
```



```
if(speed<4){  
    status=WALKING;  
} else {  
    status=RUNNING;  
}
```



```
if(speed<4){  
    status=WALKING;  
} else if(speed<12){  
    status=RUNNING;  
} else {  
    status=BIKING;  
}
```

- Porém, em alguns casos é muito difícil criar um código para solucionar um problema de forma geral.
- Vamos ver uma situação onde esse paradigma não funciona bem.
- Vamos supor que queremos criar uma aplicação para celular/*smart watch* que **detecte atividades como andar, correr e pedalar**.
- Nesse caso, podemos usar a **velocidade** e criar algumas **regras** para **diferenciar as atividades**.

# Programação tradicional



```
if(speed<4){  
    status=WALKING;  
}
```



```
if(speed<4){  
    status=WALKING;  
} else {  
    status=RUNNING;  
}
```



```
if(speed<4){  
    status=WALKING;  
} else if(speed<12){  
    status=RUNNING;  
} else {  
    status=BIKING;  
}
```

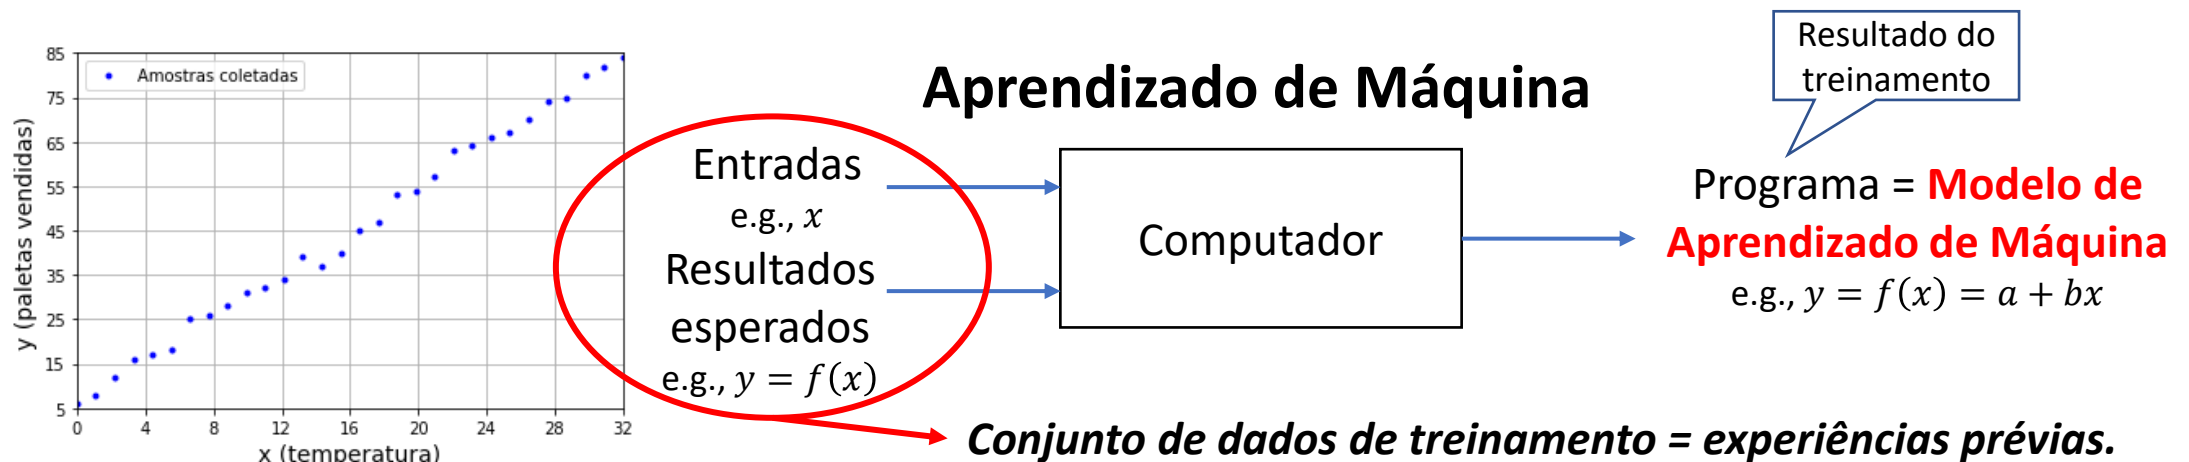


```
// ???
```

- Mas e se quisermos estender a aplicação para identificar que o usuário está jogando golfe, como poderíamos identificar essa atividade?
- Além disso, vejam que as regras que criamos são bem simples e com certeza gerariam vários erros de identificação.
  - Por exemplo, podemos correr ladeira abaixo mais rápido do que pedalamos ladeira acima.
- Aprendizado de máquina pode nos ajudar a resolver este problema.

# O paradigma do aprendizado de máquina

- “... *aprender sem serem explicitamente programados*.”
- Isso pode ser representado com uma simples reorganização do diagrama anterior:
  - E se ao invés tentarmos descobrir as regras que agem sobre os dados para gerar as respostas, fizermos o contrário? Ou seja, fornecer as respostas e os dados a um computador e deixar que ele descubra as regras que geram as saídas (i.e., um mapeamento das entradas nas respostas esperadas)?





# O paradigma do aprendizado de máquina



```
0101001010100101010  
1001010101001011101  
0100101010010101001  
0101001010100101010
```

Label = WALKING



```
1010100101001010101  
0101010010010010001  
0010011111010101111  
1010100100111101011
```

Label = RUNNING



```
1001010011111010101  
1101010111010101110  
1010101111010101011  
1111110001111010101
```

Label = BIKING



```
1111111111010011101  
0011111010111110101  
0101110101010101110  
1010101010100111110
```

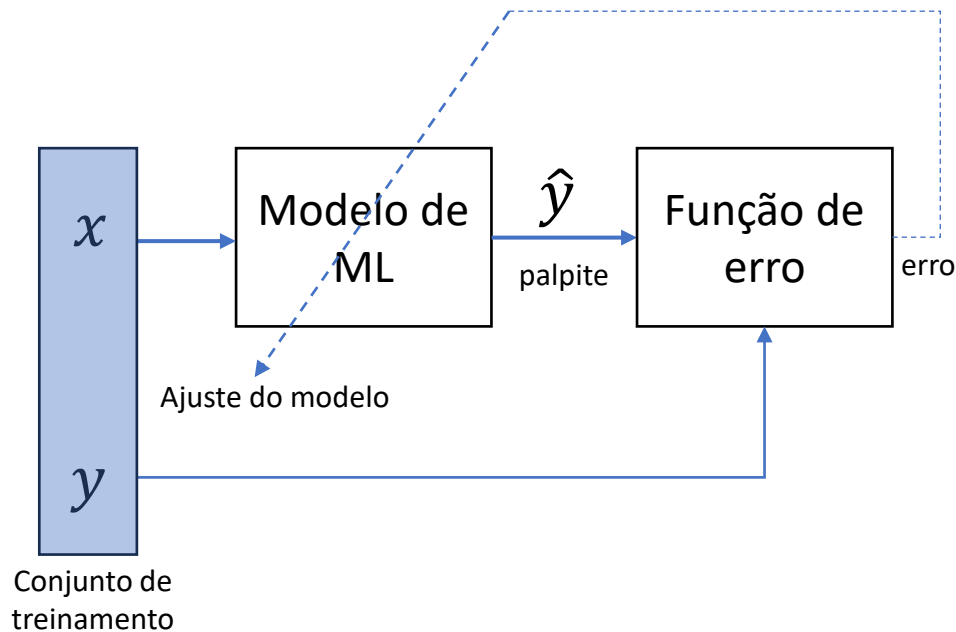
Label = GOLFING

O computador aprende, através do seu treinamento, *padrões* nos dados que podem ser mapeados nas atividades.

- No caso da nossa aplicação, podemos coletar muitas informações de sensores diferentes e rotulá-las (i.e., saídas) com a atividade do usuário.
- Usando este **conjunto de dados** (informação dos sensores e rótulos), o computador pode ser capaz de descobrir as regras que identificam as atividades: caminhar, correr, pedalar ou até mesmo jogar golfe.

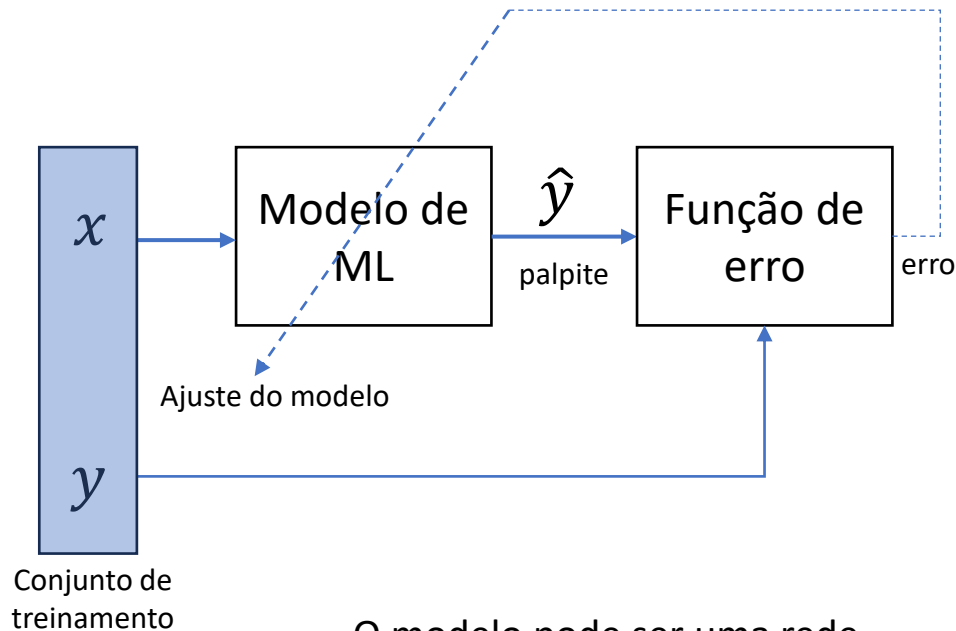


# Treinamento da máquina



- Vamos ver como o treinamento da máquina (i.e., dos modelos) funciona em alto nível.
- Primeiro, o computador faz um **mapeamento aleatório** da entrada,  $x$ , em um valor de saída,  $\hat{y}$ , ou seja, dá um **palpite** sobre qual deve ser a saída para aquela entrada.
- Em seguida, usando as saídas esperadas,  $y$ , (i.e., rótulos), ele **mede o quão bom ou ruim é esse palpite**.
- Medimos a qualidade do palpite usando uma função chamada de **função de perda, erro ou custo**.

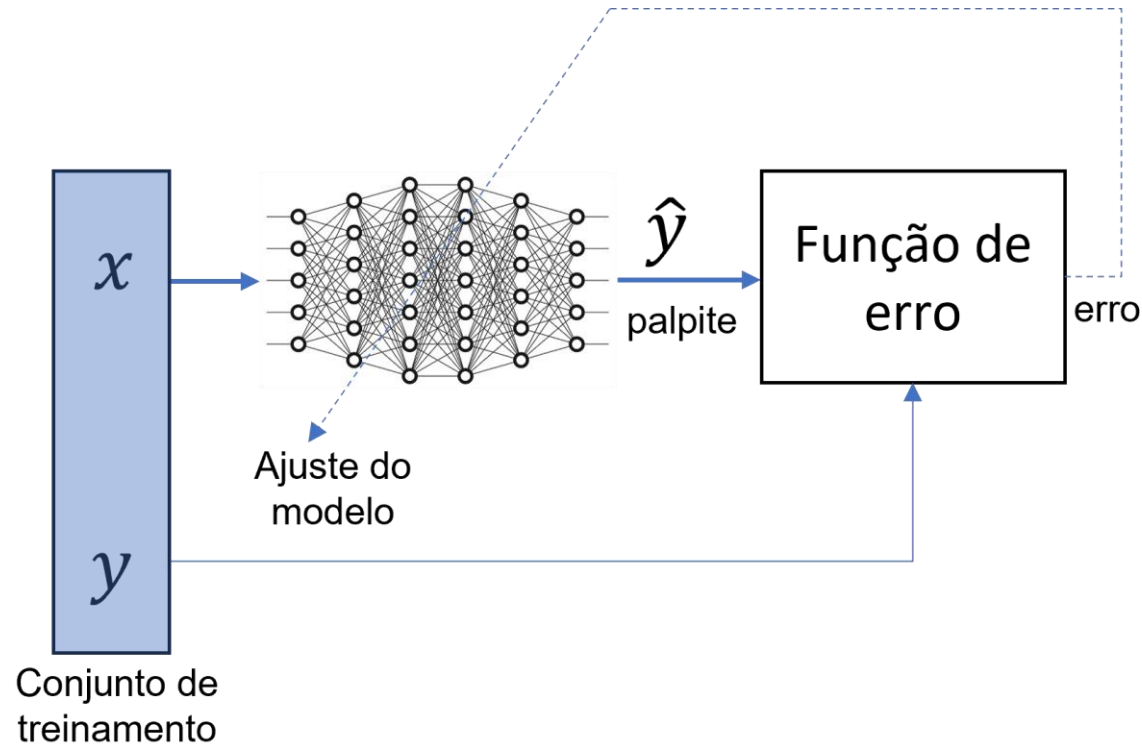
# Treinamento da máquina



O modelo pode ser uma rede neural onde o processo de treinamento otimiza os seus pesos para minimizar o erro.

- Na sequência, o modelo usa os resultados do erro (ou perda) para otimizar o modelo e, com isso, melhorar o próximo palpite.
- Esse processo é repetido até que o erro/perda seja minimizado.
  - *A ideia é que a cada repetição, o palpite se torne melhor do que o anterior, fazendo com que o erro diminua e o modelo se torne mais preciso.*
- Percebam que a solução para o problema é encontrada com base em experiências prévias, ou seja, com o conjunto de treinamento (i.e., entradas e saídas esperadas).
- Isso é chamado de ***raciocínio indutivo***, que é um processo pelo qual chega-se a ***conclusões gerais*** a partir de ***experiências passadas***.


# Treinamento da máquina




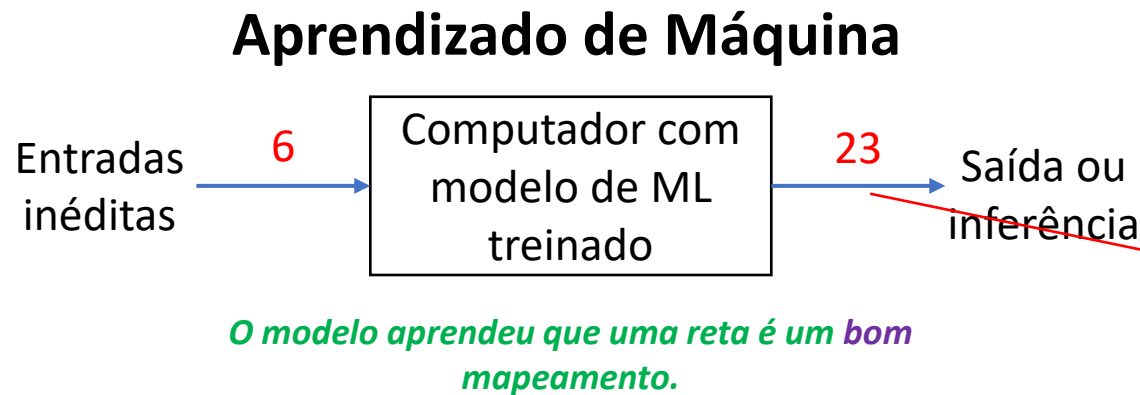
- Por exemplo, o modelo pode ser uma rede neural onde o processo de treinamento otimiza os seus pesos a fim de minimizar o erro e, consequentemente, resolver um problema classificação de imagens, aproximação de curvas, etc.

# Inferência e generalização

- Através de **treinamento** (i.e., do aprendizado) com um **conjunto de dados**, o **algoritmo** de ML **aprende** um **modelo** (i.e., as regras ou mapeamento) que **reproduz os resultados esperados** e, o **mais importante, generaliza para entradas não vistas durante o treinamento**.



Qual é a estimativa de picolés vendidos quando a temperatura é de  $\approx 6$  graus (não vista durante o treinamento)?



A partir do mapeamento aprendido (reta), o modelo gera como saída o valor 23, que é coerente com o restante dos dados.

# Atividades

- Quiz: “***TP557 - O Paradigma do Aprendizado de Máquina***”.

Perguntas?

Obrigado!



