TP557 - Tópicos avançados em IoT e Machine Learning:

Regressão com DNNs (Parte II)

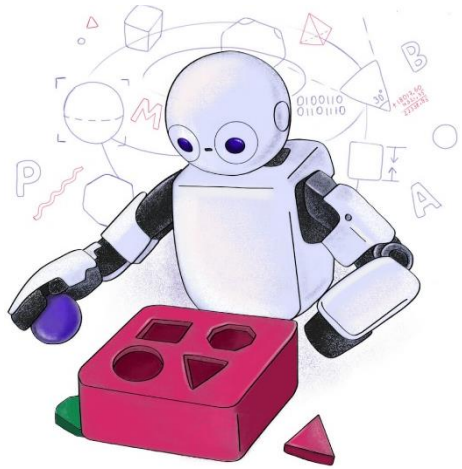

Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

O que vamos ver?

- Anteriormente, vimos através de um ***exemplo simples*** como usar a ***biblioteca TensorFlow*** para ***criar uma rede neural e resolver um problema de regressão***, ou seja, um problema de ajuste de curva.
- O objetivo era ter um ***contato inicial com a biblioteca*** e seus ***princípios básicos*** de funcionamento.
- Nesse tópico, vamos estender o que vimos anteriormente para um ***problema mais prático de regressão*** usando uma ***base de dados do mundo real***.

Tipos de aprendizado

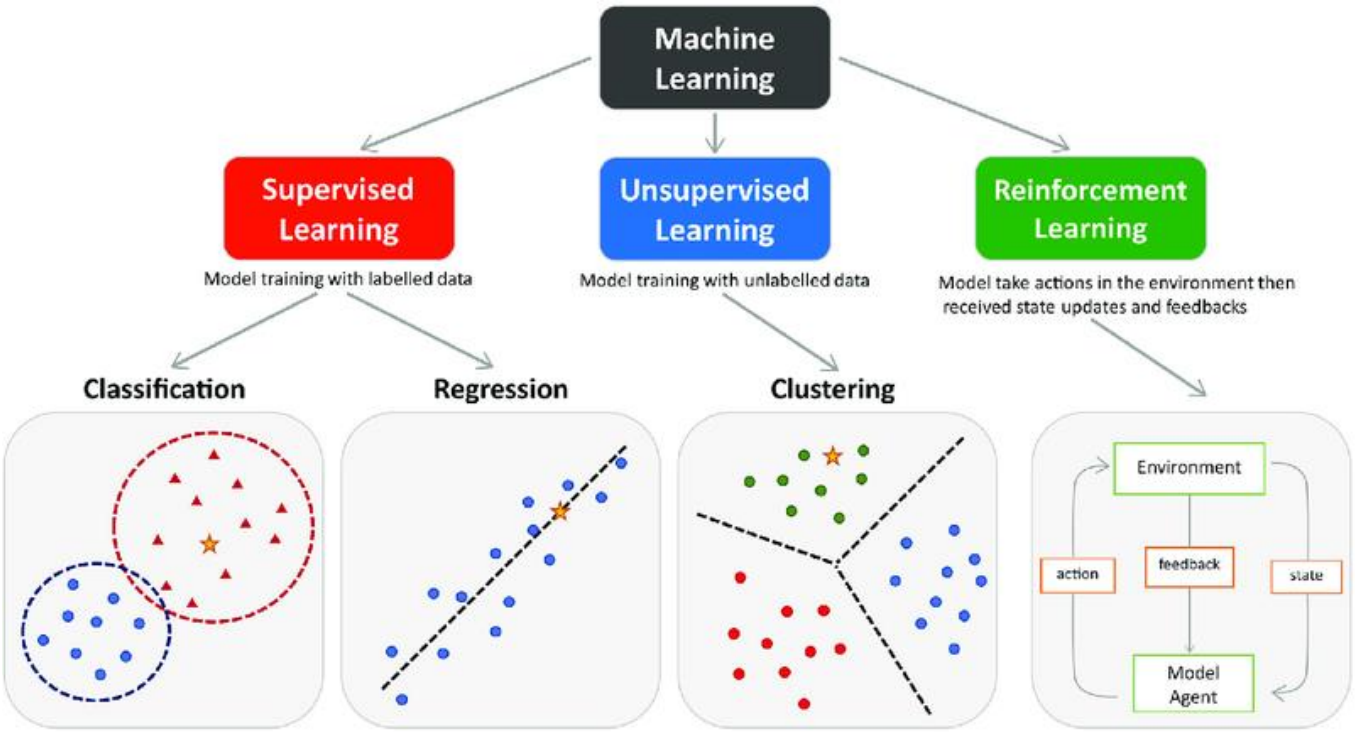

- Antes de entrarmos na regressão propriamente dita, vamos entender um pouco sobre as ***formas como os algoritmos de ML aprendem*** e as ***arquiteturas*** que podemos encontrar.

Tipos de aprendizado

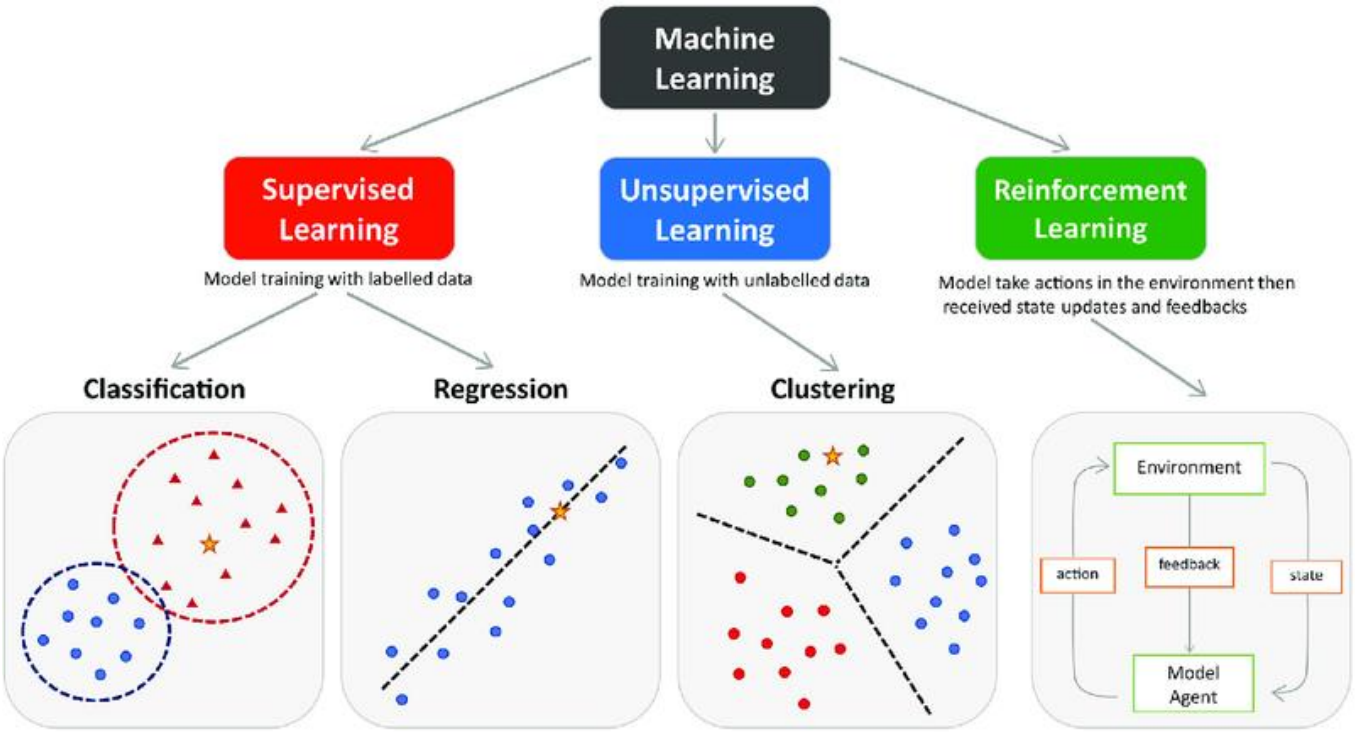

- Podemos agrupar os algoritmos de ML através da forma como eles aprendem:
  - Aprendizado supervisionado.
  - Aprendizado não-supervisionado.
  - Aprendizado por reforço.
- Existem outros, mas esses são os três mais conhecidos.

Aprendizado supervisionado

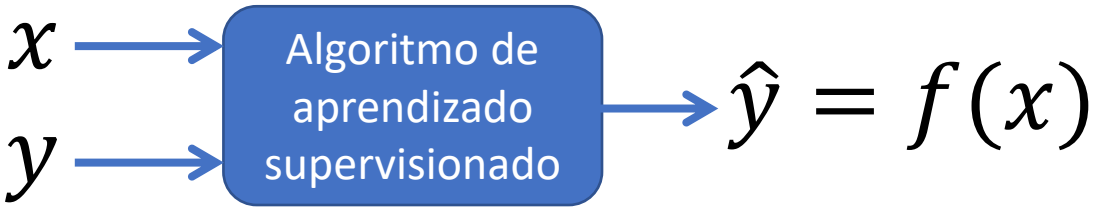

- O modelo é treinado usando um ***conjunto de dados*** que contém ***exemplos de entrada*** (também conhecidos como ***atributos***) junto com ***as saídas correspondentes*** (***rótulos*** ou respostas corretas).

Aprendizado supervisionado

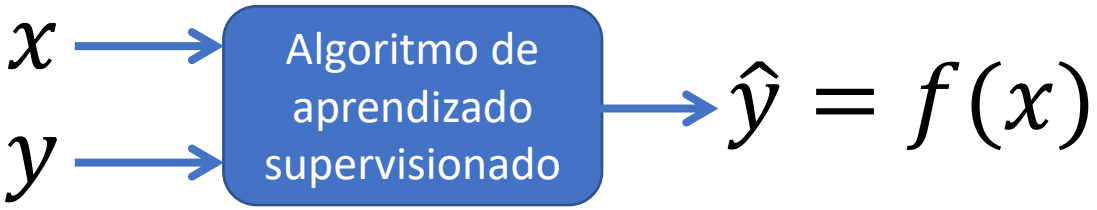

- O objetivo é que o modelo aprenda a ***mapear as entradas nas saídas corretas***, de modo que ele possa fazer predições precisas em novos dados para os quais as saídas corretas não são conhecidas (i.e., ***generalização***).

Aprendizado supervisionado

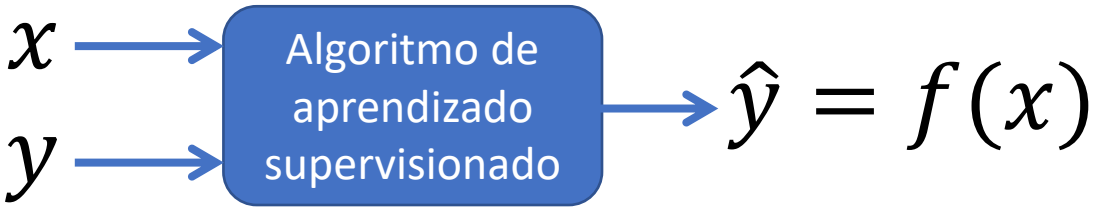

- O termo ***supervisionado*** reflete o fato de que durante o treinamento, o modelo é ***guiado*** ou ***supervisionado*** pelos ***rótulos a aprender a mapear as entradas nas saídas desejadas***.

Aprendizado supervisionado

Regressão

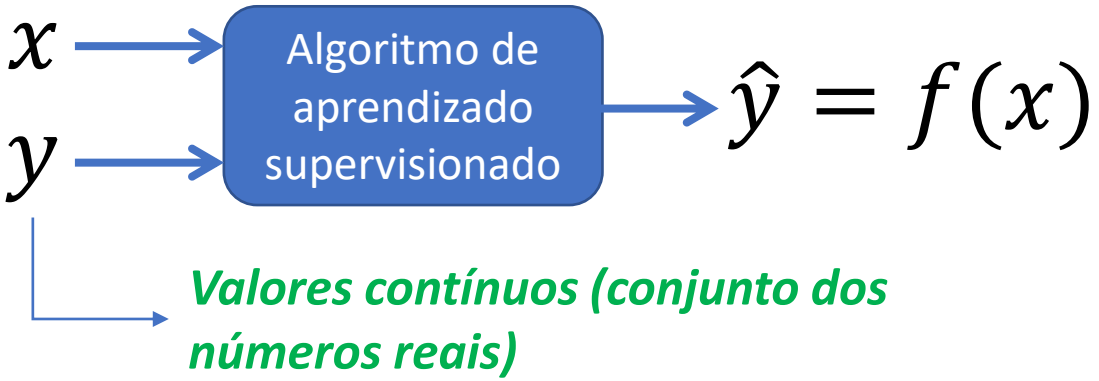

Classificação

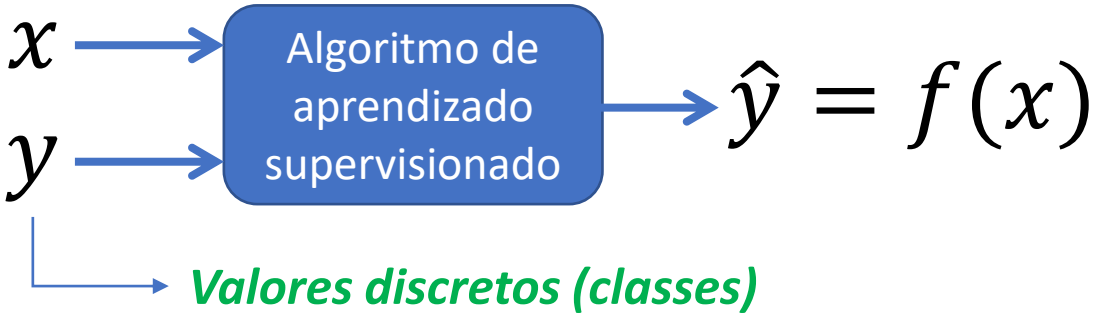

- Algoritmos de aprendizado supervisionado são frequentemente usados em tarefas de
  - ***classificação***: objetivo é atribuir uma categoria ou classe a uma entrada.
  - e ***regressão***: objetivo é predizer um valor numérico.
- São algoritmos usados em predição de preços de imóveis, detecção de objetos, etc.

Classificação e regressão

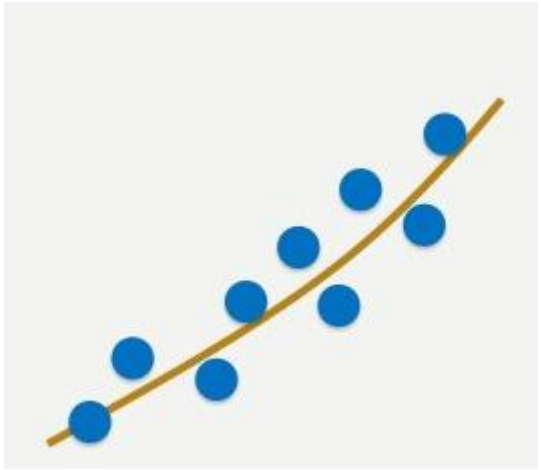

$f(\boldsymbol{x})$ ***aproxima*** o comportamento dos dados.

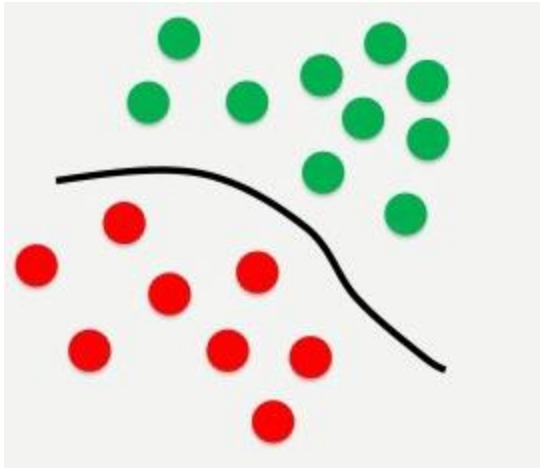

$f(\boldsymbol{x})$ ***separa*** os dados em classes.

- O ***objetivo*** da ***regressão*** é encontrar uma ***função*** que ***aproxime o comportamento dos dados*** com o ***menor erro possível*** ao longo de todos os exemplos do conjunto de dados.

Classificação e regressão

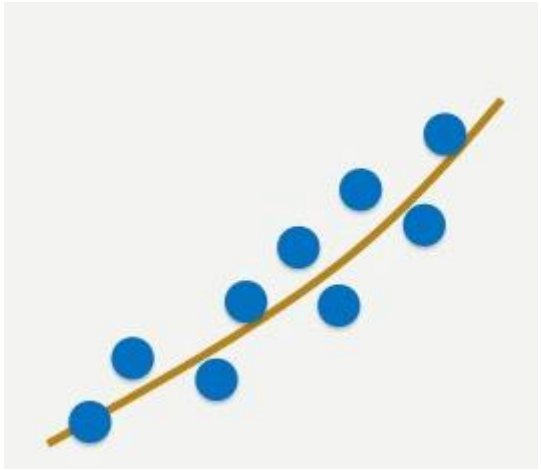

$f(\boldsymbol{x})$ ***aproxima*** o comportamento dos dados.

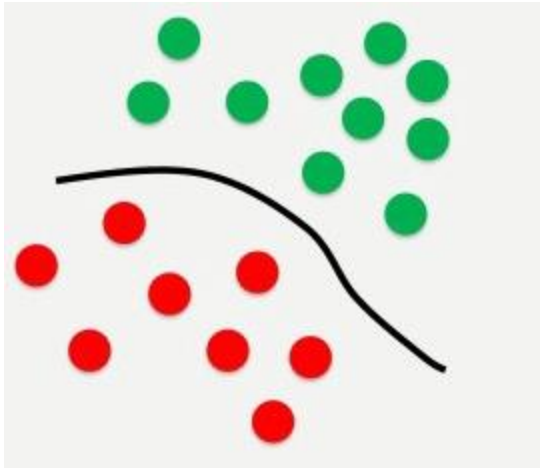

$f(\boldsymbol{x})$ ***separa*** os dados em classes.

- O ***objetivo*** da ***classificação*** é ***encontrar uma função que separe os dados em classes com o menor erro possível***.
- Nosso curso focará mais nesses dois problemas de aprendizado supervisionado.

Aprendizado não-supervisionado

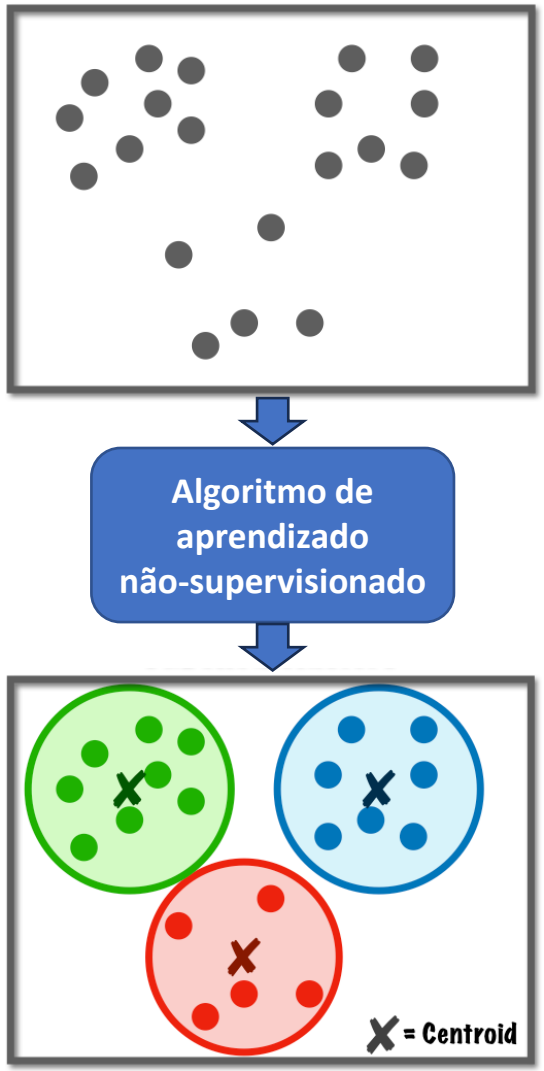

- Como já dá para supor pelo nome, o ***modelo é treinado sem a presença rótulos***.
- Ou seja, ***não se sabe quais são as respostas corretas*** para as entradas.

Aprendizado não-supervisionado

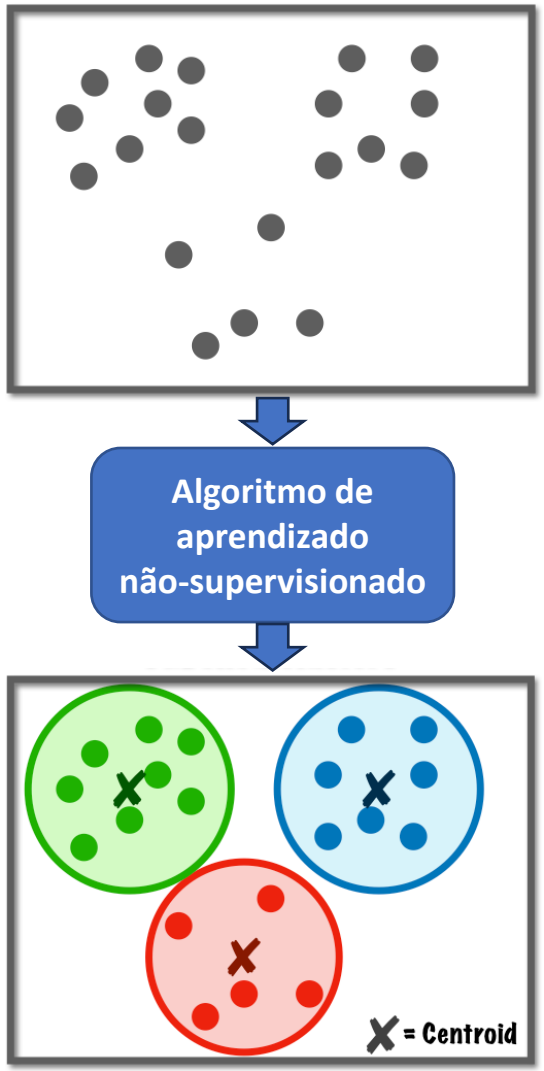

- O objetivo é ***descobrir padrões***, ***estruturas*** ou ***relações intrínsecas*** nos dados ***sem o auxílio de orientação explícita***, se ***baseando*** apenas, por exemplo, ***na similaridade entre as entradas*** (i.e., os atributos).
  - Por exemplo, a proximidade entre os dados.
- São algoritmos usados em detecção de anomalias, redução de dimensionalidade, compressão, etc.

Aprendizado por reforço

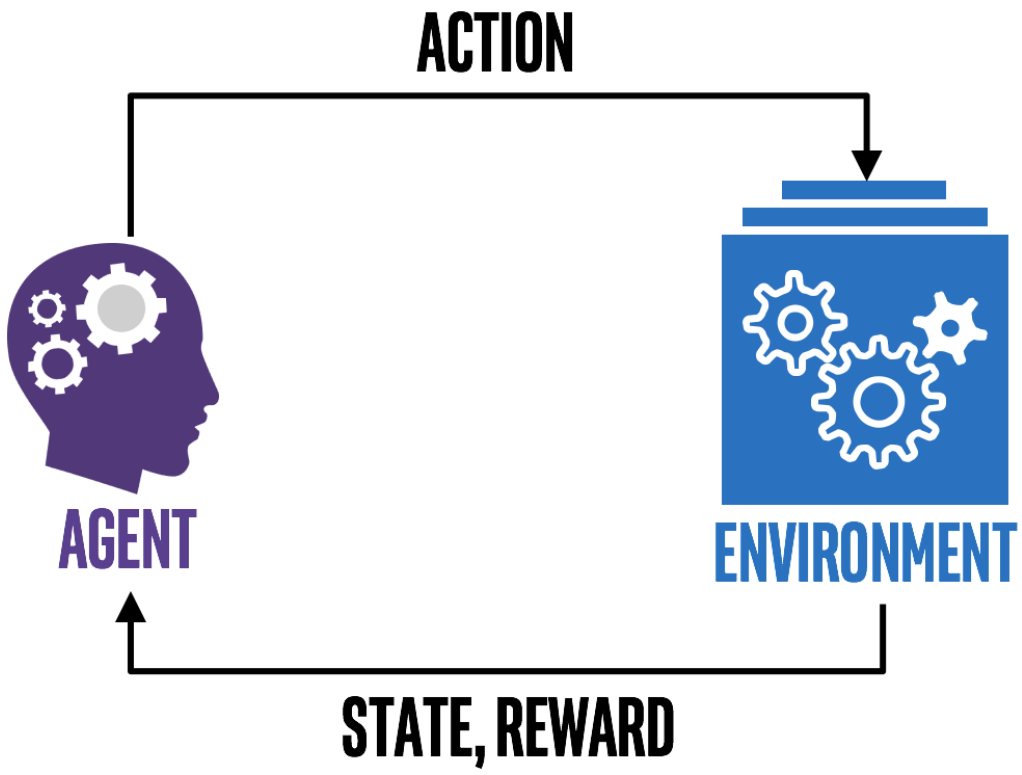

- Aprendizado totalmente diferente dos anteriores, pois ***não existem exemplos de treinamento***, sejam eles rotulados ou não.
- Abordagem de aprendizado em que um ***agente***, i.e., o algoritmo de ML, ***aprende a tomar decisões interagindo com um ambiente***.

Aprendizado por reforço

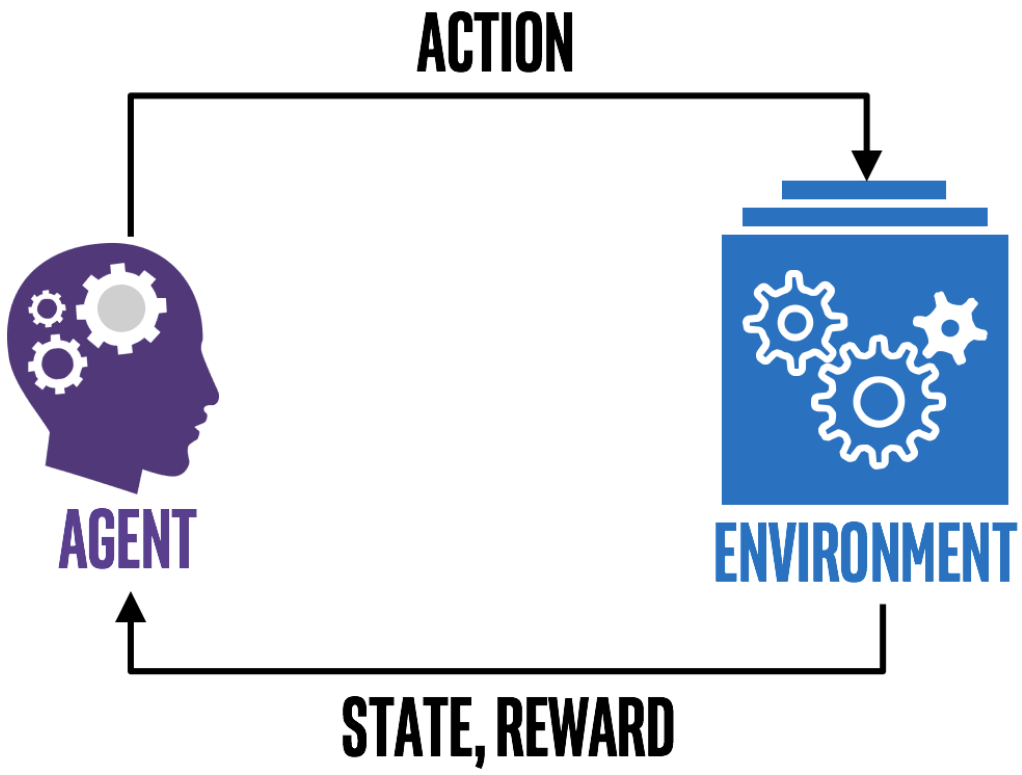

- Frequentemente ***usado em situações*** em que ***não é possível ter um conjunto de treinamento*** ou em ***ambientes onde as respostas não são conhecidas com antecedência***.

Aprendizado por reforço

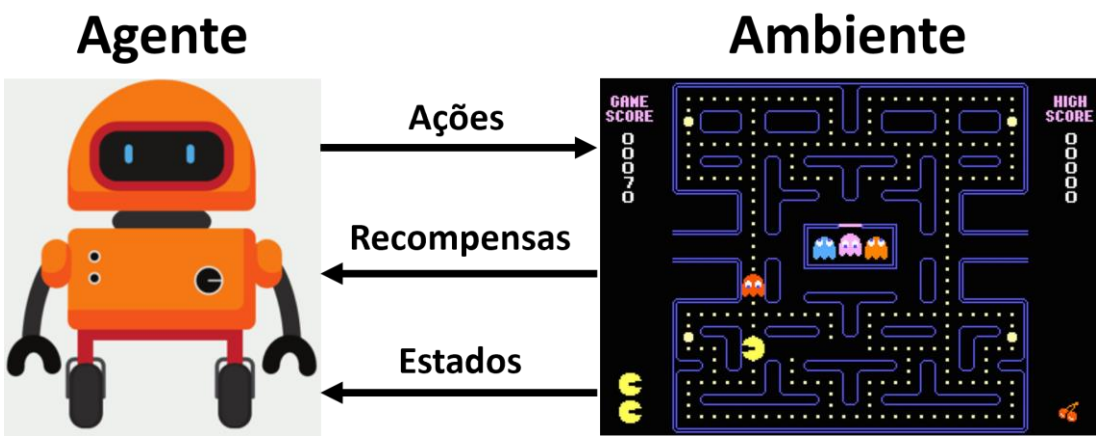

- O ***agente toma ações*** em um ambiente para ***maximizar*** a ***recompensa acumulada*** ao longo do tempo.
- O ***objetivo*** é encontrar uma ***função***, chamada de ***política***, que ***mapeie os estados na sequência de ações que maximize a recompensa acumulada***.

Aprendizado por reforço

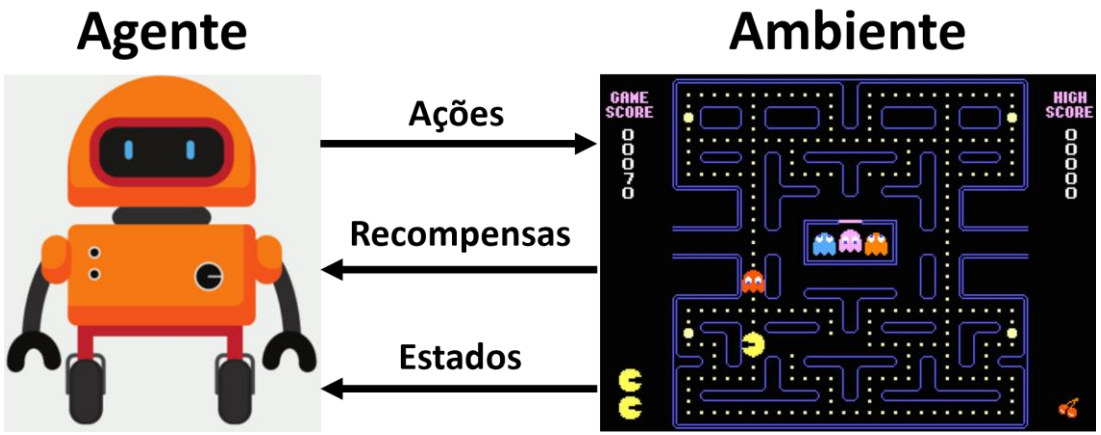

- A principal característica do aprendizado por reforço é que o ***agente aprende através de tentativa e erro***, ***ajustando*** suas ***ações*** com ***base nos reforços*** (positivos ou negativos) que recebe do ambiente.
- São algoritmos usados em jogos, robótica, carros autônomos, etc.

Modelos de aprendizado supervisionado

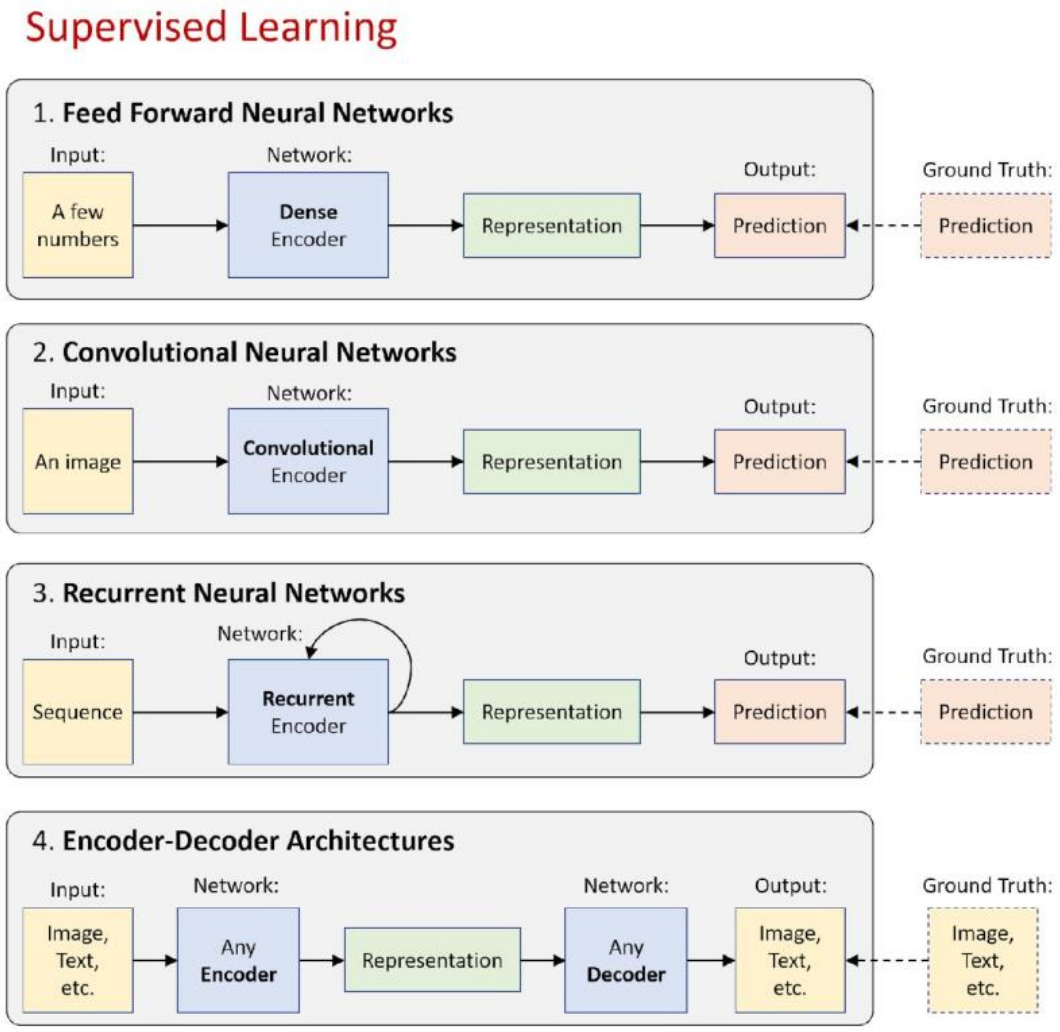

- Dos três paradigmas de aprendizado, neste curso, ***vamos focar no supervisionado***.
- Dentro do aprendizado supervisionado, temos alguns modelos (ou ***arquiteturas***) de redes neurais ***que são bastante usados***.
- **OBS**.: Além das redes neurais, existem outros modelos que seguem esse paradigma de aprendizado: regressão linear/logística, árvores de decisão, k-vizinhos mais próximos, etc.

Rede neural de alimentação direta (DNN)

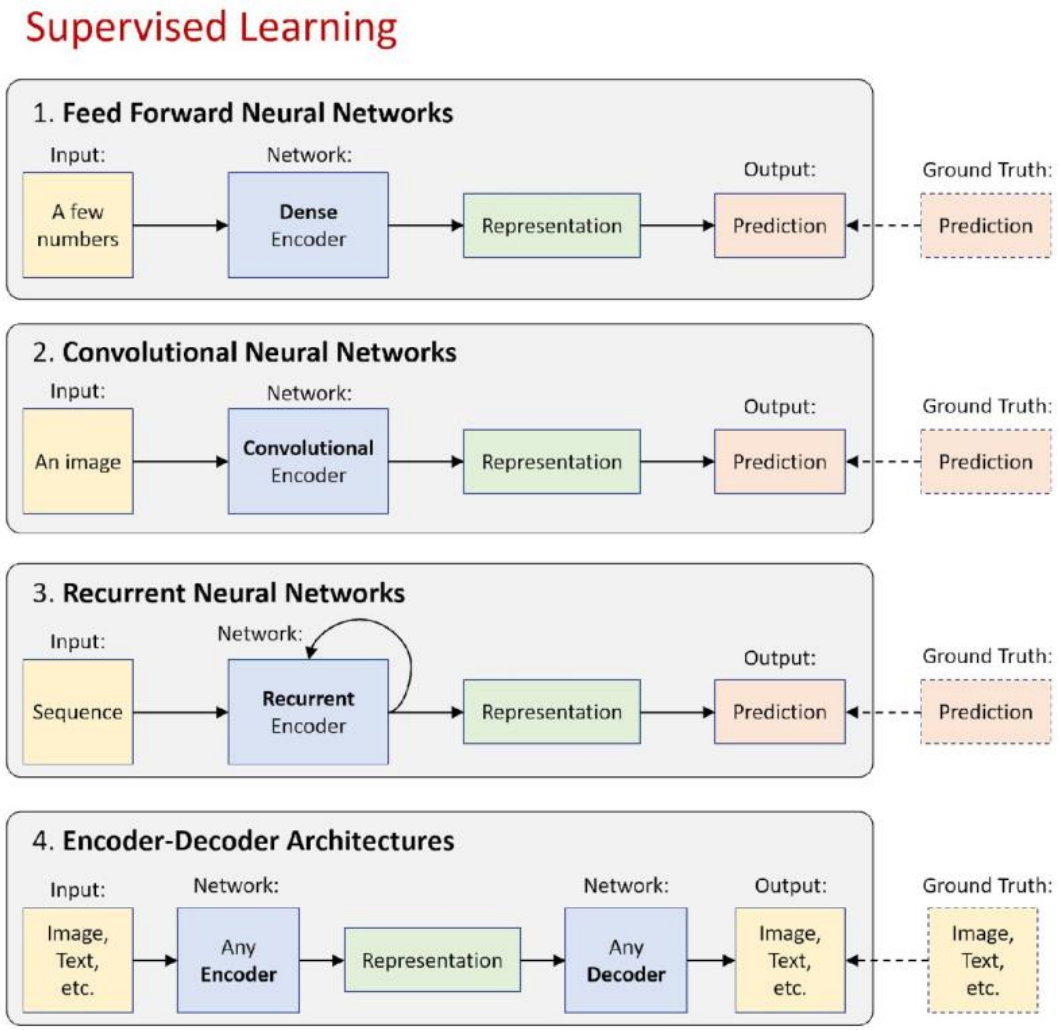

- Modelo que vimos anteriormente.
- Também chamado de ***rede neural densa***, devido aos ***neurônios*** estarem ***densamente conectados***.
- Ainda outro nome que este modelo recebe é *Multilayer Perceptron* (MLP).
- É chamada de "*feed forward*" porque a informação flui através da rede no sentido da entrada para a saída.

Rede neural convolucional (CNN)

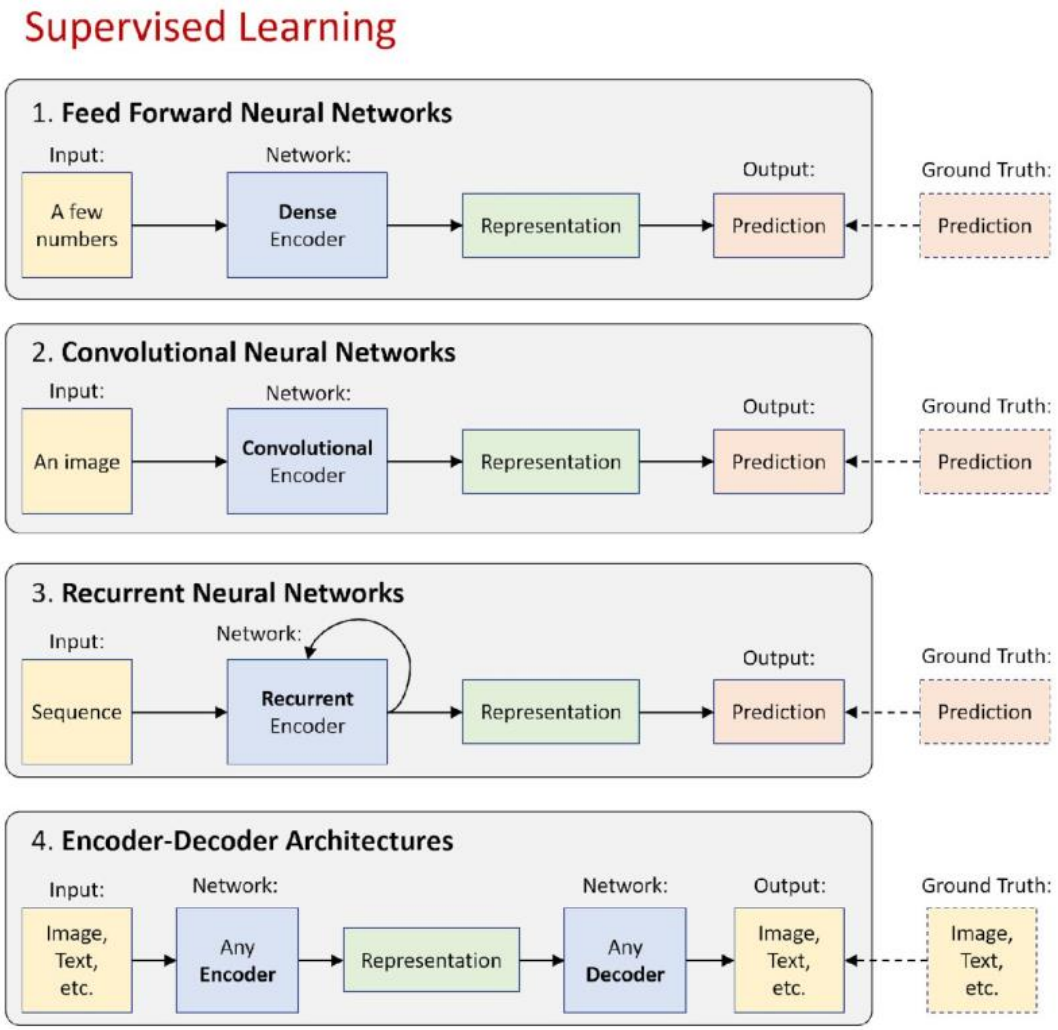

- Arquitetura projetada para lidar com dados multidimensionais (tensores 2D, 3D, etc.), como imagens e vídeos.
- O ***coração*** das CNNs são as ***camadas convolucionais***.
- Elas aplicam ***operações de convolução*** para ***extrair e identificar padrões espaciais*** em imagens ou vídeos.

Rede neural convolucional (CNN)

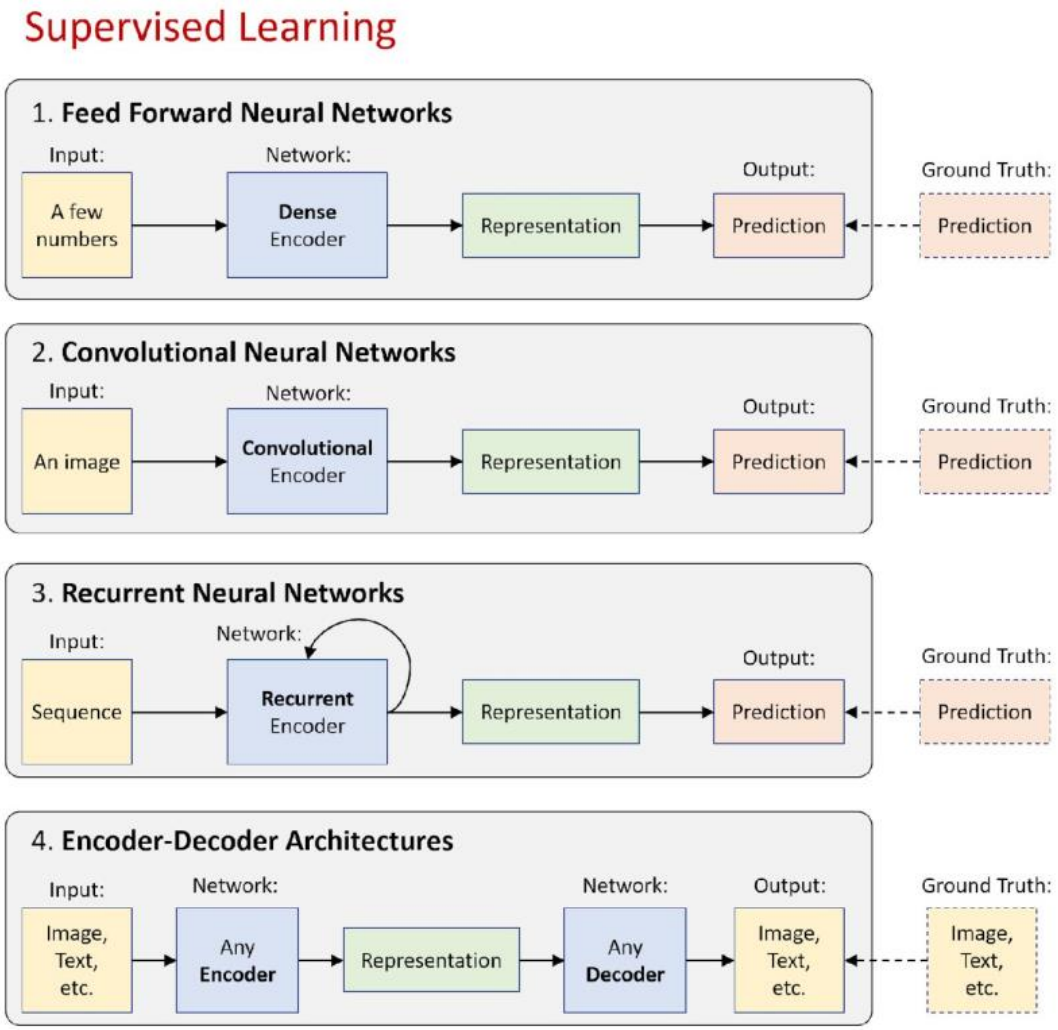

- A rede ***aprenda automaticamente a detectar características visuais*** como bordas, texturas e outros padrões visuais.
- São altamente eficazes em problemas de processamento de imagem, incluindo classificação, detecção e segmentação.

Rede neural recorrente (RNN)

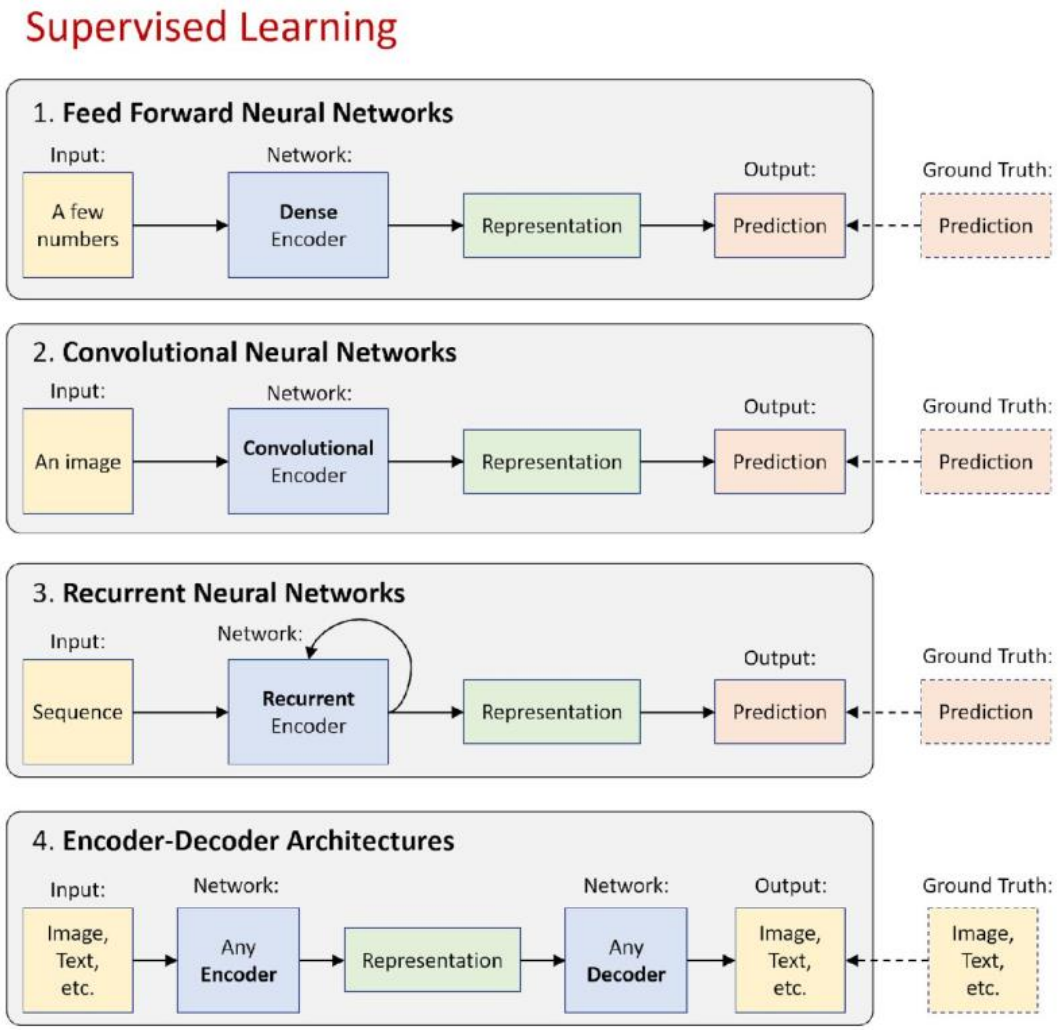

- Modelo projetado para ***lidar com dados sequenciais***, onde a ***ordem e a dependência temporal dos dados são importantes***.
- As RNNs têm ***memória*** de estado interna que permite que elas ***mantenham informações sobre as entradas anteriores*** ao longo do tempo.
- São adequadas para tarefas de análise de texto, reconhecimento de fala, previsão de séries temporais e tradução automática de texto e fala.

Autoencoders

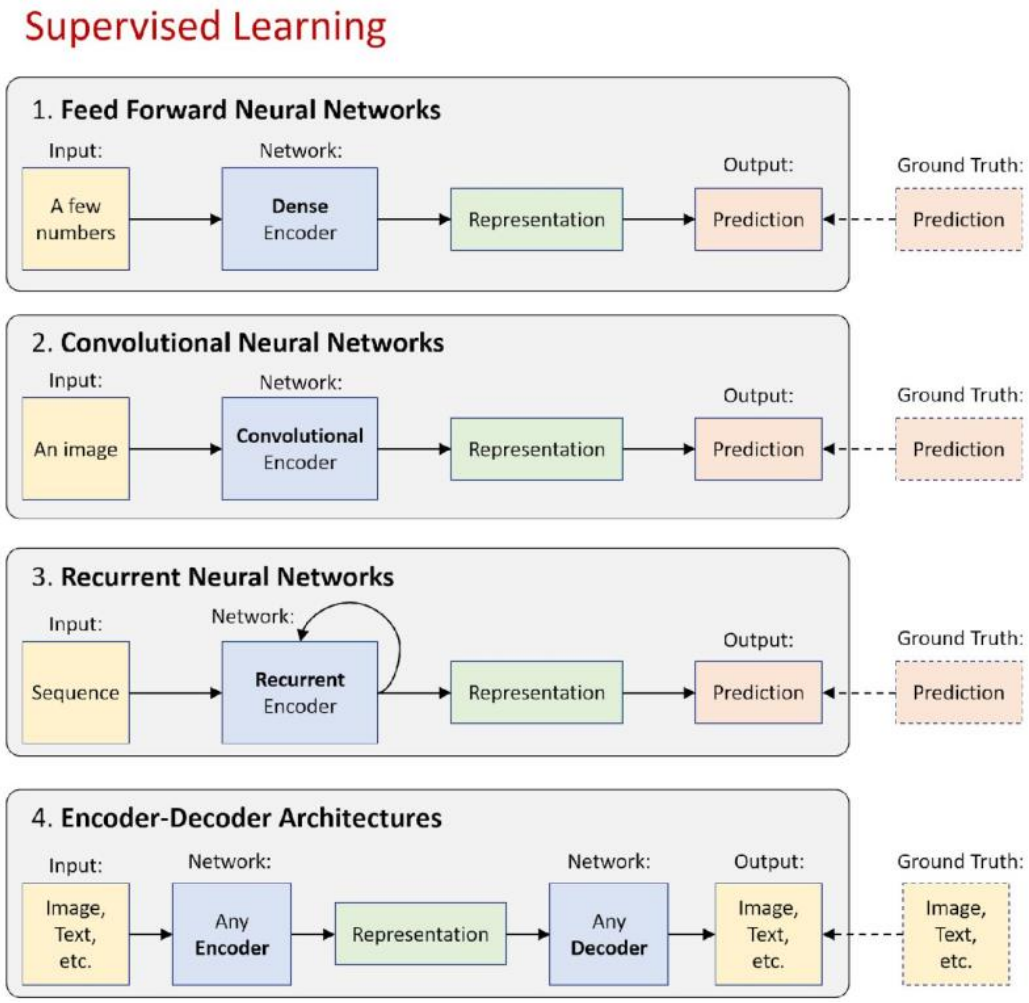

OBS.: Alguns autores não o consideram supervisionado.

- Modelo de rede neural composto por duas partes principais: o *encoder* e o *decoder*.
- ***Objetivo*** é ***aprender uma representação latente*** que ***capture*** as ***principais características e padrões dos dados*** de entrada.

Autoencoders

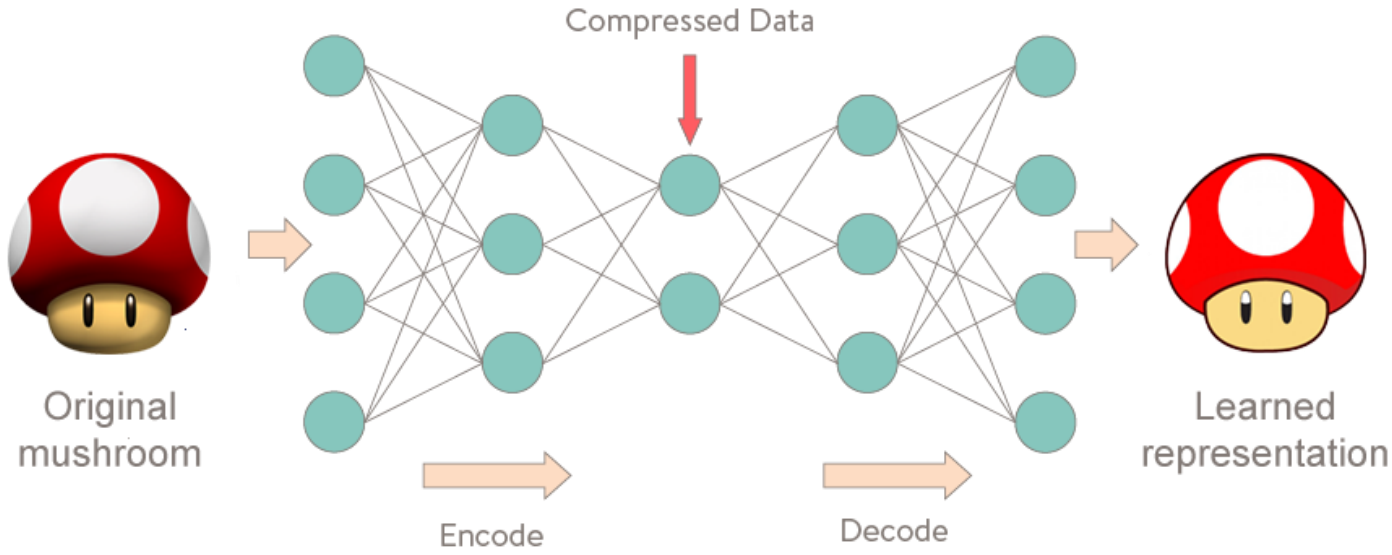

- O ***encoder transforma a entrada em uma representação latente*** (de menor ou maior dimensionalidade) e o ***decoder reconstrói a entrada original a partir dela***.
- São usados em compressão de dados, remoção de ruído, codificação de sinais, geração de dados sintéticos, etc.
- **OBS**.: Alguns autores não o consideram supervisionado.

Modelos de aprendizado supervisionado

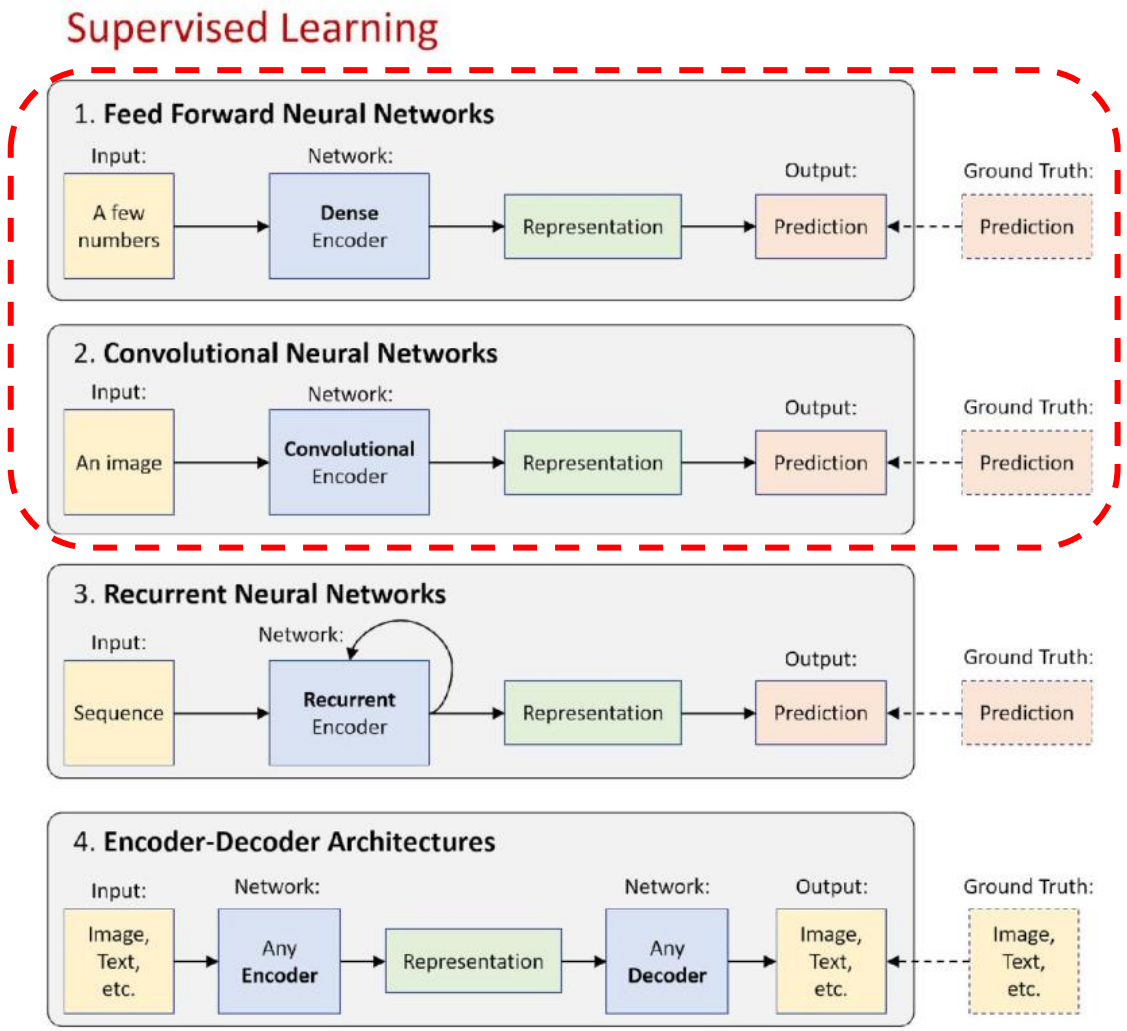

- No nosso curso, iremos focar mais nas DNNs e CNNs.

Regressão

$$\boldsymbol{x} = \{-1, 0, 1, 2, 3, 4\}$$
$$\boldsymbol{y} = \{-3, -1, 1, 3, 5, 7\}$$

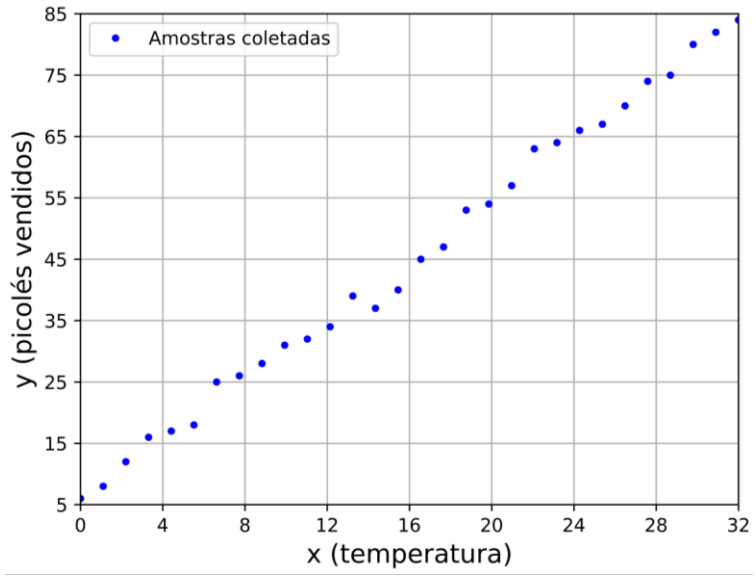

- Anteriormente, nós resolvemos um problema de regressão bem simples, onde queríamos mapear um único valor de x em um valor de saída, y.
- Fizemos o mapeamento usando uma reta como nossa função hipótese.

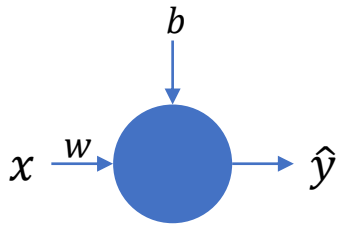

$$\hat{y} = b + wx$$

Regressão

$$\boldsymbol{x} = \{-1, 0, 1, 2, 3, 4\}$$
$$\boldsymbol{y} = \{-3, -1, 1, 3, 5, 7\}$$

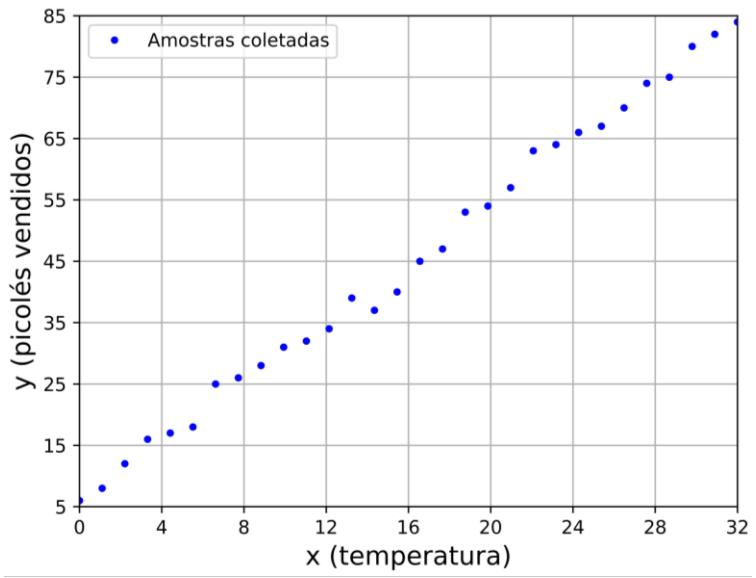

- Podemos fazer uma analogia com o problema de predizer o número de picolés que serão vendidos em um dia, y, dado a temperatura média daquele dia, x.
- Esse problema só tem um ***atributo*** de entrada, a temperatura, x.

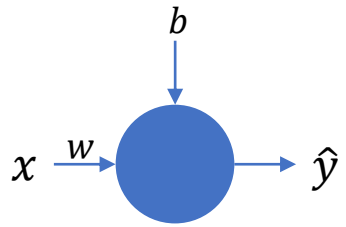

$$\hat{y} = b + wx$$

Regressão

$$\boldsymbol{x}_1 = \{-1, 0, 1, 2, 3, 4\}$$
$$\boldsymbol{x}_2 = \{-8, 1, 3, 7, 0, 2\}$$
$$\boldsymbol{y} = \{-8, 0, 7, 1, 2, 3\}$$

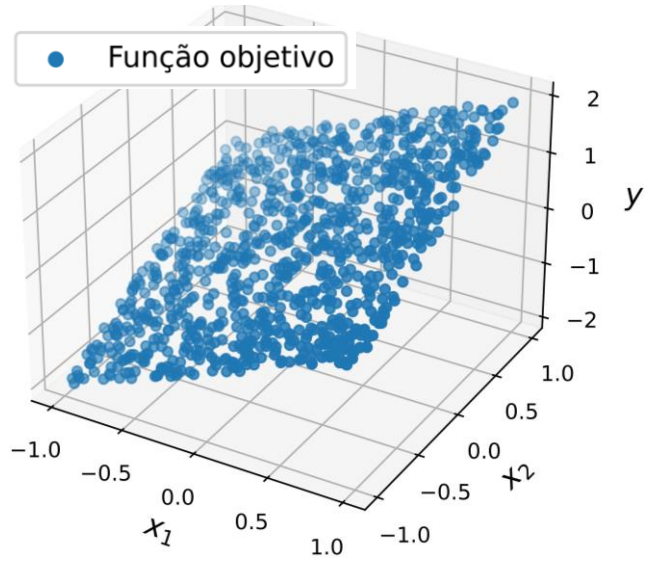

- Mas e se quisermos um modelo que ***leve em consideração não só a temperatura***, mas o ***mês do ano também***?
- O modelo agora terá 2 ***atributos*** (i.e., entradas).
- A figura ao lado mostra a distribuição dos dados para um problema com dois atributos.
- Vejam que eles formam um plano.
- Portanto, existe uma relação linear entre os atributos e a saída.

Regressão

$$\boldsymbol{x}_1 = \{-1, 0, 1, 2, 3, 4\}$$
$$\boldsymbol{x}_2 = \{-8, 1, 3, 7, 0, 2\}$$
$$\boldsymbol{y} = \{-8, 0, 7, 1, 2, 3\}$$

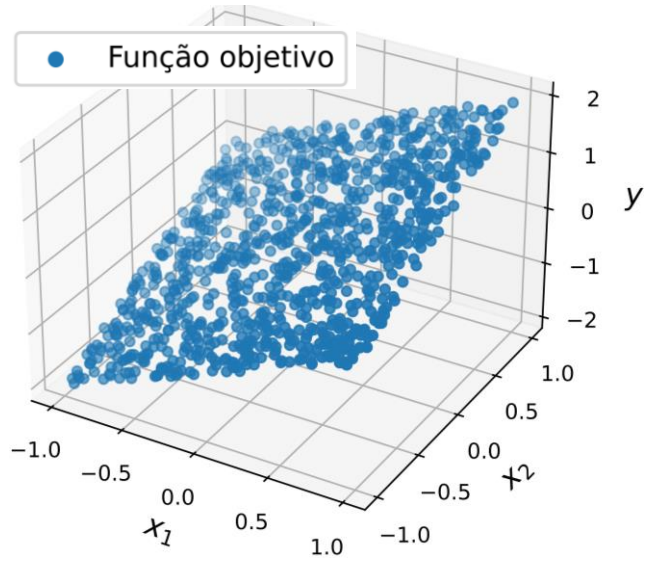

- Para aproximar esses dados, podemos usar a ***equação de um plano*** (abaixo) como nossa ***função hipótese***.

$$\hat{y} = a_0 + a_1 x_1 + a_2 x_2.$$

- Usando ***ativações lineares***, a rede neural abaixo representa a ***função de um plano***.

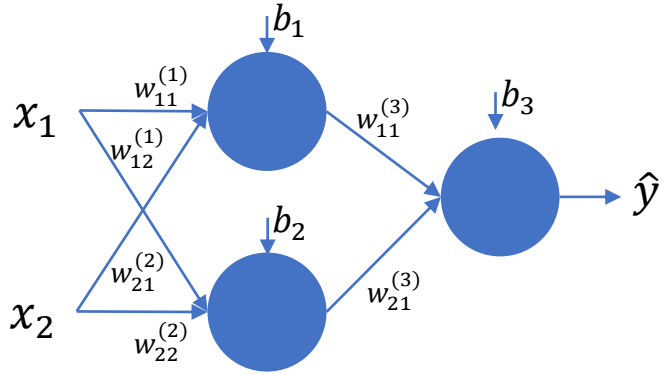

Regressão

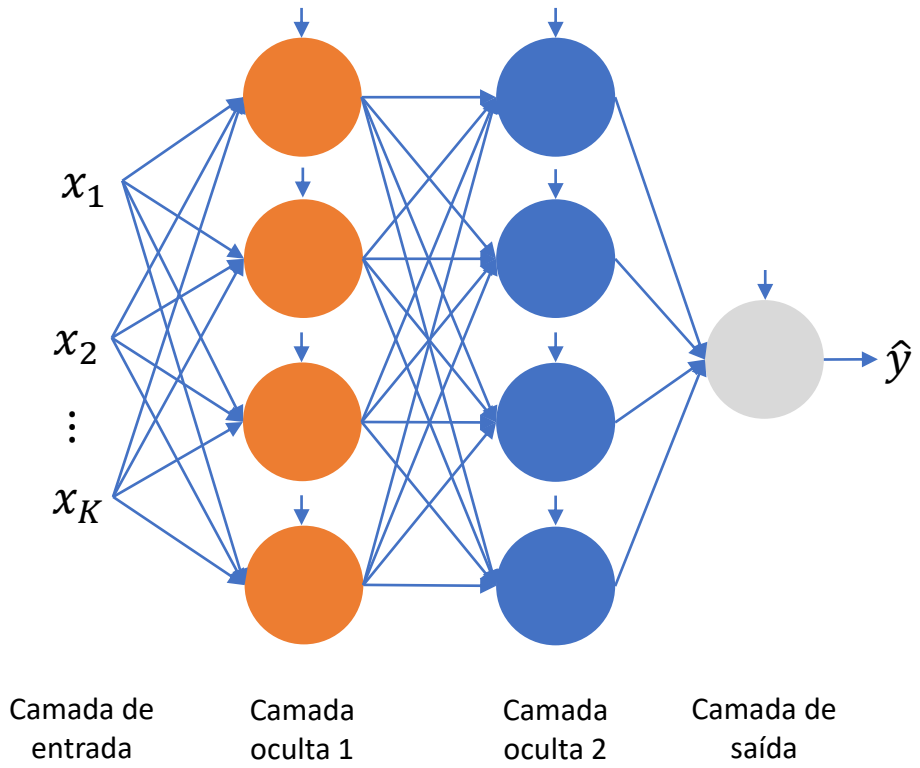

- Podemos extrapolar isso pra quantos ***atributos*** forem necessários.
- O modelo ao lado tem K ***atributos*** (i.e., entradas).
- Com ***ativações lineares***, a rede neural ao lado representa a ***função de um hiperplano***

$$\hat{y} = a_0 + a_1 x_1 + a_2 x_2 + \cdots + a_K x_K$$
$$= \sum_{i=0}^{K} a_i x_i,$$

onde $x_0 = 1$.

Aproximação universal de funções

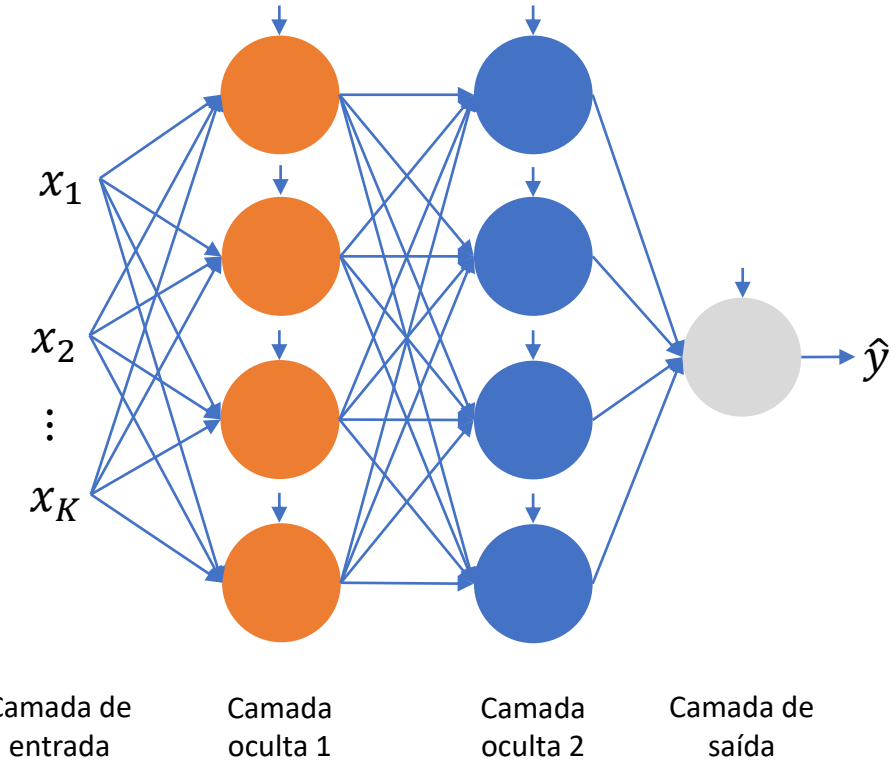

- Com ***ativações não lineares*** (sigmóide, *relu*, etc.) ***e uma camada oculta***, podemos ***aproximar qualquer tipo de função contínua***, incluindo o hiperplano, bastando encontrar o número de neurônios necessários.
- Com ***duas camadas ocultas***, podemos ***aproximar até funções com descontinuidades***.

Mas como encontramos o número ideal de camadas e neurônios?

Otimização hiperparamétrica

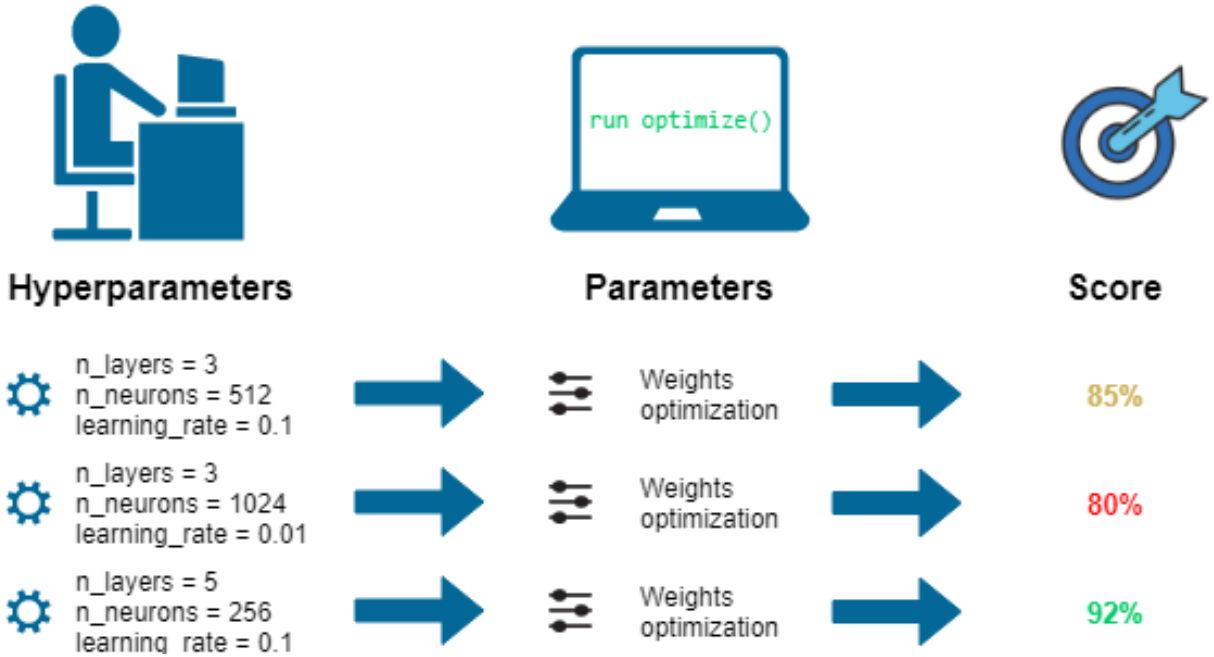

- É o processo de ***encontrar os melhores conjuntos de hiperparâmetros*** para um modelo de ML.
- Hiperparâmetros são ***parâmetros que não são aprendidos durante o treinamento*** do modelo, mas que afetam seu desempenho e comportamento.

Otimização hiperparamétrica

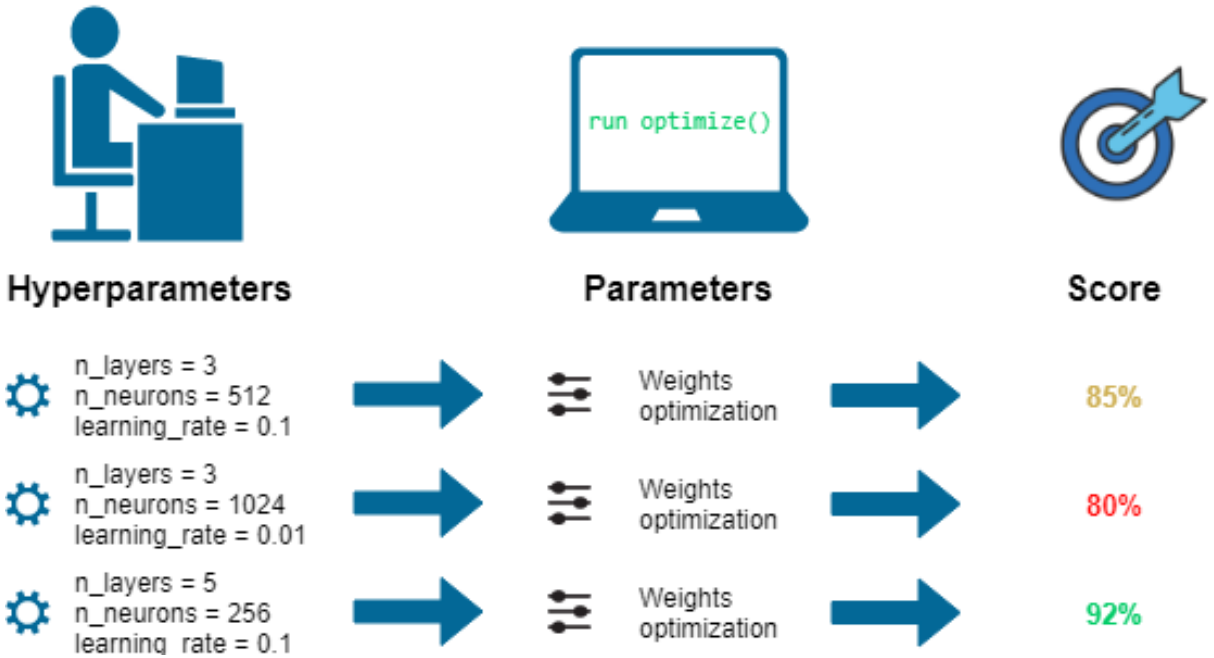

- Exemplos de hiperparâmetros incluem a ***taxa de aprendizagem***, ***número de camadas*** e ***neurônios***, ***tamanho do mini-batch***, **otimizador**, e muitos outros.
- Algumas bibliotecas populares são:
  - KerasTuner,
  - Optuna,
  - Scikit-learn,
  - Hyperopt, etc.

Exemplo

- Regressão de preços de residências usando redes neurais densas (DNNs)

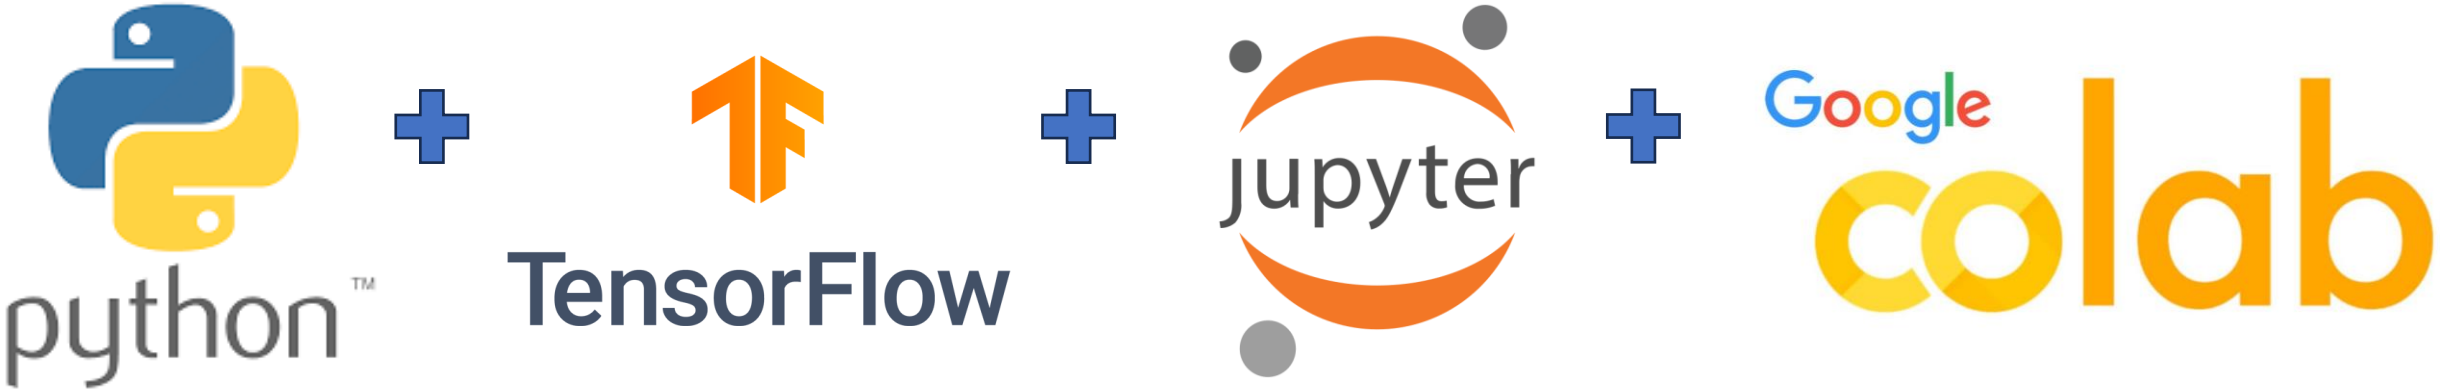

ML Workflow


```
data = tf.keras.datasets.boston_housing

(x_train, y_train), (x_test, y_test) = data.load_data()
```

- O primeiro passo no ***fluxo de trabalho*** com modelos de ML envolve a ***coleta de dados***.
- Podemos coletar dados realmente, por exemplo, gravar sons ou vídeos, tirar fotos, etc. ou reusar um conjunto de dados existente.

ML Workflow

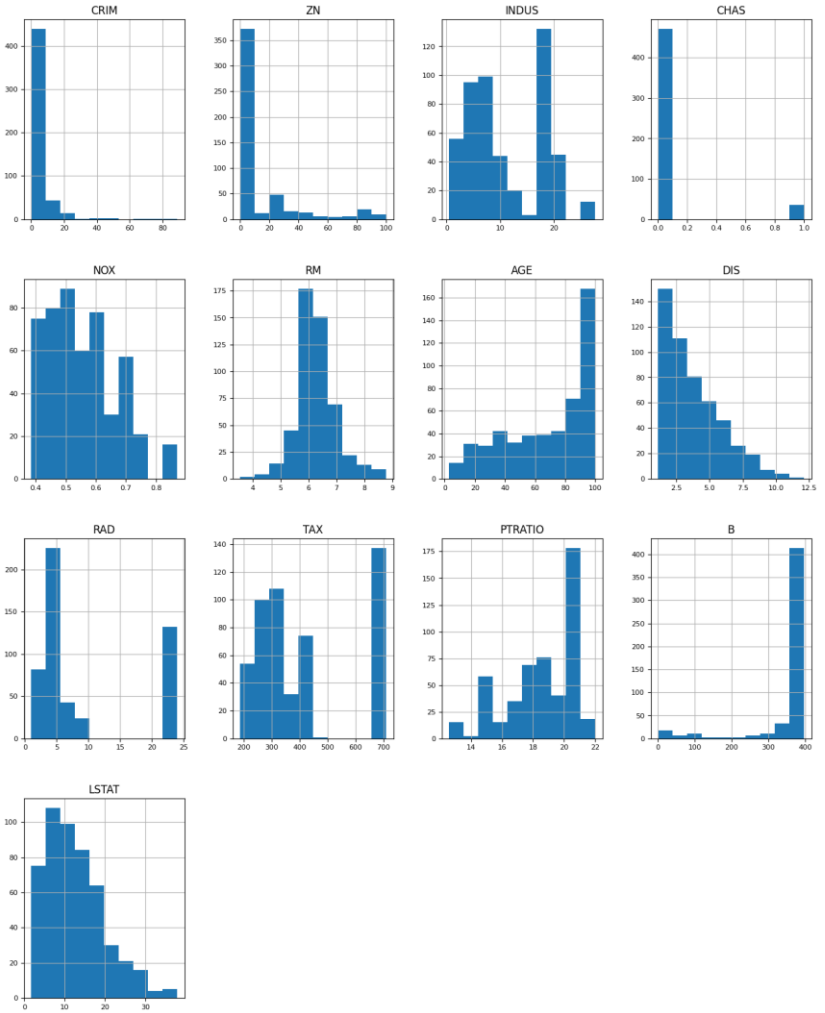

- Na sequência, fazemos uma ***análise exploratória dos dados*** (*exploratory data analysis* – EDA), avaliando intervalos dos atributos e buscando valores faltantes, discrepantes, etc.

ML Workflow


```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()

scaler.fit(x_train)

x_train_std = scaler.transform(x_train)
x_test_std = scaler.transform(x_test)
```

- Em seguida, realizamos o ***pré-processamento*** dos dados.
- Essa tarefa pode envolver a ***remoção de valores discrepantes***, ***preenchimento ou remoção de exemplos*** com dados incompletos, ***escalonamento dos atributos***, etc.

ML Workflow

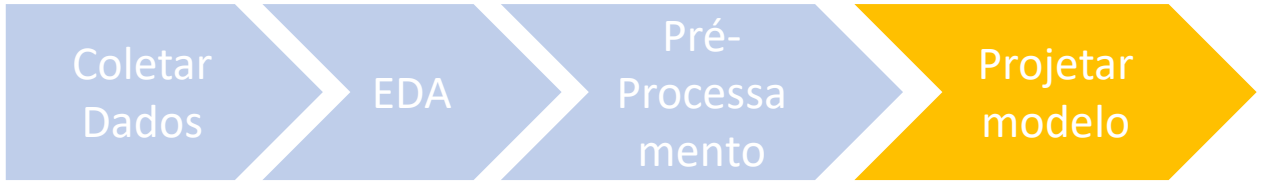


```
model = tf.keras.models.Sequential(
    [
        tf.keras.layers.Dense(20, input_shape=[13], activation='relu'),
        tf.keras.layers.Dense(1)
    ]
)

model.compile(
    optimizer='adam',
    loss='mse',
    metrics=['mae']
)
```

- Após, temos a fase de ***criação do modelo***.
- Envolve a ***definição da arquitetura***: quantidade de camadas, número de nós por camada, funções de ativação, otimizador, passo de aprendizagem, métricas, etc.

ML Workflow


```
history = model.fit(
    x_train_std,
    y_train,
    epochs=1000,
)
```

- O ***treinamento*** do modelo vem na sequência.
- A entrada desta etapa são os dados já pré-processados.

ML Workflow

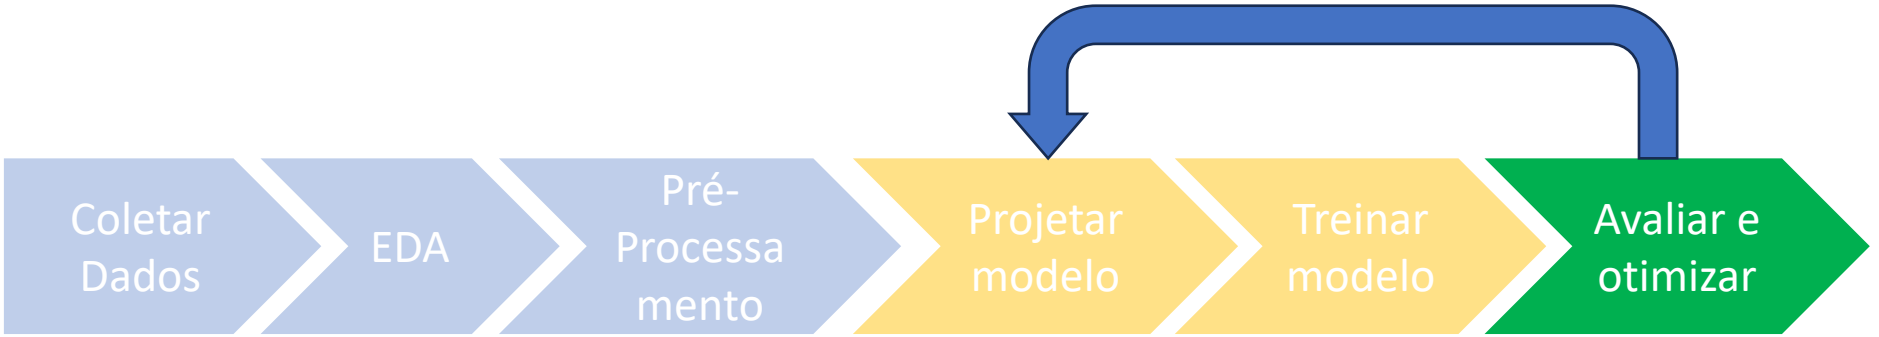

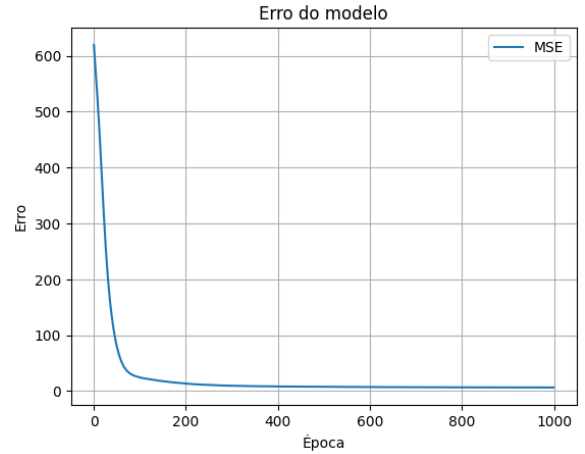


```
test_eval = model.evaluate(x_test_std, y_test)
train_eval = model.evaluate(x_train_std, y_train)

tuner.search(
   x_train_std, y_train,
   epochs=500,
   validation_data=(x_test_std, y_test)
)
```

- ***Avaliar o modelo*** envolver analisar os resultados obtidos após o treinamento.
- Analisar indícios de que o modelo está aprendendo:
  - Curva de erro com caída rápida no início e redução ao longo do treinamento, se tornando praticamente constante (indicação de convergência).
  - Comparar os erros de treinamento e validação, os quais devem ser pequenos e próximos (caso contrário, indicação de sobreajuste).
- Se o modelo não estiver bom, devemos ***otimizá-lo, manualmente ou através de técnicas de otimização hiperparamétrica***.

ML Workflow


```
xt = np.array([1.1, 0., 9., 0., 0.6, 7., 92., 3.8 , 4., 300., 21., 200, 19.5])
xt = np.reshape(xt, (1, 13))
xt_norm = scaler.transform(xt)
yt = model.predict(xt_norm)
```

- Após obtermos um bom modelo, o colocamos em "***produção***" para lidar com dados do mundo real (inéditos) e oferecer *insights* ou auxiliar em tomadas de decisão.

ML Workflow

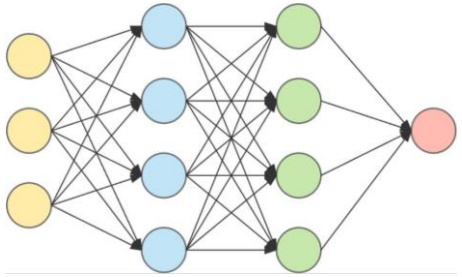

- Esse é o fluxo de trabalho que geralmente seguimos para trabalhar com modelos de aprendizado de máquina.
- O ***fluxo com o tinyML terá uma fase adicional intermediária*** entre avaliar/otimizar e a inferência, que será a ***etapa de conversão*** (i.e., compressão) do modelo para o executarmos em dispositivos embarcados.

Atividades

- Quiz: “***TP557 – Regressão com DNNs (Parte II)***”.
- Exercício #1: Regressão sem escalonamento
- Exercício #2: Otimização hiperparamétrica

Perguntas?

Obrigado!

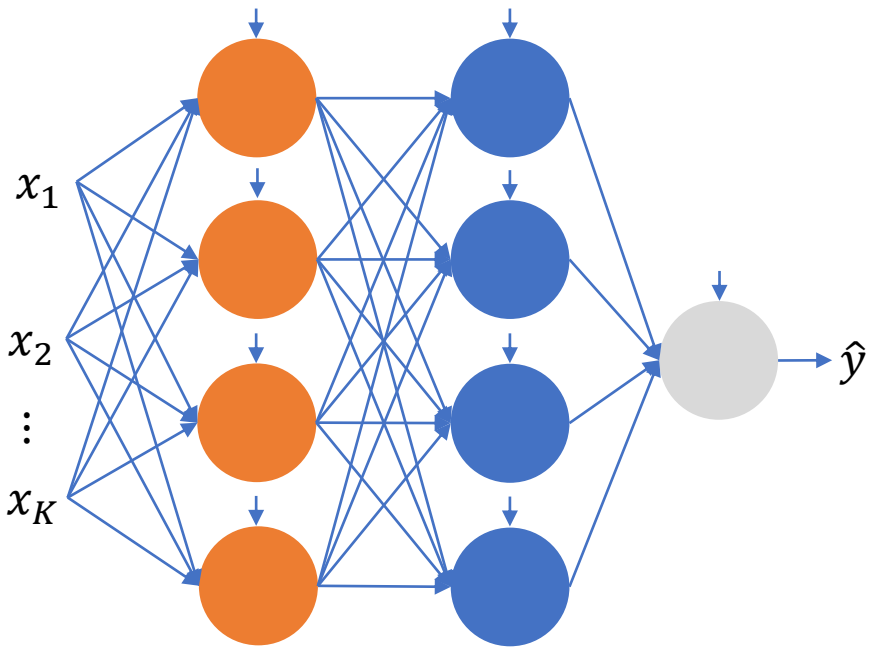

Camada de entrada | Camada oculta 1 | Camada oculta 2 | Camada de saída

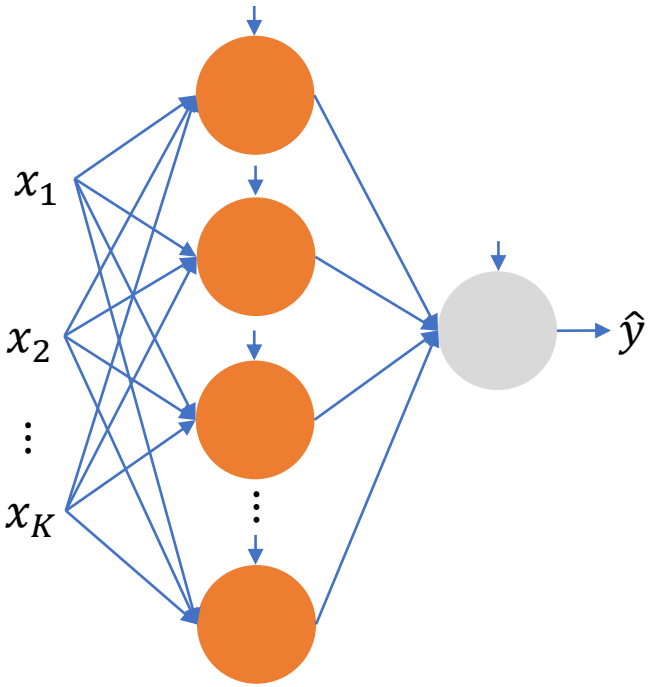

Camada de entrada | Camada oculta | Camada de saída

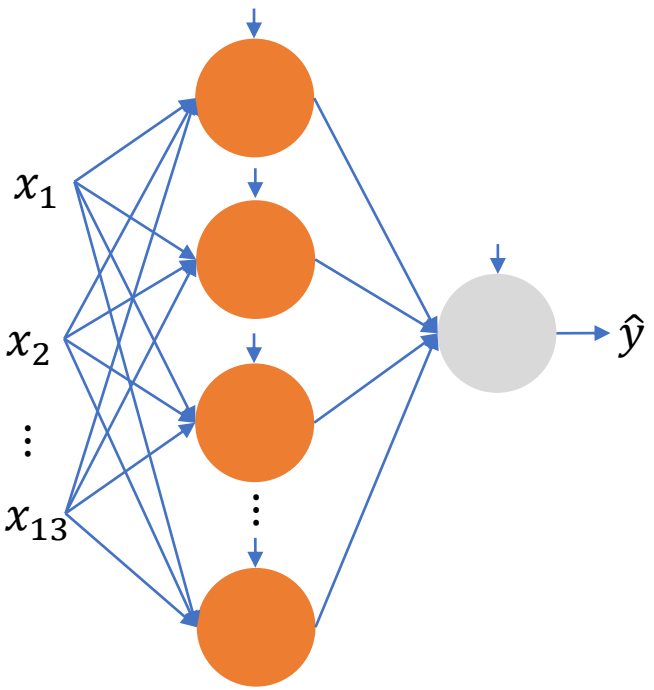

Camada de entrada | Camada oculta | Camada de saída