TP557 - Tópicos avançados em IoT e Machine Learning:

Regressão com DNNs (Parte II)

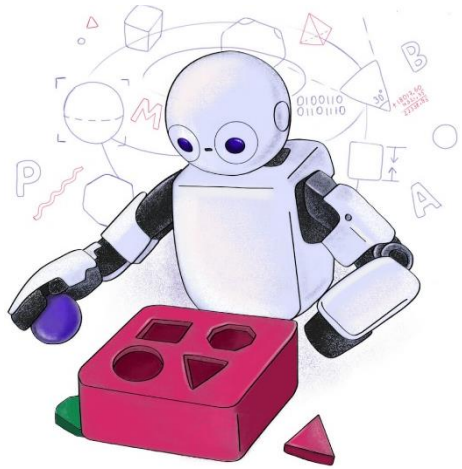

Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

O que vamos ver?

- Anteriormente, vimos através de um ***exemplo simples*** como usar a ***biblioteca TensorFlow*** para ***criar uma rede neural e resolver um problema de regressão***, ou seja, um problema de ajuste de curva.
- O objetivo era ter um ***contato inicial com a biblioteca*** e seus ***princípios básicos*** de funcionamento.
- Nesse tópico, vamos estender o que vimos anteriormente para um ***problema mais prático de regressão*** usando uma ***base de dados do mundo real***.

Regressão

$$\boldsymbol{x} = \{-1, 0, 1, 2, 3, 4\}$$
$$\boldsymbol{y} = \{-3, -1, 1, 3, 5, 7\}$$

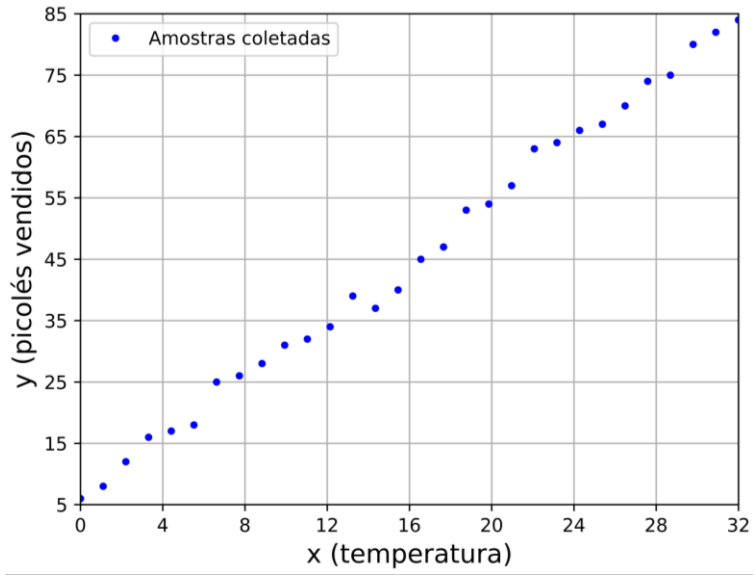

- Anteriormente, nós resolvemos um problema de regressão bem simples, onde queríamos mapear um único valor de x em um valor de saída, y.
- Fizemos o mapeamento usando uma reta como nossa função hipótese.

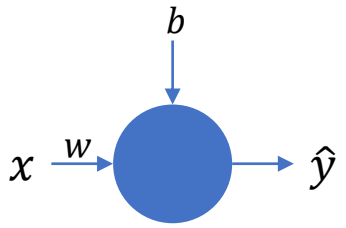

$$\hat{y} = b + wx$$

Regressão

$$\boldsymbol{x} = \{-1, 0, 1, 2, 3, 4\}$$
$$\boldsymbol{y} = \{-3, -1, 1, 3, 5, 7\}$$

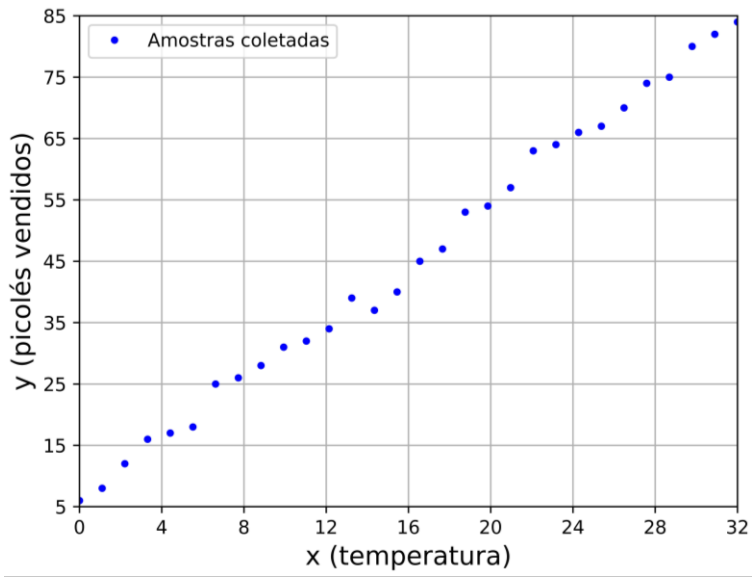

- Podemos fazer uma analogia com o problema de predizer o número de picolés que serão vendidos em um dia, y, dado a temperatura média daquele dia, x.
- Esse problema só tem um ***atributo*** de entrada, a temperatura, x.

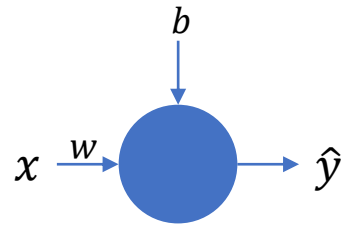

$$\hat{y} = b + wx$$

Regressão

$$\boldsymbol{x}_1 = \{-1, 0, 1, 2, 3, 4\}$$
$$\boldsymbol{x}_2 = \{-8, 1, 3, 7, 0, 2\}$$
$$\boldsymbol{y} = \{-8, 0, 7, 1, 2, 3\}$$

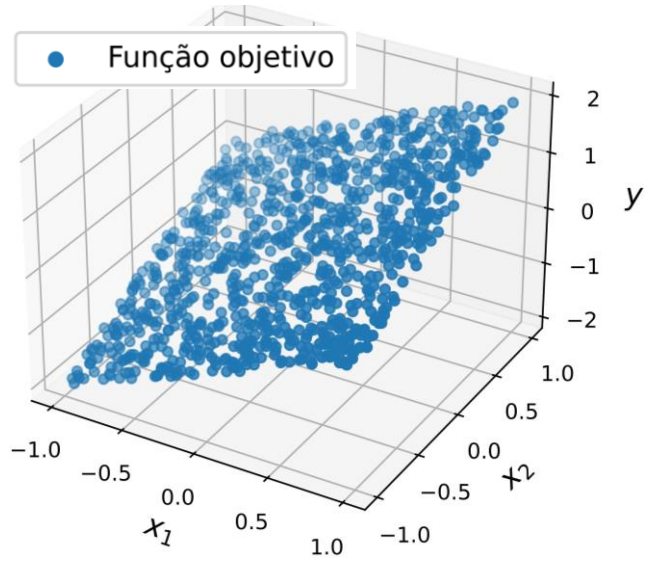

- Mas e se quisermos um modelo que ***leve em consideração não só a temperatura***, mas o ***mês do ano também***?
- O modelo agora terá 2 ***atributos*** (i.e., entradas).
- A figura ao lado mostra a distribuição dos dados para um problema com dois atributos.
- Vejam que eles formam um plano.
- Portanto, existe uma relação linear entre os atributos e a saída.

Regressão

$$\boldsymbol{x}_1 = \{-1, 0, 1, 2, 3, 4\}$$
$$\boldsymbol{x}_2 = \{-8, 1, 3, 7, 0, 2\}$$
$$\boldsymbol{y} = \{-8, 0, 7, 1, 2, 3\}$$

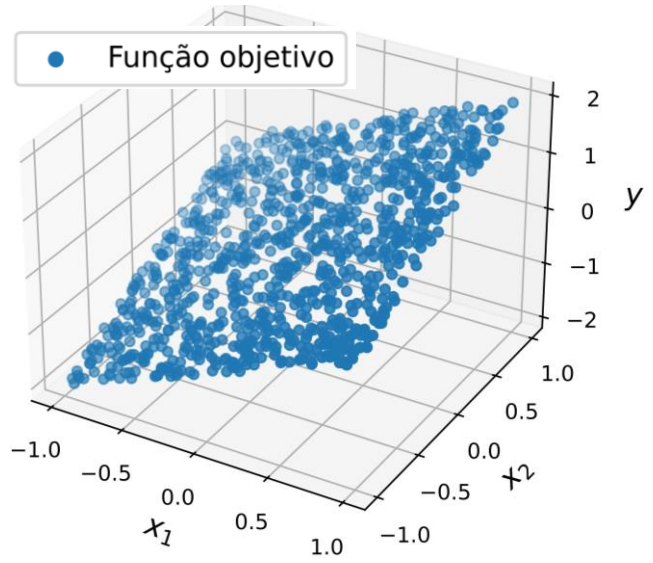

- Para aproximar esses dados, podemos usar a ***equação de um plano*** (abaixo) como nossa ***função hipótese***.

$$\hat{y} = a_0 + a_1 x_1 + a_2 x_2.$$

- Usando ***ativações lineares***, a rede neural abaixo representa a ***função de um plano***.

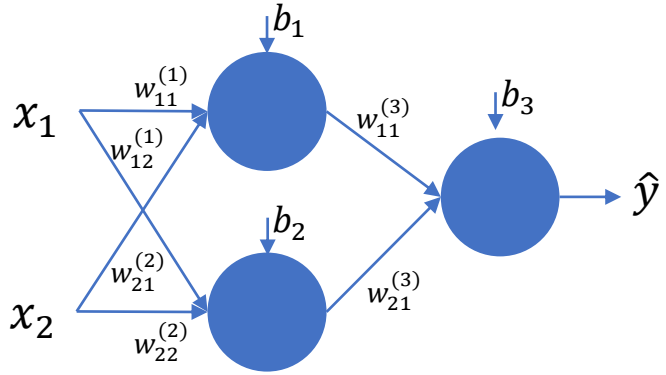

Regressão

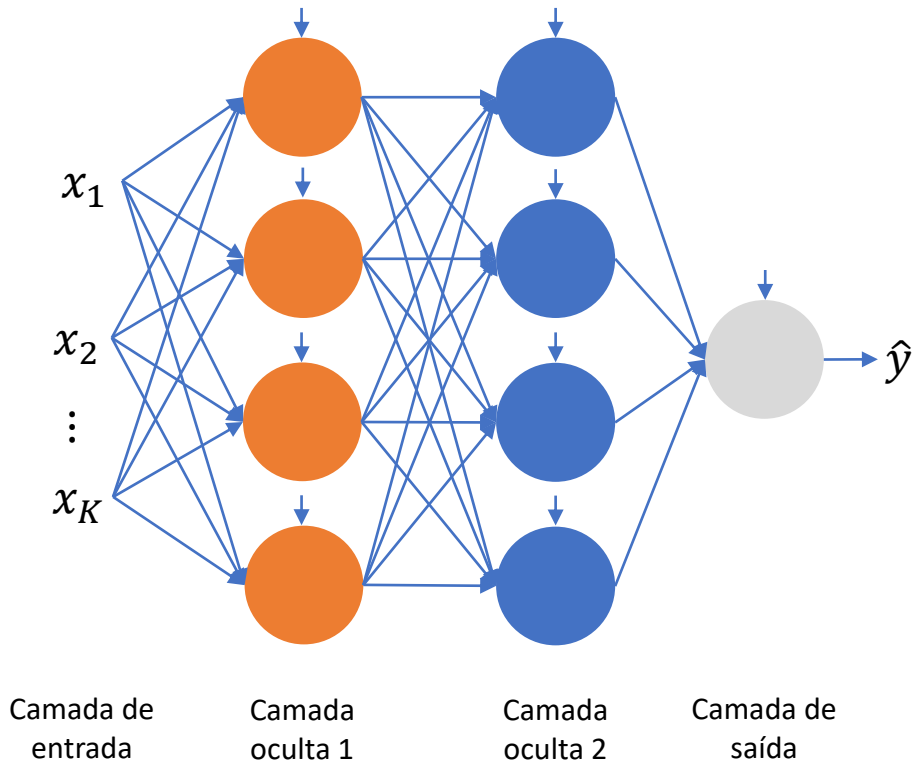

- Podemos extrapolar isso pra quantos ***atributos*** forem necessários.
- O modelo ao lado tem K ***atributos*** (i.e., entradas).
- Com ***ativações lineares***, a rede neural ao lado representa a ***função de um hiperplano***

$$\hat{y} = a_0 + a_1 x_1 + a_2 x_2 + \cdots + a_K x_K$$
$$= \sum_{i=0}^{K} a_i x_i,$$

onde $x_0 = 1$.

Aproximação universal de funções

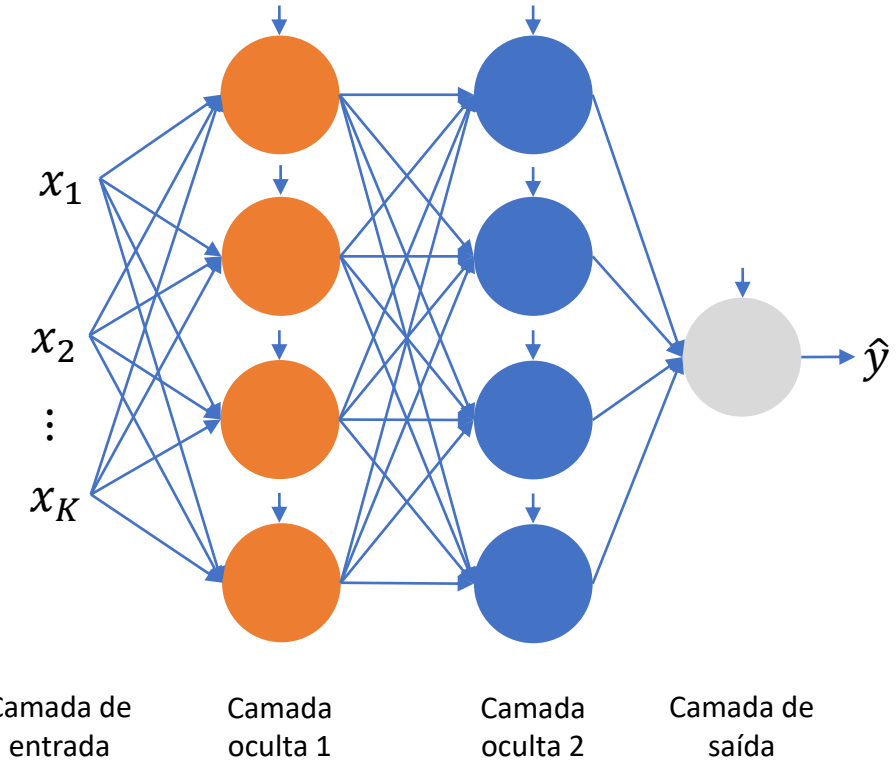

- Com ***ativações não lineares*** (sigmóide, *relu*, etc.) ***e uma camada oculta***, podemos ***aproximar qualquer tipo de função contínua***, incluindo o hiperplano, bastando encontrar o número de neurônios necessários.
- Com ***duas camadas ocultas***, podemos ***aproximar até funções com descontinuidades***.

Mas como encontramos o número ideal de camadas e neurônios?

Otimização hiperparamétrica

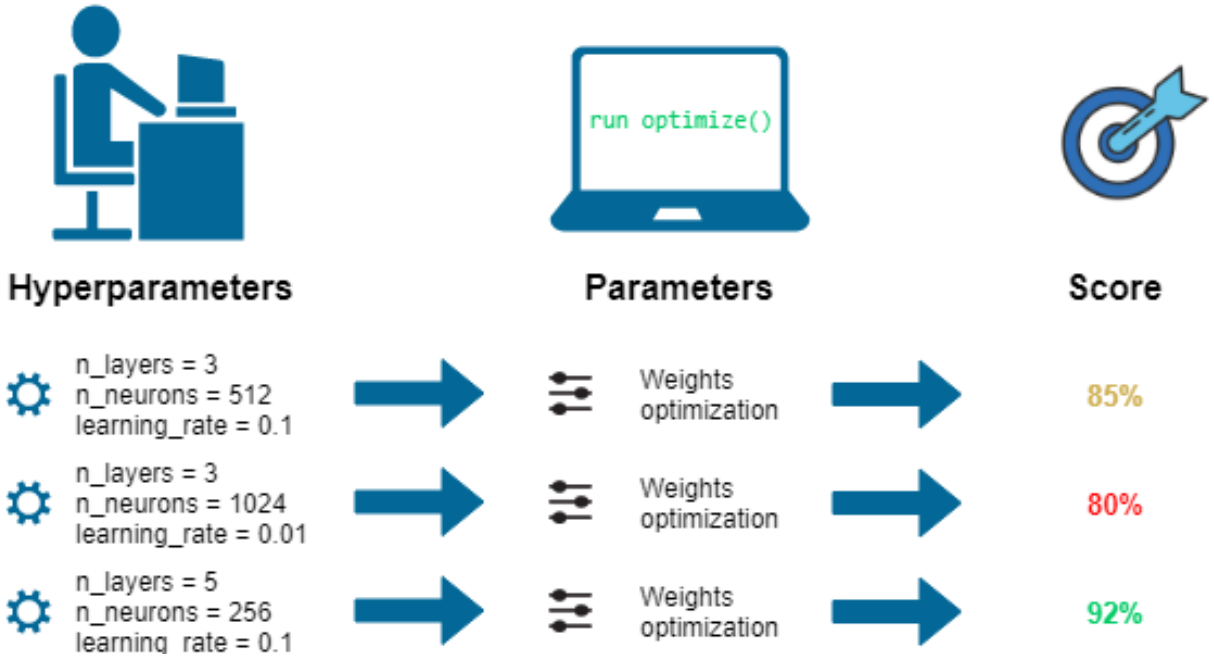

- É o processo de ***encontrar os melhores conjuntos de hiperparâmetros*** para um modelo de ML.
- Hiperparâmetros são ***parâmetros que não são aprendidos durante o treinamento*** do modelo, mas que afetam seu desempenho e comportamento.

Otimização hiperparamétrica

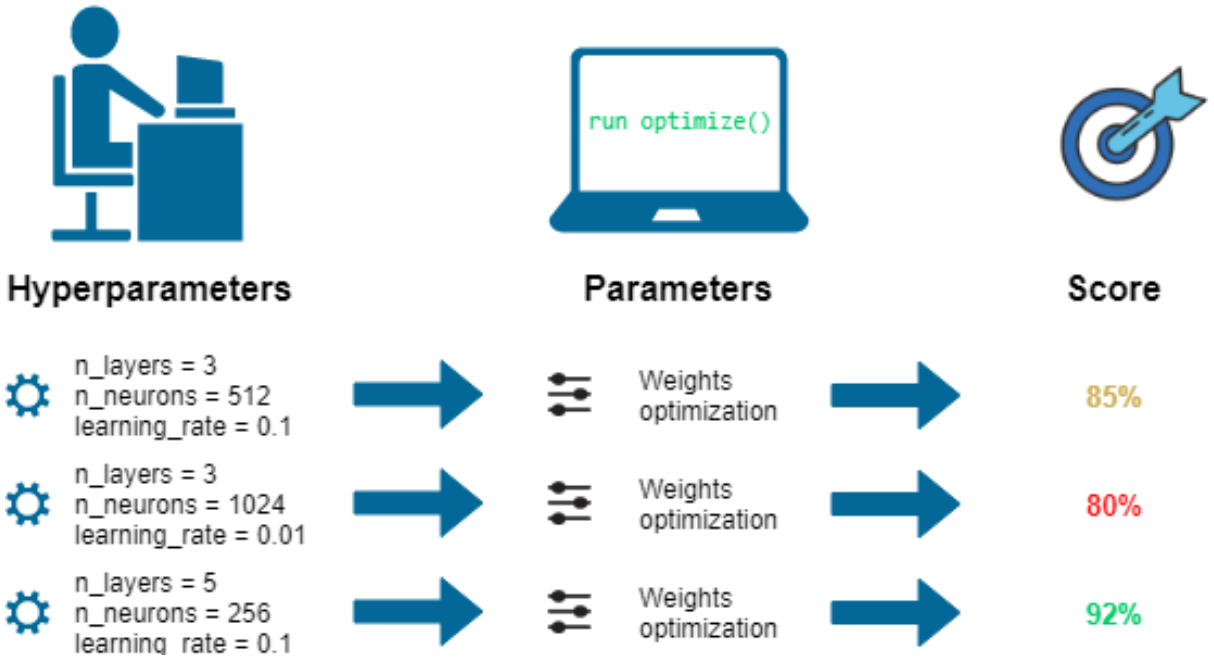

- Exemplos de hiperparâmetros incluem a ***taxa de aprendizagem***, ***número de camadas*** e ***neurônios***, ***tamanho do mini-batch***, **otimizador**, e muitos outros.
- Algumas bibliotecas populares são:
  - KerasTuner,
  - Optuna,
  - Scikit-learn,
  - Hyperopt, etc.

Exemplo

- Regressão de preços de residências usando redes neurais densas (DNNs)

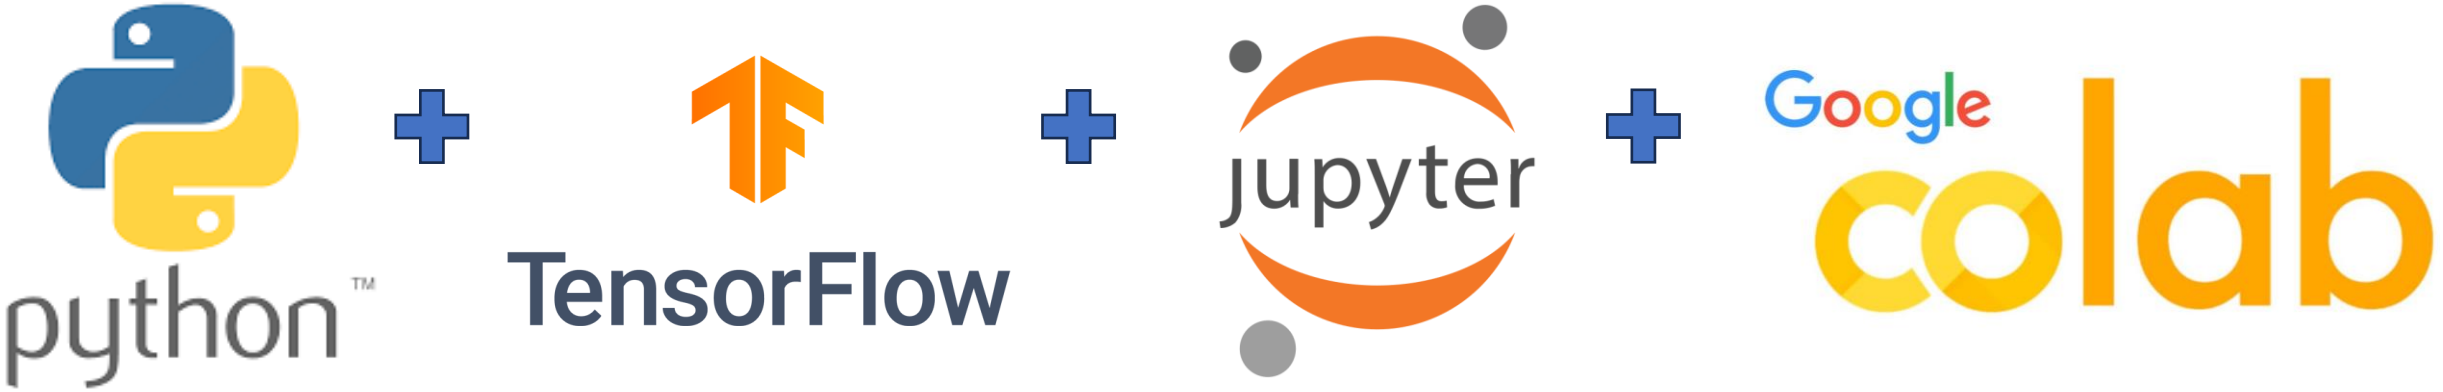

ML Workflow


```
data = tf.keras.datasets.boston_housing

(x_train, y_train), (x_test, y_test) = data.load_data()
```

- O primeiro passo no ***fluxo de trabalho*** com modelos de ML envolve a ***coleta de dados***.
- Podemos coletar dados realmente, por exemplo, gravar sons ou vídeos, tirar fotos, etc. ou reusar um conjunto de dados existente.

ML Workflow

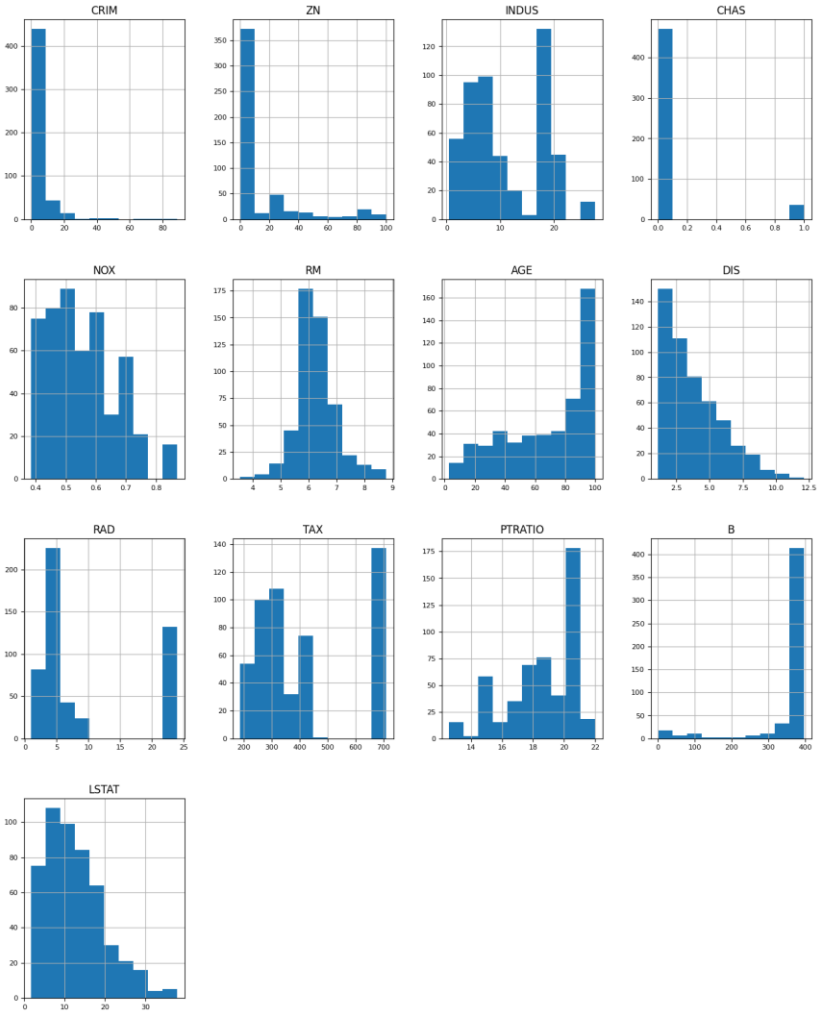

- Na sequência, fazemos uma ***análise exploratória dos dados*** (*exploratory data analysis* – EDA), avaliando intervalos dos atributos e buscando valores faltantes, discrepantes, etc.

ML Workflow


```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()

scaler.fit(x_train)

x_train_std = scaler.transform(x_train)
x_test_std = scaler.transform(x_test)
```

- Em seguida, realizamos o ***pré-processamento*** dos dados.
- Essa tarefa pode envolver a ***remoção de valores discrepantes***, ***preenchimento ou remoção de exemplos*** com dados incompletos, ***escalonamento dos atributos***, etc.

ML Workflow

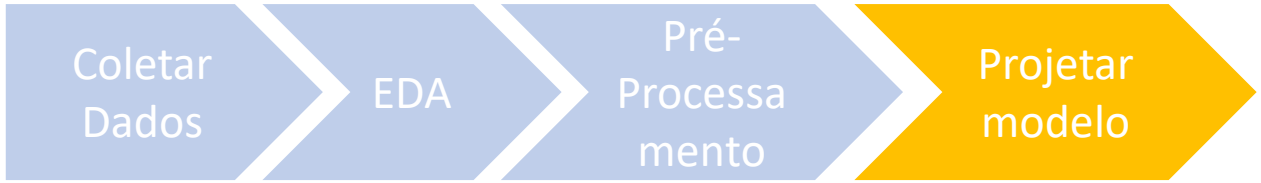


```
model = tf.keras.models.Sequential(
    [
        tf.keras.layers.Dense(20, input_shape=[13], activation='relu'),
        tf.keras.layers.Dense(1)
    ]
)

model.compile(
    optimizer='adam',
    loss='mse',
    metrics=['mae']
)
```

- Após, temos a fase de ***criação do modelo***.
- Envolve a ***definição da arquitetura***: quantidade de camadas, número de nós por camada, funções de ativação, otimizador, passo de aprendizagem, métricas, etc.

ML Workflow


```
history = model.fit(
    x_train_std,
    y_train,
    epochs=1000,
)
```

- O ***treinamento*** do modelo vem na sequência.
- A entrada desta etapa são os dados já pré-processados.

ML Workflow

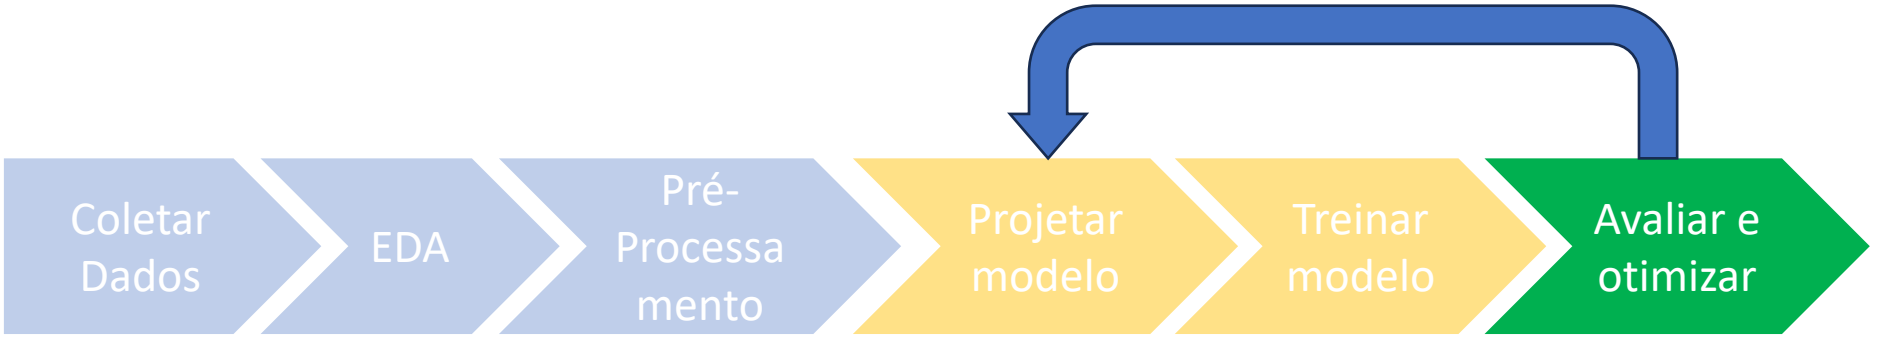

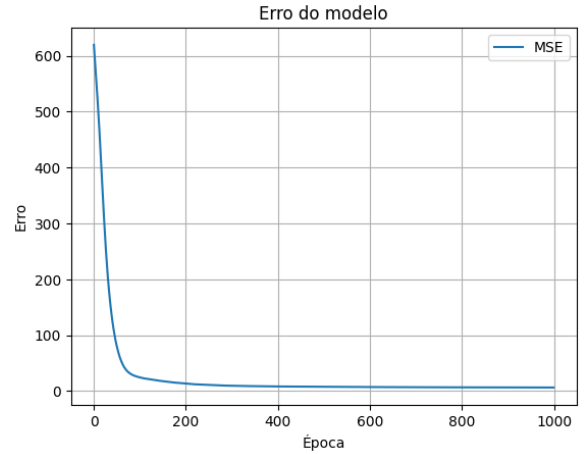


```
test_eval = model.evaluate(x_test_std, y_test)
train_eval = model.evaluate(x_train_std, y_train)

tuner.search(
   x_train_std, y_train,
   epochs=500,
   validation_data=(x_test_std, y_test)
)
```

- ***Avaliar o modelo*** envolver analisar os resultados obtidos após o treinamento.
- Analisar indícios de que o modelo está aprendendo:
  - Curva de erro com caída rápida no início e redução ao longo do treinamento, se tornando praticamente constante (indicação de convergência).
  - Comparar os erros de treinamento e validação, os quais devem ser pequenos e próximos (caso contrário, indicação de sobreajuste).
- Se o modelo não estiver bom, devemos ***otimizá-lo, manualmente ou através de técnicas de otimização hiperparamétrica***.

ML Workflow


```
xt = np.array([1.1, 0., 9., 0., 0.6, 7., 92., 3.8 , 4., 300., 21., 200, 19.5])
xt = np.reshape(xt, (1, 13))
xt_norm = scaler.transform(xt)
yt = model.predict(xt_norm)
```

- Após obtermos um bom modelo, o colocamos em "***produção***" para lidar com dados do mundo real (inéditos) e oferecer *insights* ou auxiliar em tomadas de decisão.

ML Workflow

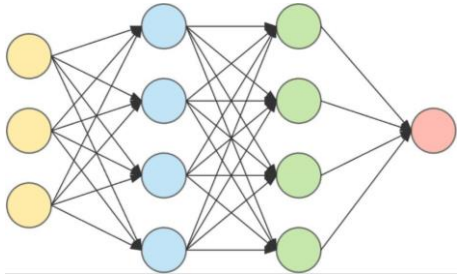

- Esse é o fluxo de trabalho que geralmente seguimos para trabalhar com modelos de aprendizado de máquina.
- O ***fluxo com o tinyML terá uma fase adicional intermediária*** entre avaliar/otimizar e a inferência, que será a ***etapa de conversão*** (i.e., compressão) do modelo para o executarmos em dispositivos embarcados.

Atividades

- Quiz: “***TP557 – Regressão com DNNs (Parte II)***”.
- Exercício #1: Regressão sem escalonamento
- Exercício #2: Otimização hiperparamétrica

Perguntas?

Obrigado!

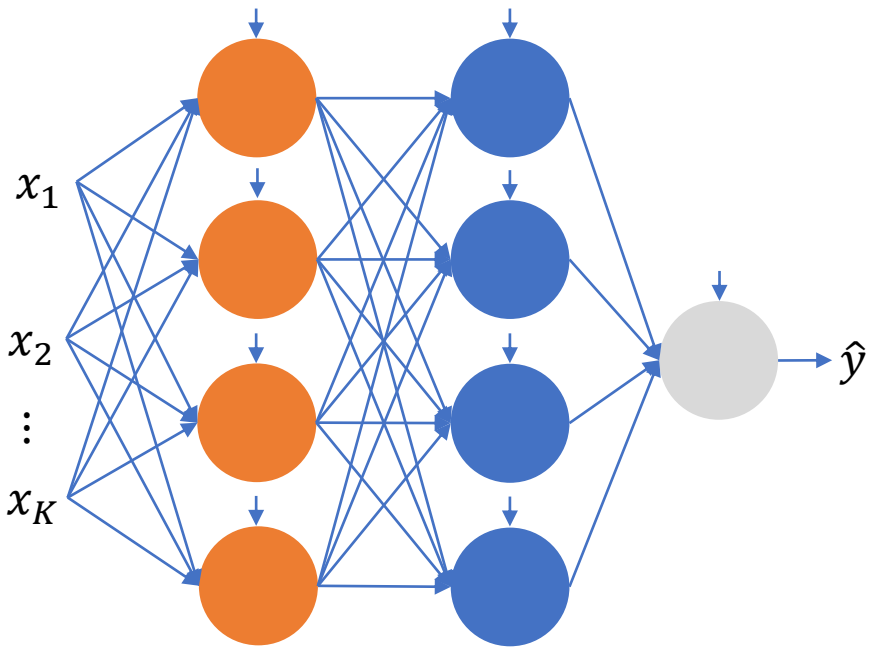

Camada de entrada | Camada oculta 1 | Camada oculta 2 | Camada de saída

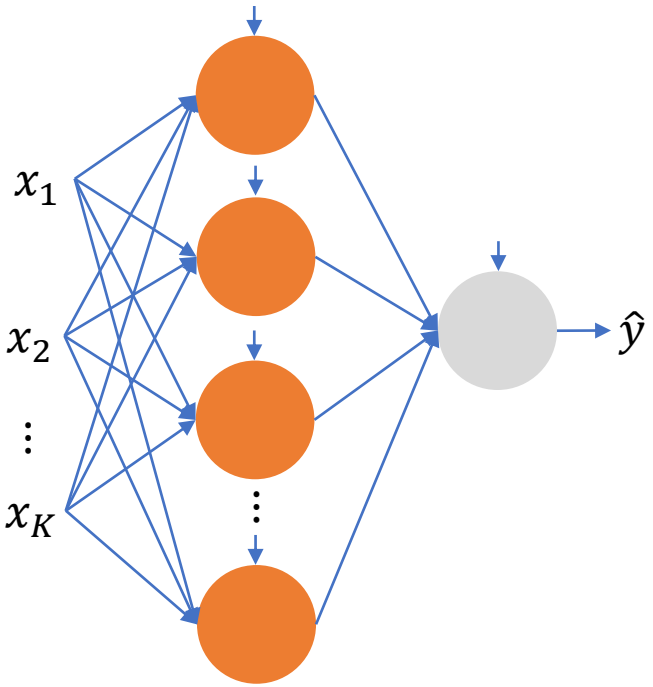

Camada de entrada | Camada oculta | Camada de saída

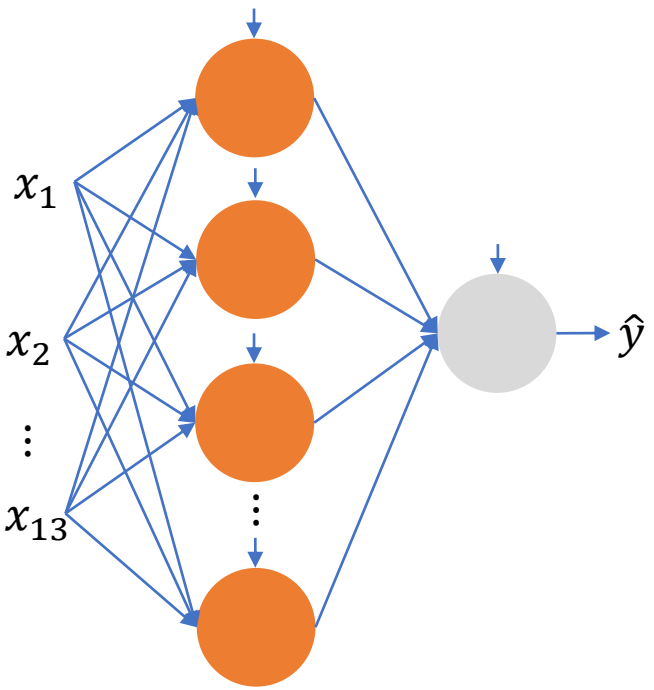

Camada de entrada | Camada oculta | Camada de saída