TP557 - Tópicos avançados em IoT e Machine Learning:

Classificação com DNNs

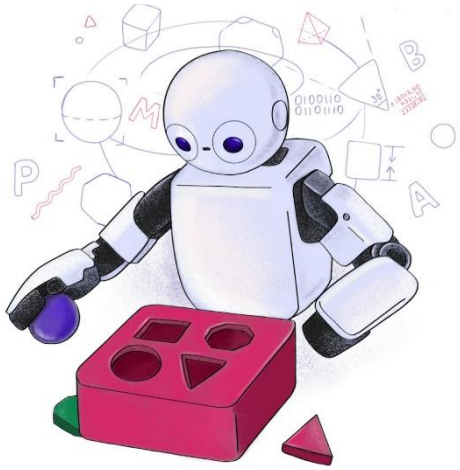

Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

O que vamos ver?

- Anteriormente, vimos como os computadores aprendem através do ajuste dos parâmetros (i.e., dos pesos) de um modelo de ML a relação entre as entradas, $\boldsymbol{x}$, e a saída esperada, y.
- Ou seja eles ***encontram um mapeamento (uma função) entre*** $\boldsymbol{x}$ e y.
- Quando os valores de $\boldsymbol{x}$ ***são mapeados em valores contínuos***, $y \in \mathbb{R}$, chamados o ***problema de regressão***.
- Neste tópico, veremos um outro problema de mapeamento, mas desta vez, os valores de $\boldsymbol{x}$ ***serão mapeados em valores de um conjunto finito e discreto de valores***, $y = \{0, 1, \dots, Q-1\}, y \subset \mathbb{N}$, onde Q define o número de valores de saída.
- Esse problema é chamado de ***classificação***.

Classificação

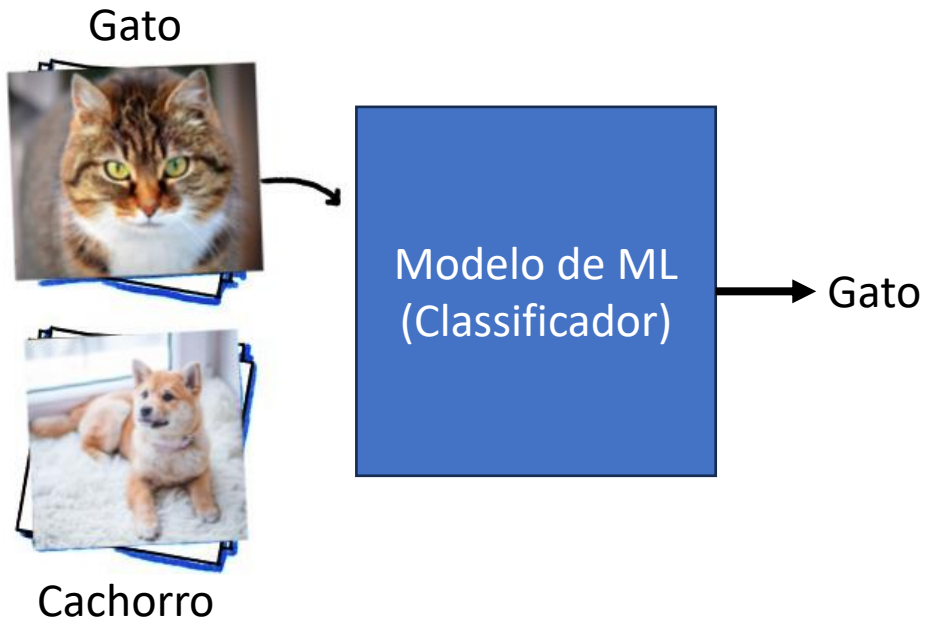

- A ideia da classificação, como o próprio nome já diz, é atribuir classes aos dados de entrada.
- Por exemplo, informar o animal presente em uma imagem (i.e., conjunto de *pixels*).
- Existem vários algoritmos de ML para solucionar este problema:
  - Regressão Logística e *Softmax*;
  - Árvores de Decisão;
  - Máquinas de vetores de suporte;
  - etc.
- Porém, neste curso, focaremos no uso de ***redes neurais artificiais*** para classificação.

Classificação com redes neurais

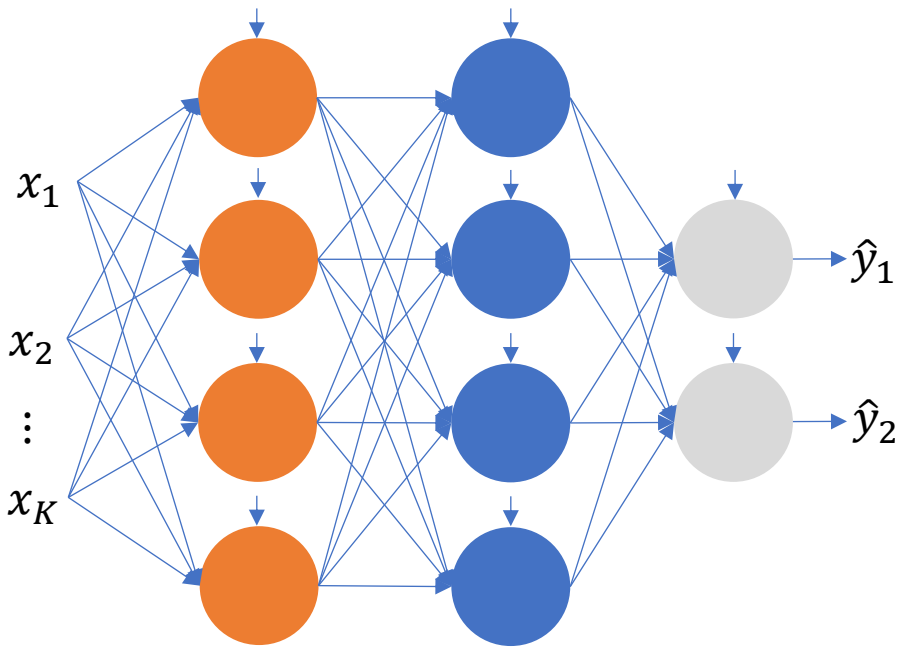

- Na sequência, veremos como ***redes neurais podem também resolver problemas de classificação***, bastando fazer algumas alterações na arquitetura da rede.
- Basicamente, precisamos alterar a ***função de ativação da camada de saída*** e a ***função de erro*** (ou *loss*).

Classificação com neurônios

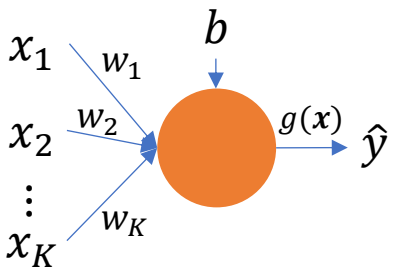

$$\hat{y} = g(\boldsymbol{x}) = \left(\sum_{k=1}^{K} w_k x_k \right) + b$$

- Até agora, usamos um neurônio (***sem função de ativação***, $f(.)$) para mapear valores de $\boldsymbol{x}$ em y, ou seja, encontrar uma ***relação linear*** entre eles.
  - Lembrando que, em geral, $\boldsymbol{x}$ é um vetor contendo vários atributos.
- Entretanto, os neurônios podem ser usados para ***classificação binária*** se usarmos uma função de ativação, $f(.)$, do tipo sigmoide (ou logística), por exemplo.

Classificação com neurônios

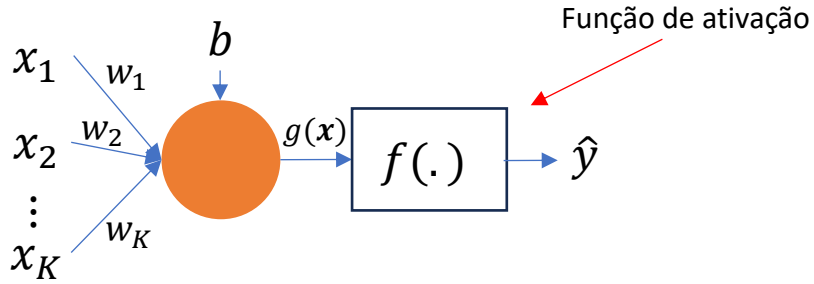

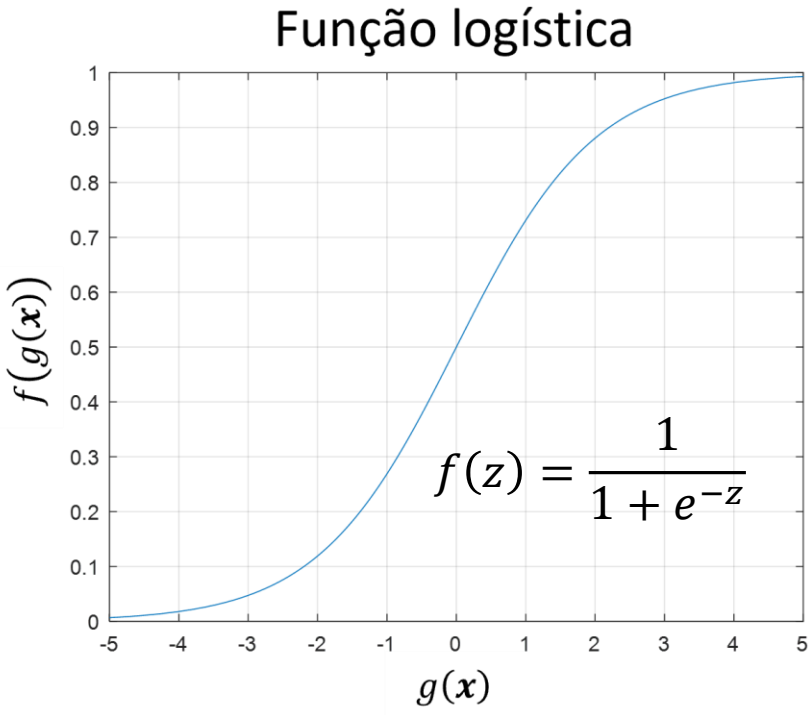

- Ao usarmos uma função de ativação, o modelo matemático do neurônio passa a ser expresso por

$$\hat{y} = f\big(g(\boldsymbol{x})\big) = f\left(\left(\sum_{k=1}^{K} w_k x_k\right) + b\right).$$

- A função de ativação logística, $f(.)$, é uma ***suavização da função degrau*** e, portanto, ***derivável***, que mapeia os valores de $g(\boldsymbol{x})$ (intervalo infinito) em valores no intervalo $[0, 1]$.
- Notem que $g(\boldsymbol{x})$ continua sendo a equação de um hiperplano.

Classificação com neurônios

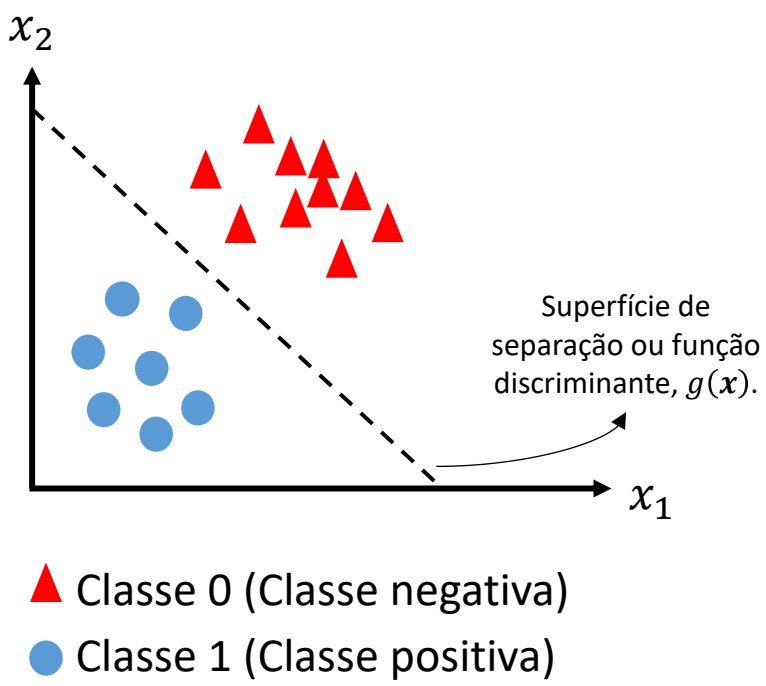

- Quando o neurônio opera como um ***classificador binário***, a combinação linear definida por $g(\boldsymbol{x})$, define uma ***superfície de separação linear*** entre ***dois grupos*** distintos de dados (i.e., classes), ***ao invés de uma função que aproxima o comportamento dos dados***.

Classificação com neurônios

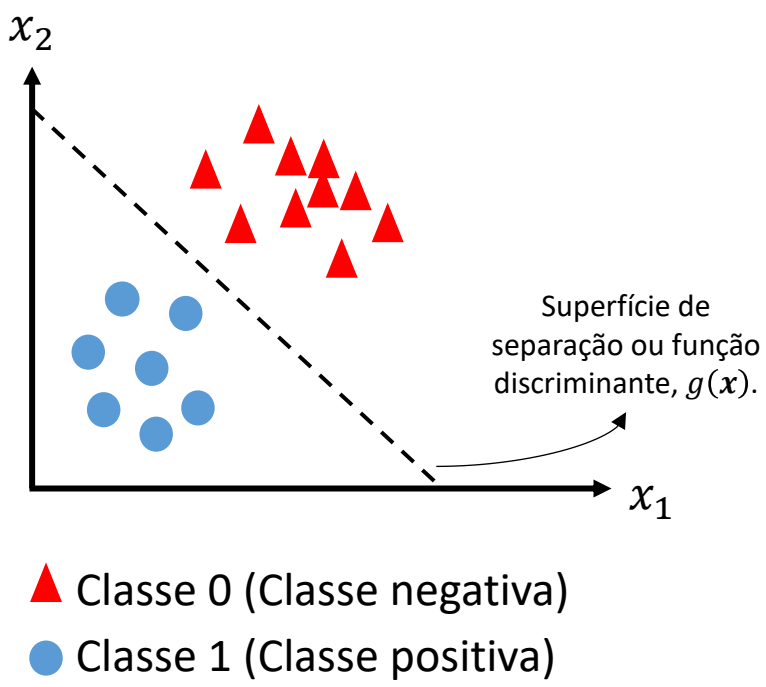

- O neurônio separa as classes usando ***hiperplanos*** (retas, planos, etc.).
- Nesse contexto, a função $g(\boldsymbol{x})$ é chamada também de ***função discriminante***, pois seus valores de saída são usados para separar as classes.

Função discriminante, $g(\boldsymbol{x})$

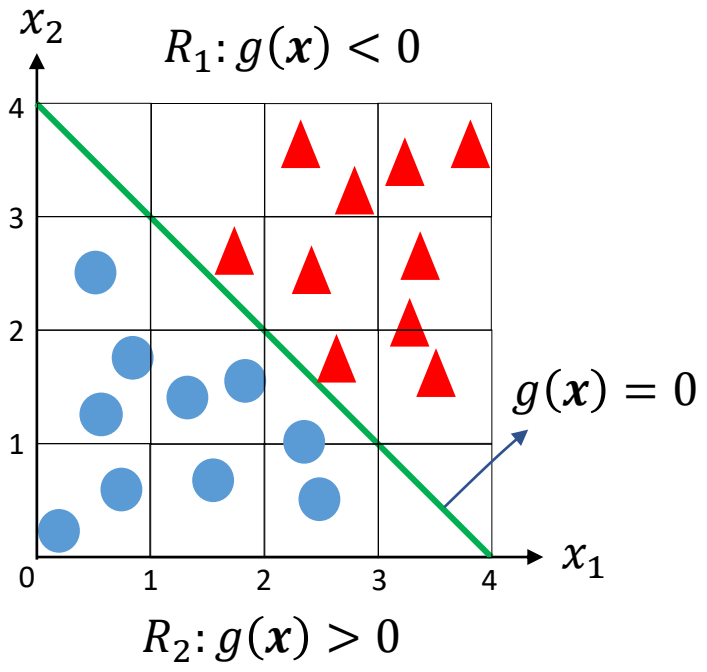

- Vamos supor a seguinte função discriminante: $g(\boldsymbol{x}) = 4 - x_1 - x_2$, a qual é mostrada na figura ao lado.
- Agora vamos encontrar as ***regiões de decisão*** substituindo alguns valores nela.
  - $x_1 = 1$ e $x_2 = 1$ resulta em $g(\boldsymbol{x}) > 0$.
    - ✓ Região da classe ***positiva***, C_2.
  - $x_1 = 3$ e $x_2 = 3$ resulta em $g(\boldsymbol{x}) < 0$.
    - ✓ Região da classe ***negativa***, C_1.
  - $x_1 = 1$ e $x_2 = 3$ resulta em $g(\boldsymbol{x}) = 0$.
    - ✓ ***Indeterminação***: não podemos afirmar a qual classe o exemplo pertence.
    - ✓ Podemos atribuir arbitrariamente a uma das duas classes ou escolher a classe que possui maior número de exemplos ou maior probabilidade de ocorrência.

Classificação com neurônios

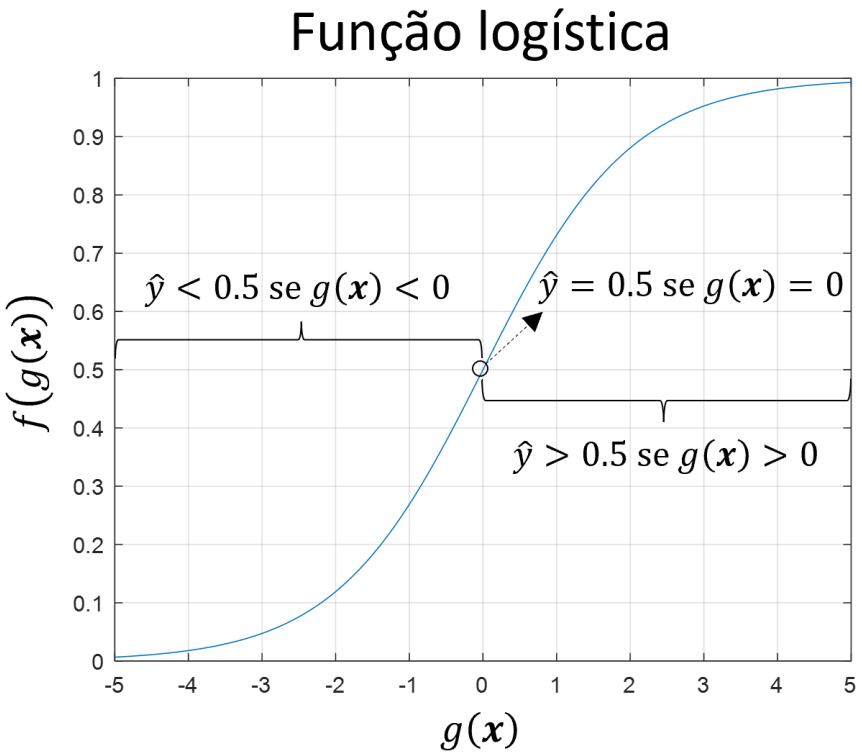

- Ao passar $g(\boldsymbol{x})$ pela função de ativação, $f(.)$, temos os seguintes valores de saída:

$$f\big(g(\boldsymbol{x})\big) = \begin{cases} 0 \leq \hat{y} < 0.5, & \text{se } g(\boldsymbol{x}) < 0 \\ 0.5 < \hat{y} \leq 1, & \text{se } g(\boldsymbol{x}) > 0 \\ 0.5, & \text{se } g(\boldsymbol{x}) = 0 \end{cases}.$$

- Esses valores de saída do neurônio são ***interpretados como sendo a probabilidade*** (pois valores estão no intervalo [0, 1]) de $\boldsymbol{x}$ pertencer à ***classe positiva***.
- Quanto ***mais distante*** de $g(\boldsymbol{x})$ estiver $\boldsymbol{x}$, ***maior será a probabilidade dele pertencer a uma das duas classes***.

Classificação com neurônios

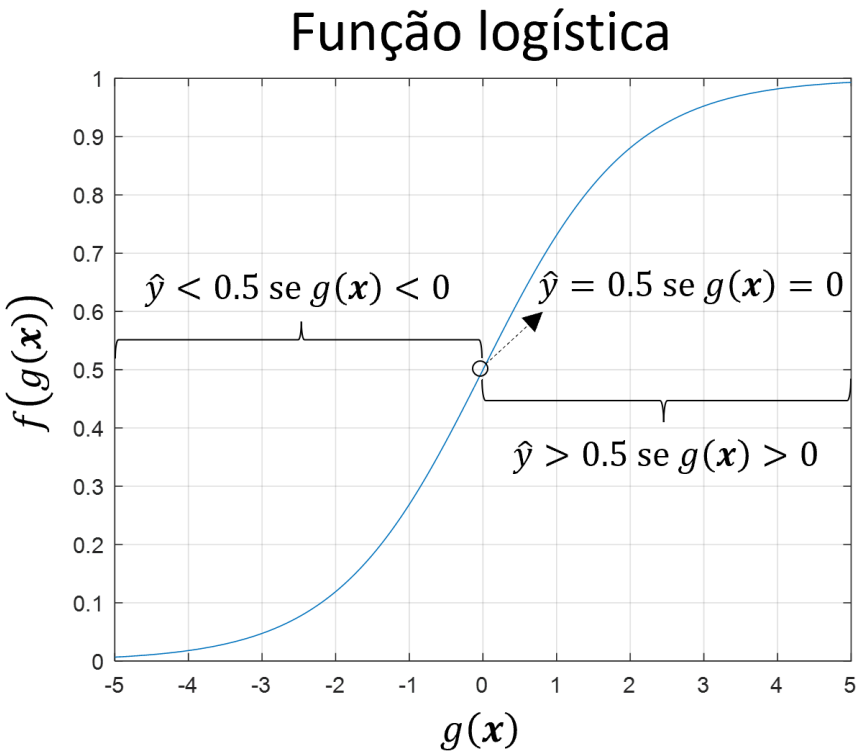

- A probabilidade da classe negativa é obtida através do complemento de $\hat{y}$, i.e., $1 - \hat{y}$.
- Notem $\hat{y}$ ***pode assumir qualquer valor no intervalo*** [0, 1], ou seja, esse é um ***problema de regressão e não de classificação!***
- ***Então como obtemos um classificador?***

Classificação com neurônios

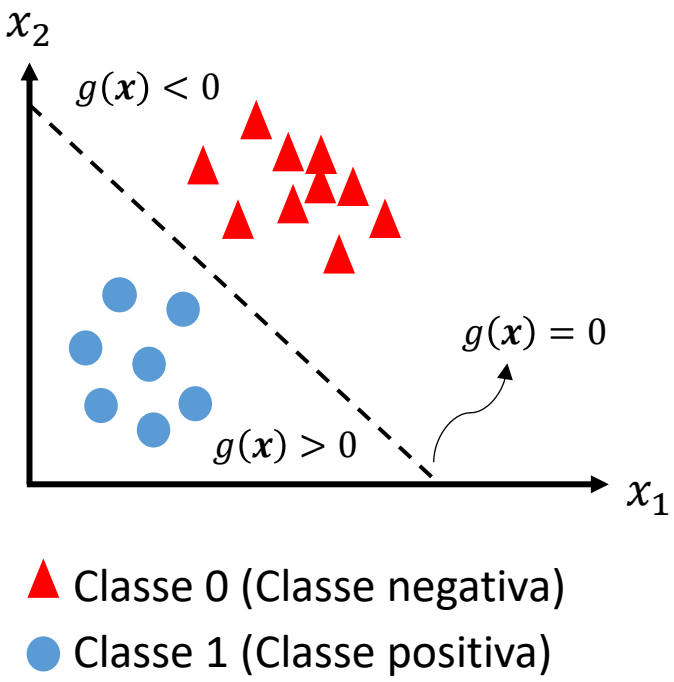

- Para classificar, ***quantizamos os valores de saída da função de ativação***:

$$C = \begin{cases} 0, & \hat{y} < 0.5, \\ 1, & \hat{y} > 0.5, \\ \text{uma ou outra}, & \hat{y} = 0.5. \end{cases}$$

- Em geral, quando $\hat{y} = 0.5$, atribui-se $\boldsymbol{x}$ à ***classe mais frequente*** ou a ***uma das duas classes de forma arbitrária***.

Classificação com neurônios

- O ***objetivo*** do treinamento do classificador é ***encontrar os pesos*** de $g(\boldsymbol{x})$ de forma que as ***classes sejam separadas da melhor forma possível***.
- Ou seja, assim como na regressão, o objetivo é ***minimizar uma função de erro***.

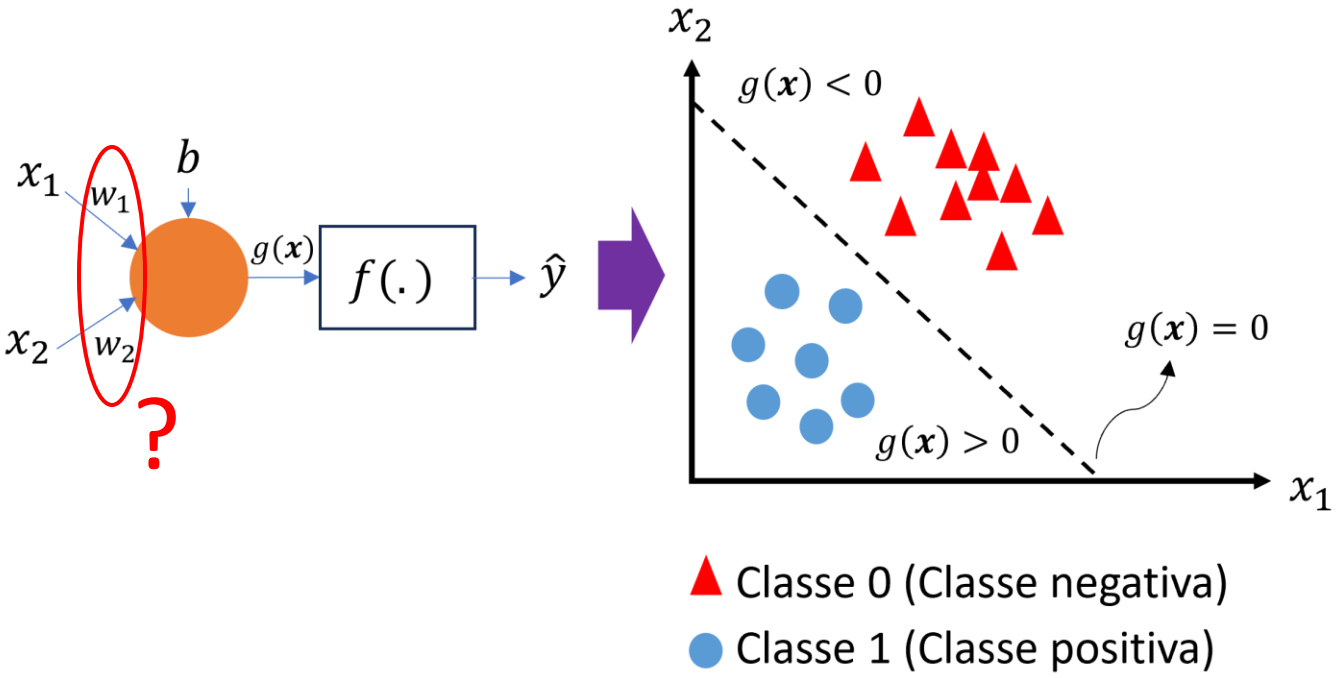

Mas e se tivermos mais de duas classes ou elas não puderem ser separadas por hiperplanos?

Classificação com redes neurais

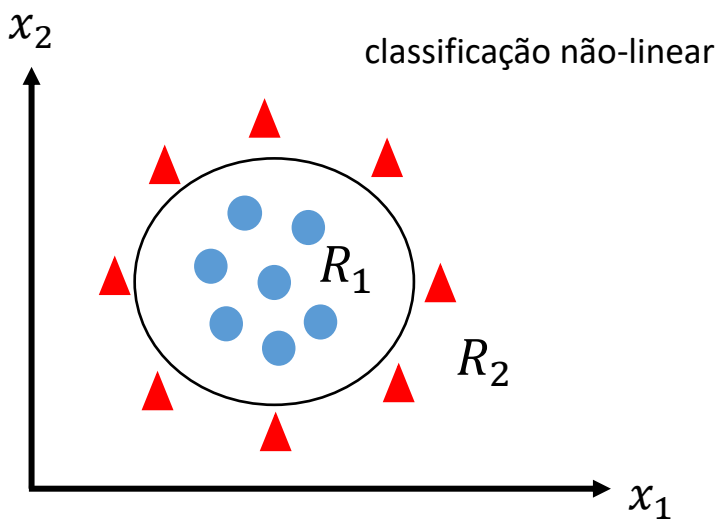

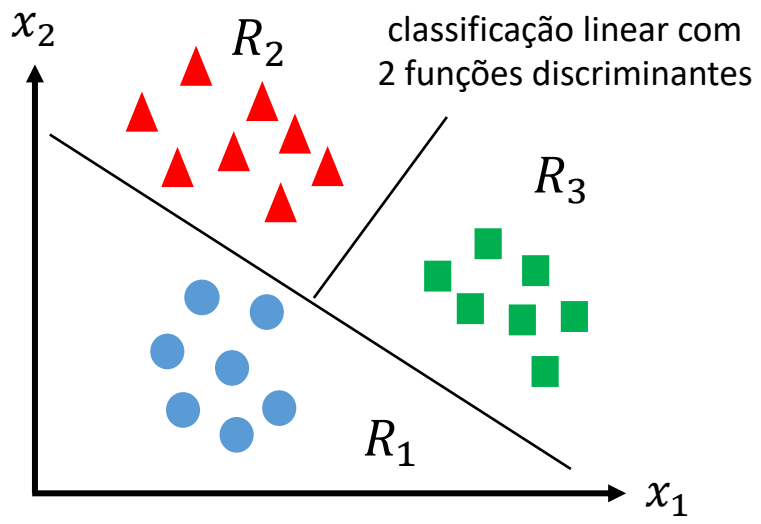

- Se precisarmos resolver problemas com ***mais classes*** ou ***mais complexos*** (e.g., que ***exijam superfícies de separação não-lineares ou várias delas***), podemos ***agrupar vários neurônios e usar uma rede neural***.
- Usamos uma ou mais camadas escondidas para encontrar uma superfície de separação adequada.
  - Redes neurais são aproximadoras universais de funções.

Classificação com redes neurais

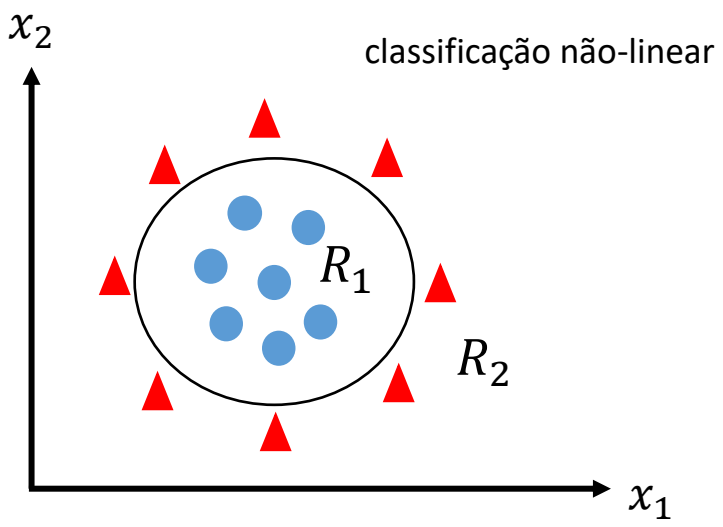

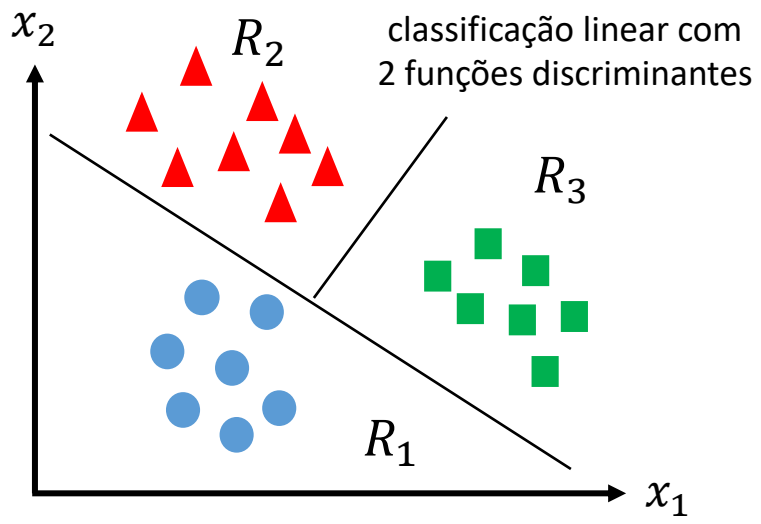

- No caso com múltiplas classes, teremos ***vários neurônios na camada de saída*** da rede, ***um para cada classe*** do problema de classificação.
- ***Cada saída*** da rede neural dá a ***probabilidade de uma das classes.***
- **OBS**.: Mesmo no caso com duas classes, podemos criar uma rede com duas saídas, onde cada uma delas dá a probabilidade de uma das classes.
  - Nesse caso, usaríamos uma rede, pois a separação não é feita por hiperplanos.

Classificação com redes neurais

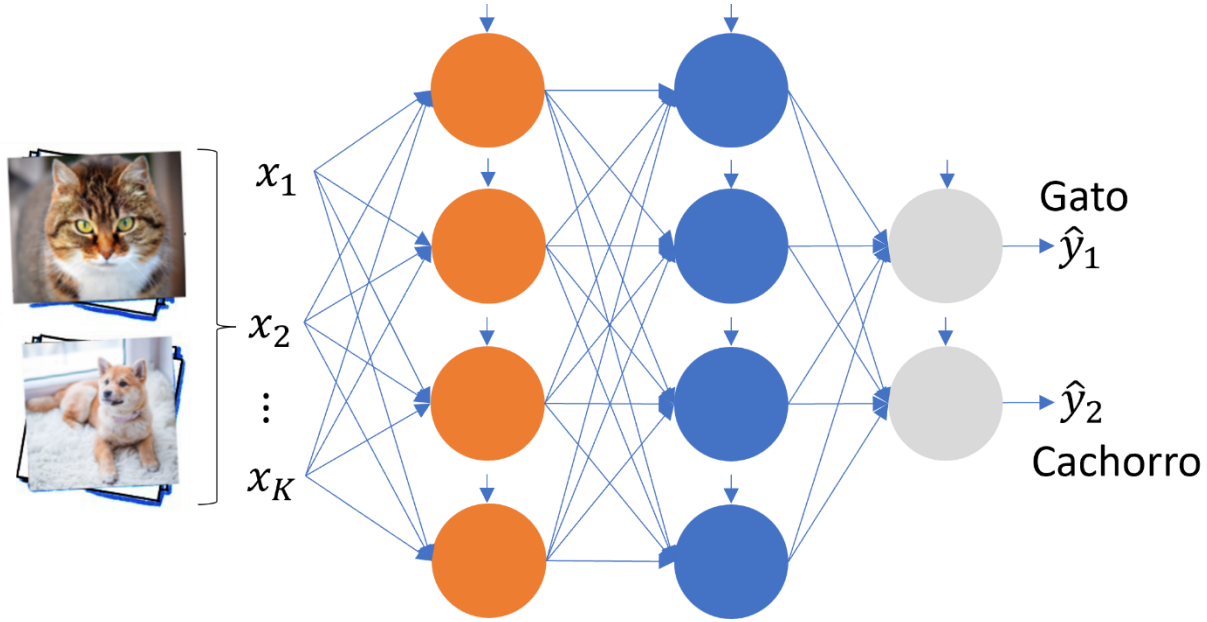

- Portanto, se quisermos projetar uma rede neural capaz de distinguir entre gatos e cachorros, poderíamos ter ***um neurônio de saída representando gatos e outro representando cães***.
- ***Cada neurônio*** de saída irá apresentar a ***probabilidade de uma imagem de entrada pertencer a uma das duas classes***.

Classificação com redes neurais

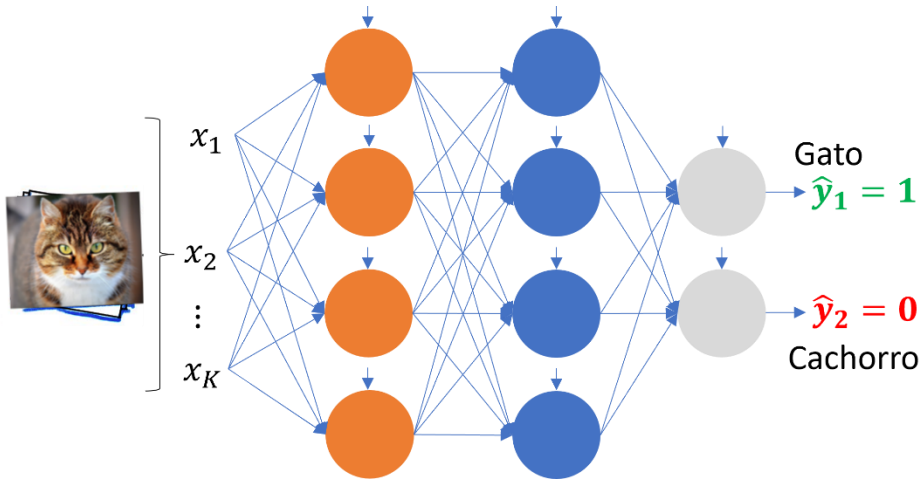

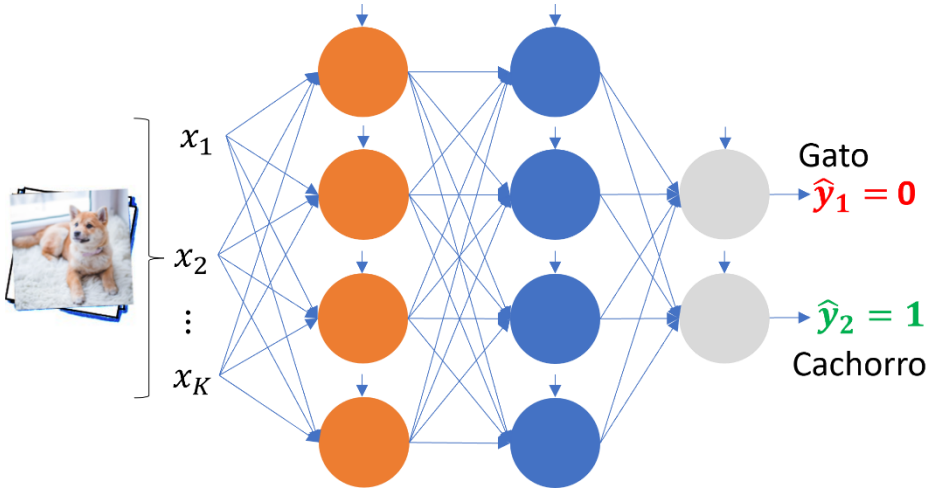

- Então, se uma ***imagem de um gato*** for ***passada para a rede***, o ***neurônio que representa os gatos terá um alto valor de probabilidade*** (teoricamente 1) e o que representa os ***cachorros*** terá um ***baixo valor de probabilidade*** (teoricamente 0).
- O contrário ocorreria se imagem de um cachorro fosse passada para a rede.

Classificação com redes neurais

Dados de entrada	Saídas esperadas (rótulos)
	$[1, \quad 0]$
	$[0, \quad 1]$

- As ***saídas (teóricas) da rede*** nos fornecem uma maneira de ***rotular*** cães e gatos fazendo com que o ***rótulo*** de uma imagem seja um ***vetor contendo a saída desejada de cada um dos neurônios da camada de saída***.

Classificação com redes neurais

Dados de entrada	Rótulo
	$[1, \quad 0]$
	$[0, \quad 1]$

- Portanto, se o ***primeiro*** neurônio da camada de saída representa gatos e o ***segundo*** cães, podemos dizer que o ***rótulo*** (i.e., saída esperada) ***para imagens de gatos é dado pelo vetor:*** $[1, \quad 0]$.
- E o rótulo para imagens de cães é dado pelo vetor $[0, \quad 1]$.
- Essa forma de representar os rótulos é chamada de ***codificação one-hot***.
  - Vetor onde um único elemento é igual a 1 (indicando a classe verdadeira) e todos os outros são iguais a 0.

Classificação com redes neurais

- E se quiséssemos usar uma rede neural para reconhecer imagens contendo dígitos escritos à mão?
  - Esse é um problema com 10 classes, os dígitos de 0 a 9.
- Quantos neurônios seriam necessários na camada de saída?
- Como seria a codificação ***one-hot*** dos rótulos nesse caso?

Classificação com redes neurais

$$0 \rightarrow [1, 0, 0, 0, 0, 0, 0, 0, 0, 0]$$
$$1 \rightarrow [0, 1, 0, 0, 0, 0, 0, 0, 0, 0]$$
$$2 \rightarrow [0, 0, 1, 0, 0, 0, 0, 0, 0, 0]$$
$$3 \rightarrow [0, 0, 0, 1, 0, 0, 0, 0, 0, 0]$$
$$4 \rightarrow [0, 0, 0, 0, 1, 0, 0, 0, 0, 0]$$
$$5 \rightarrow [0, 0, 0, 0, 0, 1, 0, 0, 0, 0]$$
$$6 \rightarrow [0, 0, 0, 0, 0, 0, 1, 0, 0, 0]$$
$$7 \rightarrow [0, 0, 0, 0, 0, 0, 0, 1, 0, 0]$$
$$8 \rightarrow [0, 0, 0, 0, 0, 0, 0, 0, 1, 0]$$
$$9 \rightarrow [0, 0, 0, 0, 0, 0, 0, 0, 0, 1]$$

- Precisaríamos de ***10 neurônios***, 1 para cada um dos 10 possíveis dígitos (0 a 9).
- O ***rótulo*** seria um ***vetor com 10 elementos***.
- Porém, ***apenas um dos elementos seria diferente de 0***, aquele que identifica a classe a qual o dígito $\boldsymbol{x}$ pertence.
- Vejamos na sequência, um código que usa uma rede neural para reconhecer dígitos escritos à mão.

A base de dados

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
   [tf.keras.layers.Flatten(input_shape=(28, 28)),
    tf.keras.layers.Dense(20, activation=tf.nn.relu),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- Usaremos a base de dados com imagens de dígitos escritos à mão do MNIST (*Modified National Institute of Standards and Technology*).
- O TensorFlow disponibiliza uma função (i.e., *load_data()*) que baixa e divide os dados em conjuntos de treinamento e teste.

Coletar Dados

A base de dados

- A base de dados possui um conjunto de ***treinamento de 60.000 imagens*** e um ***conjunto de teste de 10.000 imagens***.
- São ***imagens em escala de cinza*** com 28x28 pixels dos dígitos de 0 a 9.
  - Notem que as imagens são *arrays* ***bidimensionais***.

A base de dados

- Os ***pixels*** são representados por ***valores inteiros não sinalizados de 8 bits***, i.e., variam de 0 a 255.
- Cada ***pixel será um atributo de entrada da rede neural***.
- Os rótulos são valores de 0 a 9.

Normalização dos dados

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
   [tf.keras.layers.Flatten(input_shape=(28,28)),
    tf.keras.layers.Dense(20, activation=tf.nn.relu),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- Para ***melhorar a estabilidade*** do treinamento e ***aumentar a velocidade de convergência***, nós normalizamos os valores das imagens.
  - Em geral, as redes neurais se ***comportam bem melhor se os dados são escalonados***.
- Normalizamos os valores dos pixels de forma que fiquem no intervalo entre 0 e 1.
- Para fazer isso, dividimos os valores por 255.

Definindo a rede neural

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
   [tf.keras.layers.Flatten(input_shape=(28,28)),
    tf.keras.layers.Dense(20, activation=tf.nn.relu),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- Como fizemos antes, definimos a rede ***empilhando*** (i.e., listando) algumas camadas em uma rede ***sequencial*** (i.e., *dense feed forward*).

Projetar modelo

Definindo a rede neural

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
   [tf.keras.layers.Flatten(input_shape=(28,28)),
    tf.keras.layers.Dense(20, activation=tf.nn.relu),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- ***Não existe uma regra para definirmos a arquitetura da rede*** (i.e., número de camadas, nós, otimizador, função de erro, etc.), o ***mais indicado é testar diferentes arquiteturas***, de preferência com ***técnicas de otimização hiperparamétrica***.
- Assim, apenas para ilustrar como realizar classificação com redes neurais, iremos adotar uma arquitetura qualquer.

Projetar modelo

Camada de achatamento

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
  [tf.keras.layers.Flatten(input_shape=(28,28)),
   tf.keras.layers.Dense(20, activation=tf.nn.relu),
   tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- Como as imagens são *arrays* bidimensionais com dimensão 28x28 pixels, a primeira operação que precisamos realizar é ***transformá-las em arrays unidimensionais*** com 784 pixels (i.e., 28x28 = 784 pixels).

Camada de achatamento

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
  [tf.keras.layers.Flatten(input_shape=(28,28)),
   tf.keras.layers.Dense(20, activation=tf.nn.relu),
   tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- Essa camada ***não tem parâmetros a serem aprendidos durante o treinamento***, ela só ***redimensiona*** os dados de entrada.
- Assim, a primeira camada da rede, ***Flatten***, realiza uma operação de ***achatamento*** das *arrays* 2D de entrada.

Por que achatamos as imagens?

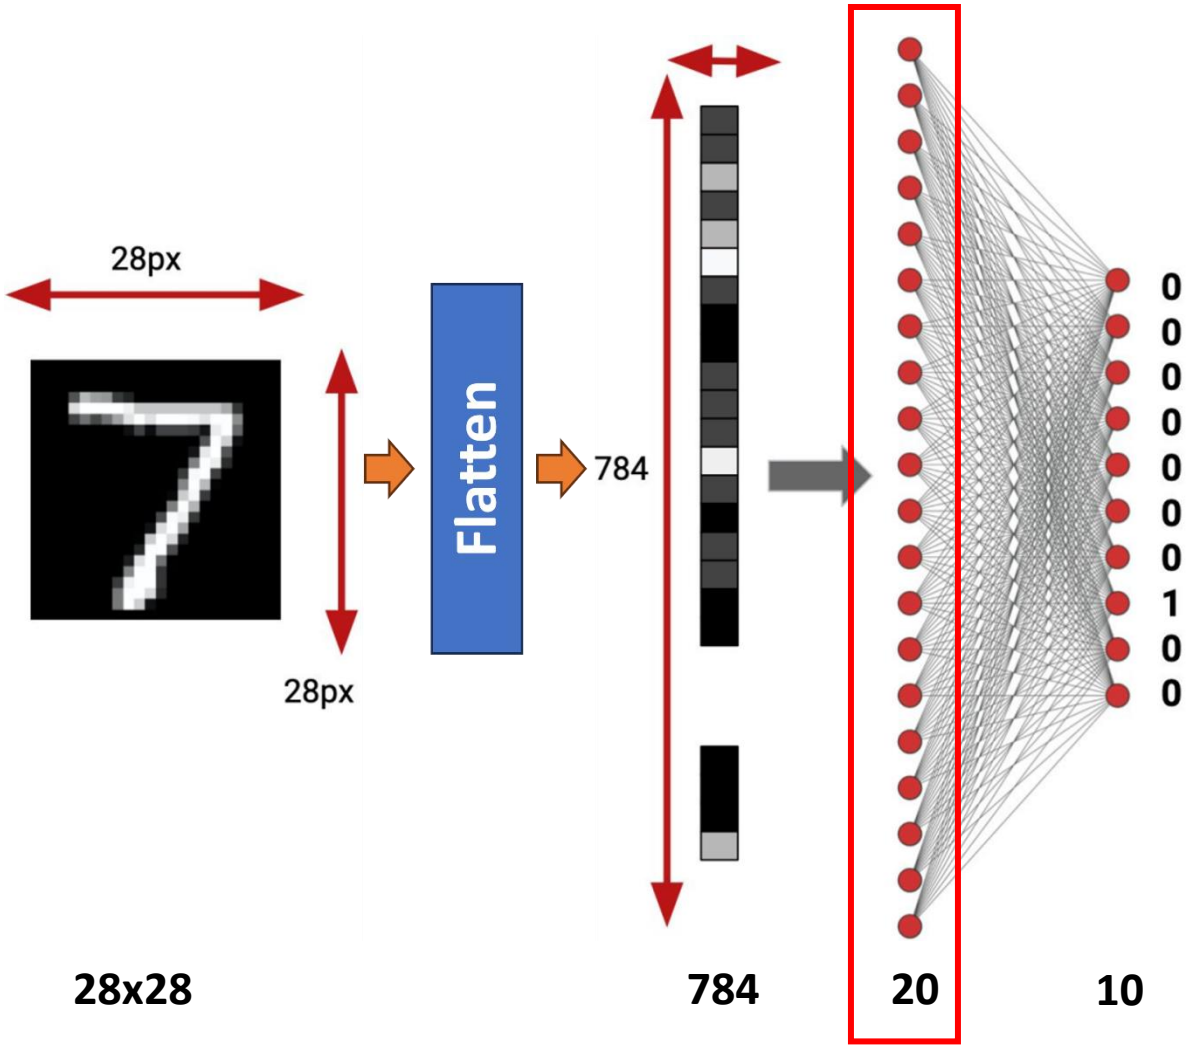

- Notem que a camada (oculta) seguinte à camada *Flatten* tem 20 neurônios.
- Essa camada oculta espera como entrada uma ***array unidimensional***.
- Por isso precisamos que as imagens sejam transformadas em *arrays* com uma única dimensão e 784 elementos.

Camada de achatamento

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
   [tf.keras.layers.Flatten(input_shape=(28,28)),
    tf.keras.layers.Dense(20, activation=tf.nn.relu),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- Como a camada *Flatten* é a primeira camada, definimos nela as ***dimensões de entrada***.
- Definimos que a camada deve esperar por *arrays* de entrada com dimensões 28x28.
- Se ela receber *arrays* com dimensões diferentes, um erro será lançado.
- **OBS**.: Não definimos o número de exemplos de entrada, pois ele varia com o tamanho do *mini-batch*.

Camada oculta

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
   [tf.keras.layers.Flatten(input_shape=(28,28)),
    tf.keras.layers.Dense(20, activation=tf.nn.relu),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- Na sequência, definimos a primeira e única ***camada oculta densa*** desta rede.
- Como discutido anteriormente, ela possui 20 neurônios.
  - Esse número foi escolhido de forma arbitrária*.

*Mais tarde vocês explorarão outras arquiteturas.

Camada oculta

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
   [tf.keras.layers.Flatten(input_shape=(28,28)),
    tf.keras.layers.Dense(20, activation=tf.nn.relu),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- Com ***poucos nós***, a ***rede pode não ter capacidade suficiente para aprender as características*** contidas nas imagens.
- Por outro lado, ***com muitos nós*** a ***rede pode se especializar demais*** ou ficar ***muito lenta*** para aprender.
- A camada usa função de ativação ReLU, que iremos detalhar em seguida.

Camada de saída

```
import tensorflow as tf

data = tf.keras.datasets.mnist
(X_train, y_train), (X_test, y_test) = data.load_data()

X_train  = X_train / 255.0
X_test = X_test / 255.0

model = tf.keras.models.Sequential(
   [tf.keras.layers.Flatten(input_shape=(28,28)),
    tf.keras.layers.Dense(20, activation=tf.nn.relu),
    tf.keras.layers.Dense(10, activation=tf.nn.softmax)])
```

- Como temos 10 possíveis classes, a camada de saída possui 10 neurônios, um para ***calcular a probabilidade de cada uma das classes*** do problema.
- Ela usa função de ativação ***Softmax***, a qual discutiremos em detalhes a seguir.

A rede neural

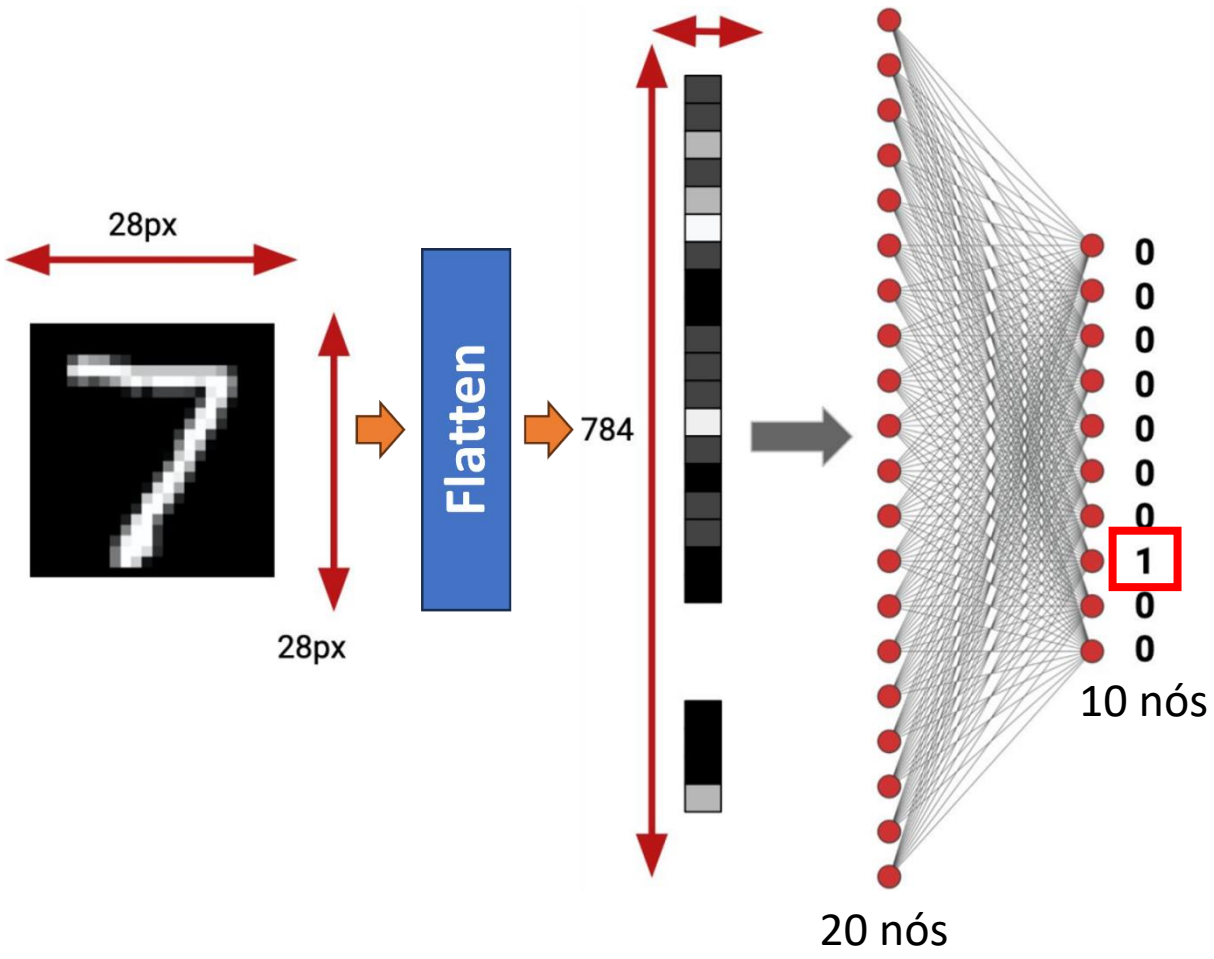

- A figura mostra a ***rede neural densa*** que criamos, com 20 neurônios na camada oculta e 10 na de saída.
- Cada neurônio está conectado a cada entrada ou neurônio da camada anterior.

A rede neural

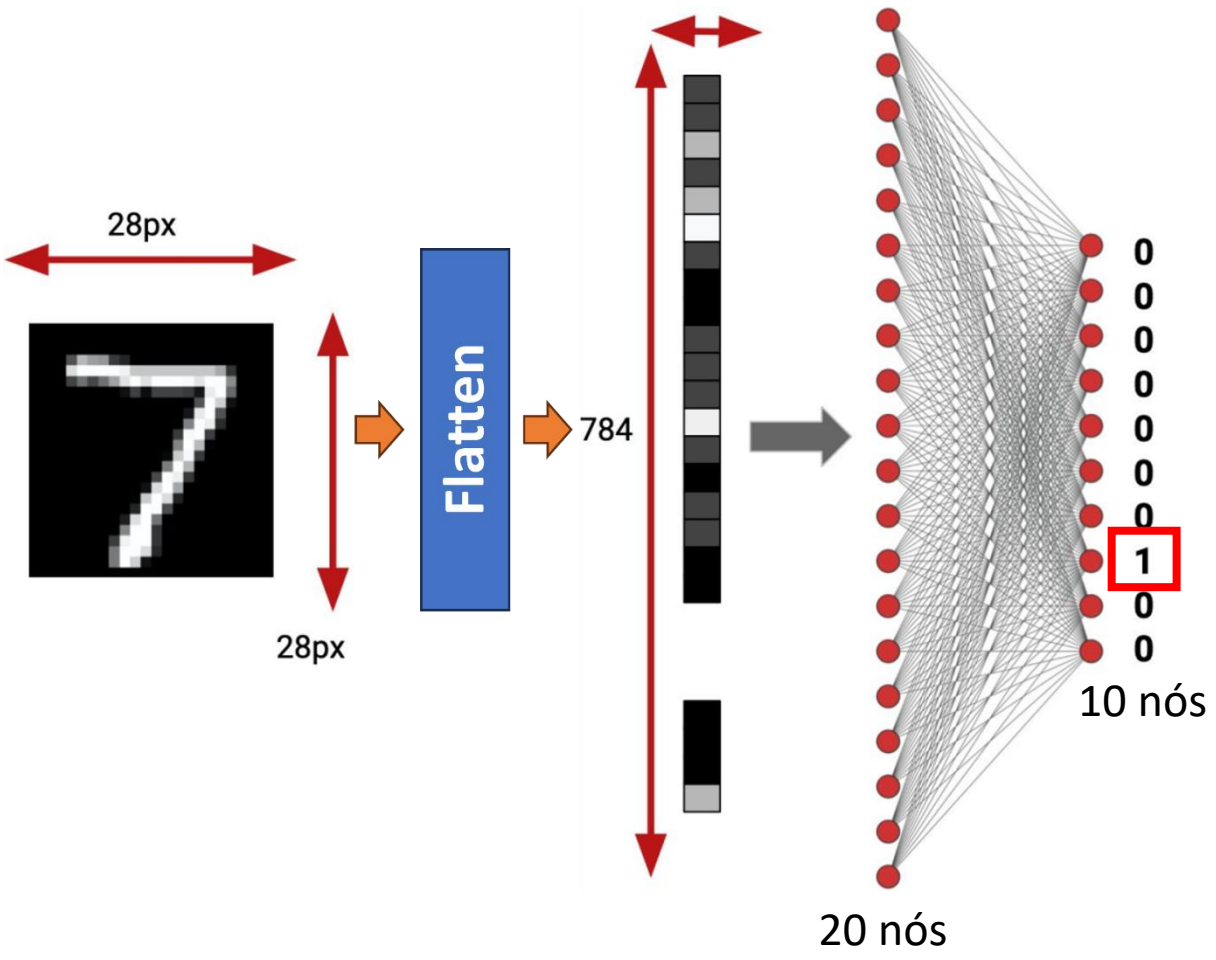

- Assim, se alimentarmos a rede com os *pixels* de uma ***imagem contendo um número 7***.
- Então, desejaríamos que o ***neurônio de saída que representa o número 7 fosse o que tivesse o maior valor de probabilidade*** (em teoria 1).
- Portanto, o ***rótulo dessa imagem*** é ***um vetor com 10 elementos*** contendo 0s, com exceção do elemento que representa o dígito 7, o qual terá o valor 1.

Funções de ativação: ReLU

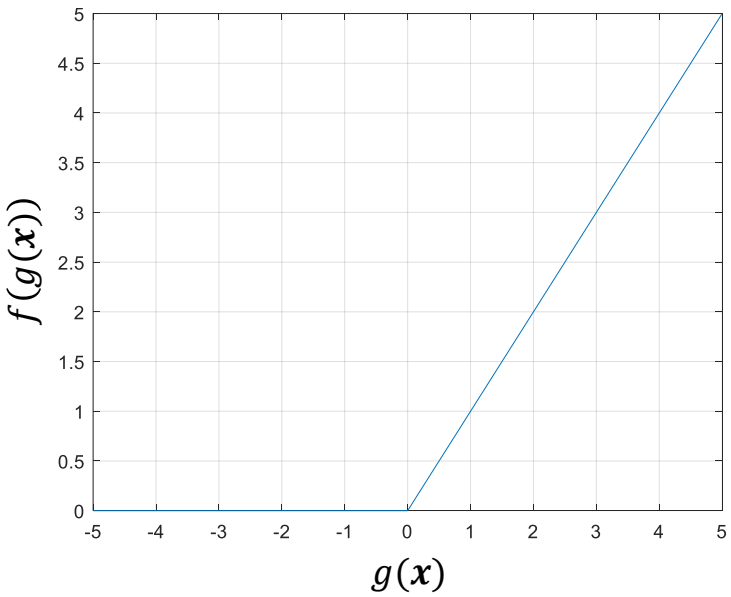

$$\hat{y} = f(g(\boldsymbol{x})) = \max(0, g(\boldsymbol{x}))$$

- Como vimos, a camada oculta usa funções de ativação ***Rectified Linear Unit*** (ReLU) em seus neurônios.
- É uma ***função não-linear*** em que sua saída é igual 0 quando $g(\boldsymbol{x}) \leq 0$ e o próprio $g(\boldsymbol{x})$ quando $g(\boldsymbol{x}) > 0$.
- É uma das funções mais amplamente utilizadas em redes neurais.
- Suas principais ***vantagens*** são a sua ***simplicidade e eficiência computacional***.

Funções de ativação: ReLU

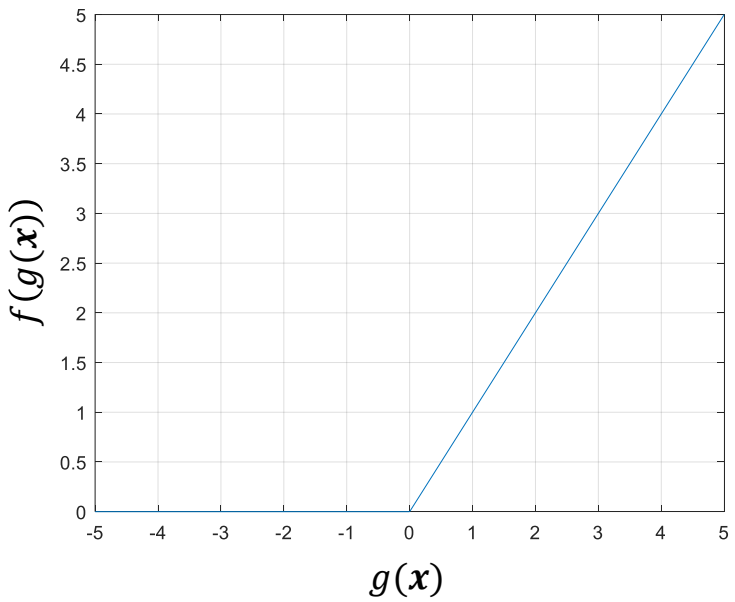

$$\hat{y} = f(g(\boldsymbol{x})) = \max(0, g(\boldsymbol{x}))$$

- Ajuda a ***mitigar o problema do desaparecimento de gradiente***, que ocorre com funções de ativação como a sigmoide e tangente hiperbólica quando usadas ***em redes profundas***.
- Ela introduz ***não linearidade*** nas redes, permitindo que elas ***aprendam padrões e a modelar relacionamentos complexos nos dados***.
- **OBS.**: Redes com neurônios usando ***ativação linear só podem modelar relacionamentos lineares*** entre entradas e saídas.

Funções de ativação: ReLU

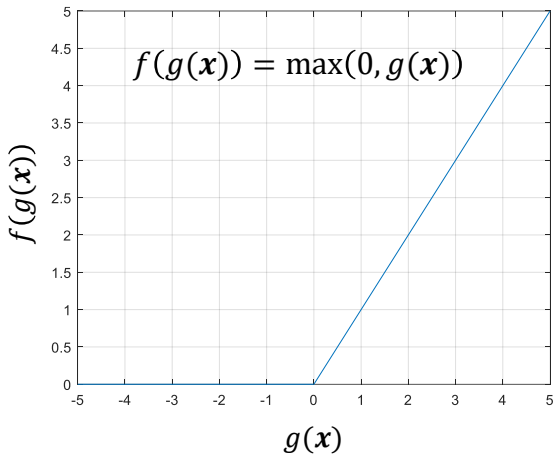

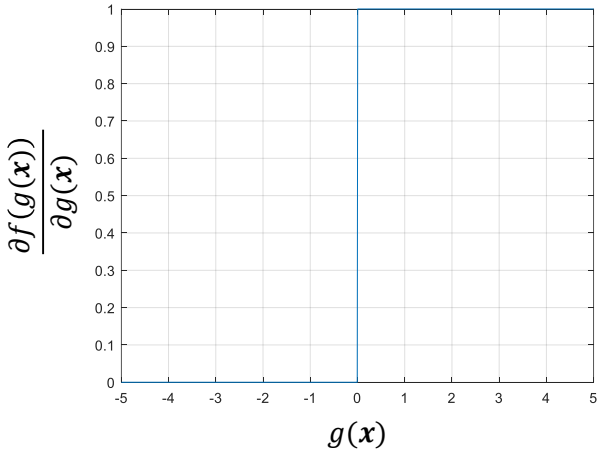

- Uma desvantagem é que ela pode levar ao problema da ***ReLU agonizante***.
- Esse problema ocorre quando os ***neurônios têm saída igual a zero durante o treinamento e, consequentemente, não conseguem atualizar seus pesos durante a retropropagação***.
- Para mitigar esse problema, foram propostas algumas variantes como: Leaky ReLU, Parametric ReLU, Exponential Linear Units (ELU) e Gaussian Error Linear Unit (GELU).

Funções de ativação: Softmax

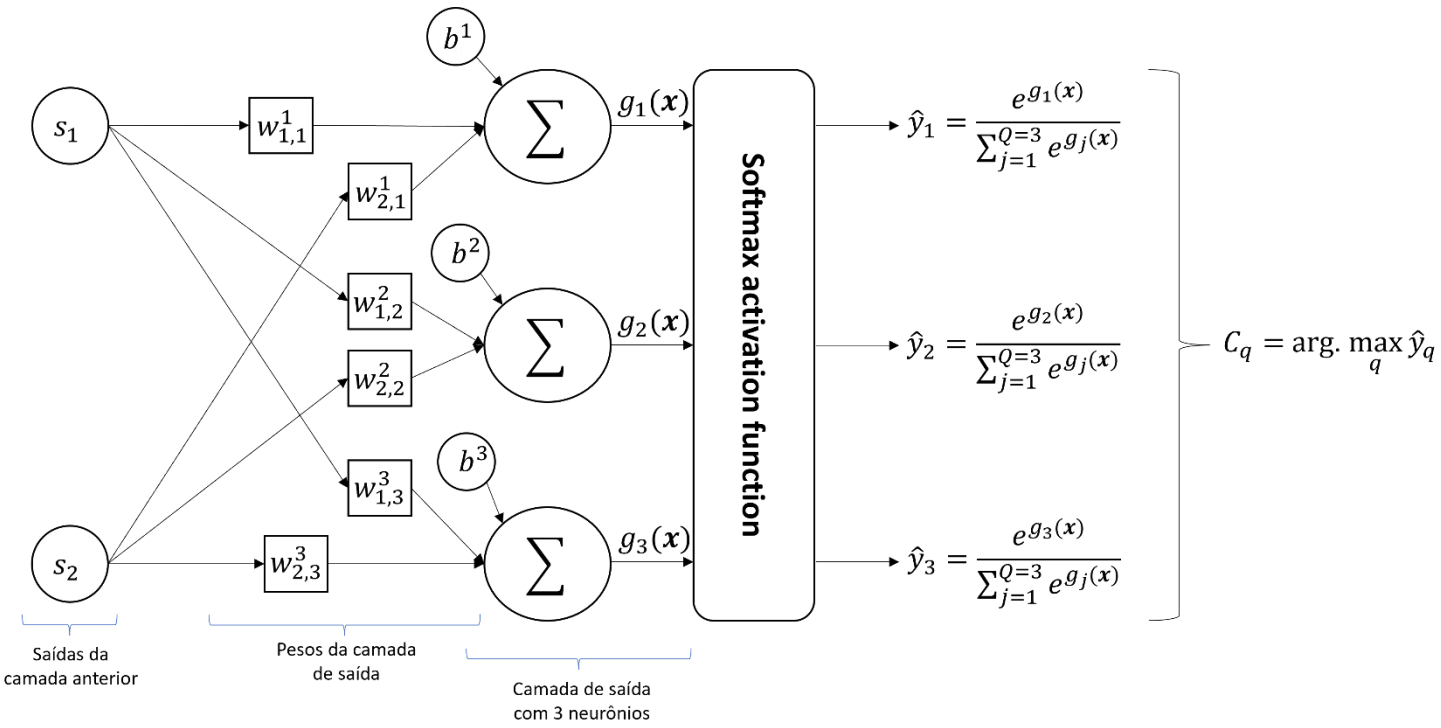

$Q = 3$ (número de classes)

- Usada frequentemente na ***camada de saída*** de ***redes neurais*** empregadas em tarefas de ***classificação***, onde a rede precisa ***atribuir*** uma ***probabilidade para cada classe*** possível.
- Transforma um ***vetor de valores de ativação em uma distribuição de probabilidades***.
  - Normaliza as ativações.
- É uma generalização da função sigmoide.

Funções de ativação: Softmax

Ativações da camada de saída

Função de ativação *softmax*

Probabilidades

$$\begin{array}{c} g_1(\boldsymbol{x}) \\ g_2(\boldsymbol{x}) \\ g_3(\boldsymbol{x}) \\ g_4(\boldsymbol{x}) \\ g_5(\boldsymbol{x}) \end{array} \begin{bmatrix} 1.3 \\ 5.1 \\ 2.2 \\ 0.7 \\ 1.1 \end{bmatrix} \longrightarrow \boxed{\frac{e^{g_i(\boldsymbol{x})}}{\sum_{j=1}^{Q} e^{g_j(\boldsymbol{x})}}} \longrightarrow \begin{bmatrix} 0.01 \\ 0.9 \\ 0.05 \\ 0.01 \\ 0.02 \end{bmatrix}$$

$Q = 5$ (número de classes)

OBS.: *e* é a base do logaritmo natural.

- A função opera da seguinte maneira.
- Dado um ***vetor de valores de ativação***, $g_i(\boldsymbol{x}), \forall i$, ou seja, a soma ponderada das entradas de um neurônio, ela
  - calcula a exponencial de cada ativação,
  - normaliza essas exponenciais dividindo-as pela soma de todas as exponenciais, gerando uma distribuição de probabilidades das classes.

Funções de ativação: Softmax

Ativações da camada de saída

Função de ativação *softmax*

Probabilidades

$$\begin{array}{c} g_1(\boldsymbol{x}) \\ g_2(\boldsymbol{x}) \\ g_3(\boldsymbol{x}) \\ g_4(\boldsymbol{x}) \\ g_5(\boldsymbol{x}) \end{array} \begin{bmatrix} 1.3 \\ 5.1 \\ 2.2 \\ 0.7 \\ 1.1 \end{bmatrix} \longrightarrow \boxed{\frac{e^{g_i(\boldsymbol{x})}}{\sum_{j=1}^{Q} e^{g_j(\boldsymbol{x})}}} \longrightarrow \begin{bmatrix} 0.01 \\ 0.9 \\ 0.05 \\ 0.01 \\ 0.02 \end{bmatrix}$$

$Q = 5$ (número de classes)

- Ela ***garante que as saídas estejam no intervalo entre 0 e 1, e a soma de todas as saídas seja igual a 1***, tornando-as interpretáveis como uma ***função massa de probabilidade multinomial***.
- Isso é crucial para tarefas de classificação ***multiclasse***, onde se deseja determinar a probabilidade de um exemplo de entrada pertencer a cada classe possível.
  - ***Multiclasse***: cada ***exemplo*** é atribuído a uma única ***classe exclusiva***, ou seja, pertence a apenas uma classe.

Compilando o modelo

```
model.compile(optimizer = 'adam',
              loss = 'sparse_categorical_crossentropy',
              metrics = ['accuracy']
)

history = model.fit(X_train, y_train, epochs=20)
```

- Vamos usar o otimizador Adam, o qual ***ajusta adaptativamente passos de aprendizagem independentes*** dependendo do ***histórico de gradientes passados***, ***acelerando a convergência do algoritmo***.

Compilando o modelo

```
model.compile(optimizer = 'adam',
              loss = 'sparse_categorical_crossentropy',
              metrics = ['accuracy']
)

history = model.fit(X_train, y_train, epochs=20)
```

- Como função de erro (i.e., *loss*), usaremos a função conhecida como ***entropia cruzada categórica***.
- ***Não usamos o MSE,*** pois ela é uma ***métrica usada em problemas de regressão***, ***onde queremos predizer valores contínuos***.

Compilando o modelo

```
model.compile(optimizer = 'adam',
              loss = 'sparse_categorical_crossentropy',
              metrics = ['accuracy']
)

history = model.fit(X_train, y_train, epochs=20)
```

- No entanto, em ***problemas de classificação***, as ***saídas são categóricas***, ou seja, pertencem a um ***conjunto discreto e finito de valores***.
- As saídas podem ser ***codificadas*** como ***vetores one-hot*** ou ***valores inteiros.***
- Nesses casos, usamos como função de erro a entropia cruzada categórica ou sua versão esparsa.

Entropia cruzada categórica

- Métrica frequentemente utilizada para avaliar o ***desempenho de modelos de classificação multiclasse***.
- Ela mede a ***diferença entre as distribuições de probabilidade preditas pelo modelo e as distribuições dos rótulos*** das classes.
- A função da ***entropia cruzada média*** é dada por

O erro tende a 0 quando $\hat{y}_q(n)$ tende a 1, caso contrário, o erro aumenta.

$$J_e(\boldsymbol{W}) = -\frac{1}{N}\sum_{n=0}^{N-1}\sum_{q=0}^{Q-1} 1\{y(n) == q\}\log\left(\hat{y}_q(n)\right),$$

onde Q é o número classes, N é o número de exemplos, $1\{\cdot\}$ é a ***função indicadora*** (1{condição verdadeira} = 1 e 1{condição falsa} = 0), $\boldsymbol{W}$ é a matriz de ***pesos***, $y(n)$ é rótulo do n-ésimo exemplo de entrada e $\hat{y}_q(n)$ é a q-ésima saída do modelo para o n-ésimo exemplo de entrada.

Entropia cruzada categórica

- Usando-se a codificação ***one-hot***, a equação pode ser re-escrita como

$$J_e(\boldsymbol{W}) = -\frac{1}{N}\sum_{n=0}^{N-1} \boldsymbol{y}(n)^T \log\left(\hat{\boldsymbol{y}}\,(n)\right),$$

onde $\boldsymbol{y}(n) = [1\{y(n) == 0\}, \cdots, 1\{y(n) == Q-1\}]^T \in \mathbb{R}^{Q\times 1}$ é um vetor coluna com os rótulos utilizando a codificação ***one-hot*** e $\hat{\boldsymbol{y}}\,(n) = \left[\hat{y}_0(n), \cdots, \hat{y}_{Q-1}(n)\right]^T \in \mathbb{R}^{Q\times 1}$ é um vetor coluna com as Q saídas do modelo para o n-ésimo exemplo de entrada.

- Durante o ***treinamento*** do modelo, o ***objetivo é minimizar a entropia cruzada categórica***, ou seja, fazer com que as ***probabilidades previstas pelo modelo se aproximem ao máximo dos rótulos dos exemplos***.

Entropia cruzada categórica esparsa

Classe	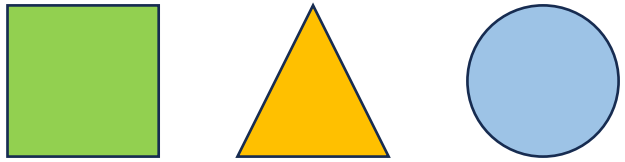		
Rótulo	0	1	2
Codificação *one-hot*	[1,0,0]	[0,1,0]	[0,0,1]

- É uma variação da entropia cruzada categórica que ***ao invés de usar a codificação one-hot para os rótulos, utiliza valores inteiros*** para indicar a classe a que pertence um exemplo.
- Essa variação é particularmente ***útil quando se lida com uma grande quantidade de classes***.
- Por exemplo, imaginem armazenar os vetores ***one-hot*** de um problema com mil ou mais classes (e.g., ImageNet-1K, ImageNet-21K).

Entropia cruzada categórica esparsa

Classe	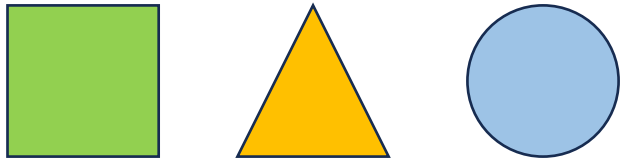		
Rótulo	0	1	2
Codificação *one-hot*	[1,0,0]	[0,1,0]	[0,0,1]

- Isso ***economiza memória***, já que apenas ***um valor inteiro é necessário em vez de um vetor one-hot***.
- Além disso, há uma ***diminuição no tempo de cálculo***, já que podemos ***indexar diretamente a probabilidade de saída correta através do índice fornecido pelo rótulo***.
  - Com isso, evita-se vários cálculos de multiplicação, log e soma.

Compilando o modelo

```
model.compile(optimizer = 'adam',
              loss = 'sparse_categorical_crossentropy',
              metrics = ['accuracy']
)

history = model.fit(X_train, y_train, epochs=20)
```

- Se os rótulos são valores ***inteiros***, usamos a função de perda ***sparse_categorical_crossentropy***.
- Caso contrário, se os rótulos estiverem no formato ***one-hot***, deve-se usar a função de perda ***categorical_crossentropy***.

Treinando o modelo

```
model.compile(optimizer = 'adam',
              loss = 'sparse_categorical_crossentropy',
              metrics = ['accuracy']
)

history = model.fit(X_train, y_train, epochs=20)
```

- Treinamos o modelo por apenas 20 épocas.
  - Veremos no exemplo que com essa quantidade de épocas já teremos bons resultados.

Treinar modelo

Avaliando o modelo

```
model.compile(optimizer = 'adam',
              loss = 'sparse_categorical_crossentropy',
              metrics = ['accuracy']
)

history = model.fit(X_train, y_train, epochs=20)
```

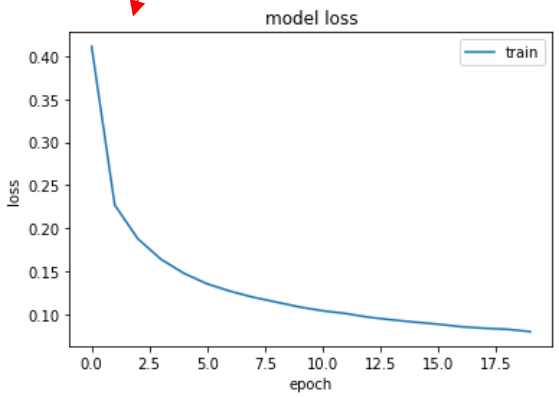

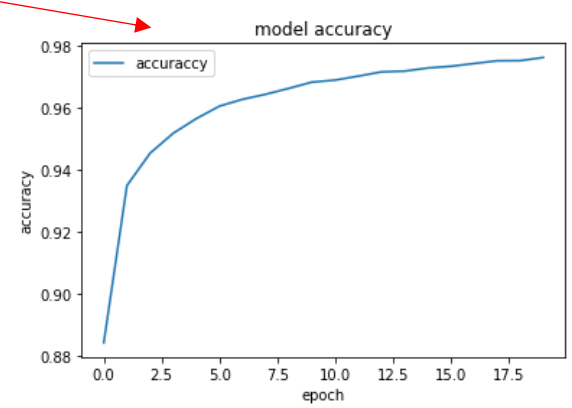

Avaliar e otimizar

- Na sequência, avaliamos o desempenho do modelo durante o treinamento.
- Além da entropia cruzada, vejam que usamos a ***acurácia*** como métrica.
  - Acurácia mede a proporção de exemplos classificados corretamente em relação ao número total de exemplos.
- **OBS**.: A ***função minimizada é a da entropia cruzada***. A acurácia é apenas calculada após cada época e ***não influencia no treinamento***.

Realizando inferências

```
classifications = model.predict(X_test)

print(classifications[0])
# retorna o índice da maior probabilidade.
print("Predicted class: ", np.argmax(classifications[0]))
print("The actual class: ", y_test[0])
```

- Por fim, fazemos ***inferências*** com o modelo treinado usando ***amostras inéditas*** para avaliar sua ***capacidade de generalização***.

Inferência

Classificação binária

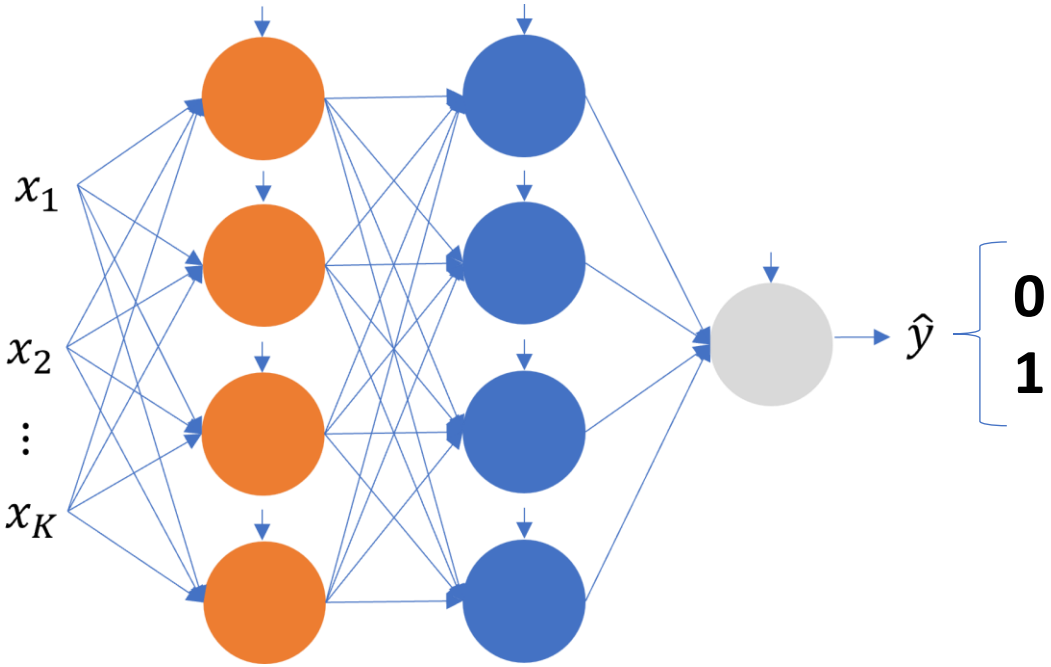

- No caso da ***classificação binária***, se os rótulos forem escalares inteiros, com valor 0 ou 1, podemos criar um ***classificador binário*** com ***apenas uma saída***.
- Ou seja, com apenas ***um neurônio na camada de saída***.
- Nesse caso, normalmente, também usamos funções ReLU como ativação das camadas ocultas.
- Porém, nesse caso a ***função sigmoide é usada como ativação da camada de saída***.

Classificação binária

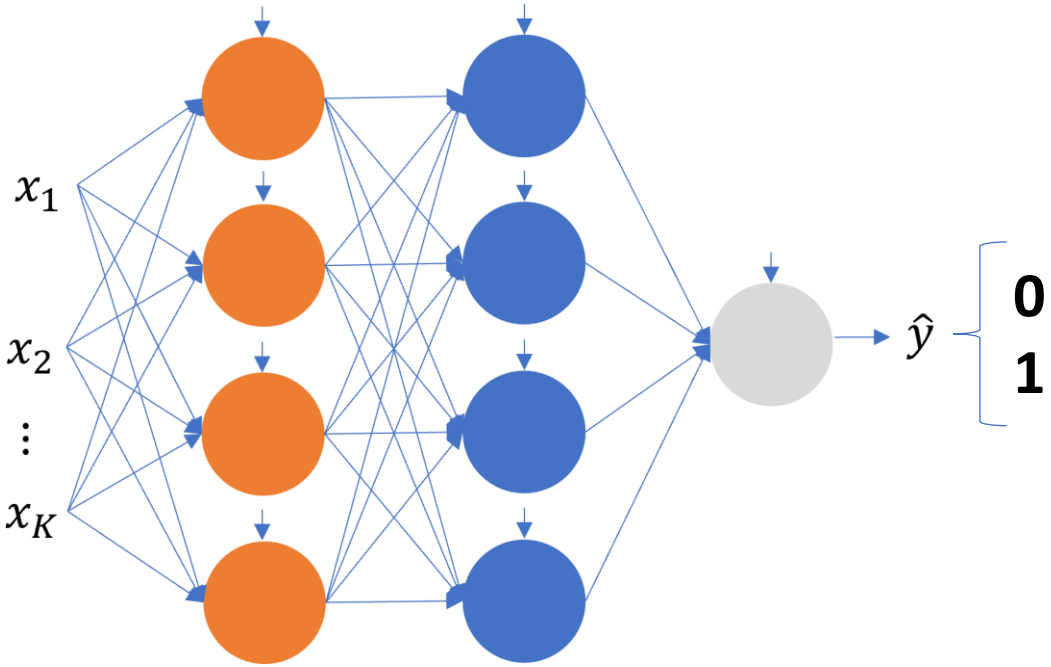

- O otimizador é em geral escolhido entre Adam ou SGD, mas existem outros que podem ser testados: Nadam, RMSProp, etc.
- A função de perda deve ser a da ***entropia cruzada binária***.
  - No TensorFlow ela é implementada pela classe ***BinaryCrossentropy***.
- Se estivermos lidando com imagens e a rede for do tipo ***dense feed forward***, devemos usar uma camada ***Flatten*** na entrada.

Exemplo

- Exemplo: Classificação de imagens com dígitos escritos à mão.

python + TensorFlow + jupyter + Google colab

Atividades

- Quiz: “***TP557 – Classificação com DNNs***”.
- Exercício: Detecção de peças de roupa

Perguntas?

Obrigado!

Anexo I: Dissipação do gradiente

Dissipação do gradiente

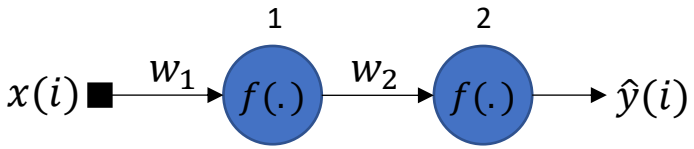

Considerações:

- 2 x neurônios com função de ativação sigmoide, $f(.)$.
- $g_1 = xw_1 \rightarrow$ entrada (i.e., ativação) do primeiro neurônio.
- $z_1 = f(xw_1) \rightarrow$ saída do primeiro neurônio.
- $g_2 = z_1 w_2 = f(xw_1)w_2 \rightarrow$ entrada (i.e., ativação) do segundo neurônio.
- $\hat{y} = f(f(xw_1)w_2) \rightarrow$ saída do segundo neurônio.
- **Objetivo**: minimizar o erro quadrático médio, $J_e = \frac{1}{N}\sum_{i=1}^{N}(\hat{y}(i) - y(i))^2$.

Dissipação do gradiente

- As ***regras de atualização*** dos dois pesos são dadas por

$$w_2 = w_2 - \alpha \frac{\partial J_e}{\partial w_2},$$

$$w_1 = w_1 - \alpha \frac{\partial J_e}{\partial w_1}.$$

- Usando a regra da cadeia, obtemos as derivadas $\frac{\partial J_e}{\partial w_1}$ e $\frac{\partial J_e}{\partial w_2}$

$$\frac{\partial J_e}{\partial w_2} = \frac{\partial J_e}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial g_2} \frac{\partial g_2}{\partial w_2},$$

$$\frac{\partial J_e}{\partial w_1} = \frac{\partial J_e}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial g_2} \frac{\partial g_2}{\partial z_1} \frac{\partial z_1}{\partial g_1} \frac{\partial g_1}{\partial w_1}.$$

Dissipação do gradiente

$$\frac{\partial J_e}{\partial w_2} = \frac{\partial J_e}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial g_2} \frac{\partial g_2}{\partial w_2},$$

$$\frac{\partial J_e}{\partial w_1} = \frac{\partial J_e}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial g_2} \frac{\partial g_2}{\partial z_1} \frac{\partial z_1}{\partial g_1} \frac{\partial g_1}{\partial w_1}.$$

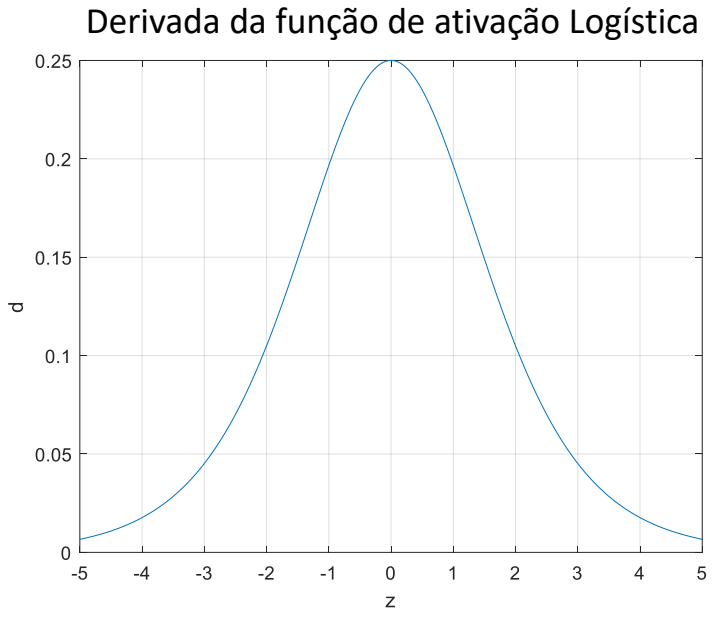

- A derivada da função sigmoide é no máximo igual a 0.25.
- Assim, por exemplo, a primeira camada de uma rede neural com M camadas, terá as derivadas parciais da função de erro em relação a seus pesos compostas pela multiplicação de M termos no máximo iguais a 0.25.
- Isso faz com que as primeiras camadas aprendam lentamente ou nem aprendam, pois têm derivadas muito pequenas, tendendo a zero.

Explosão do gradiente

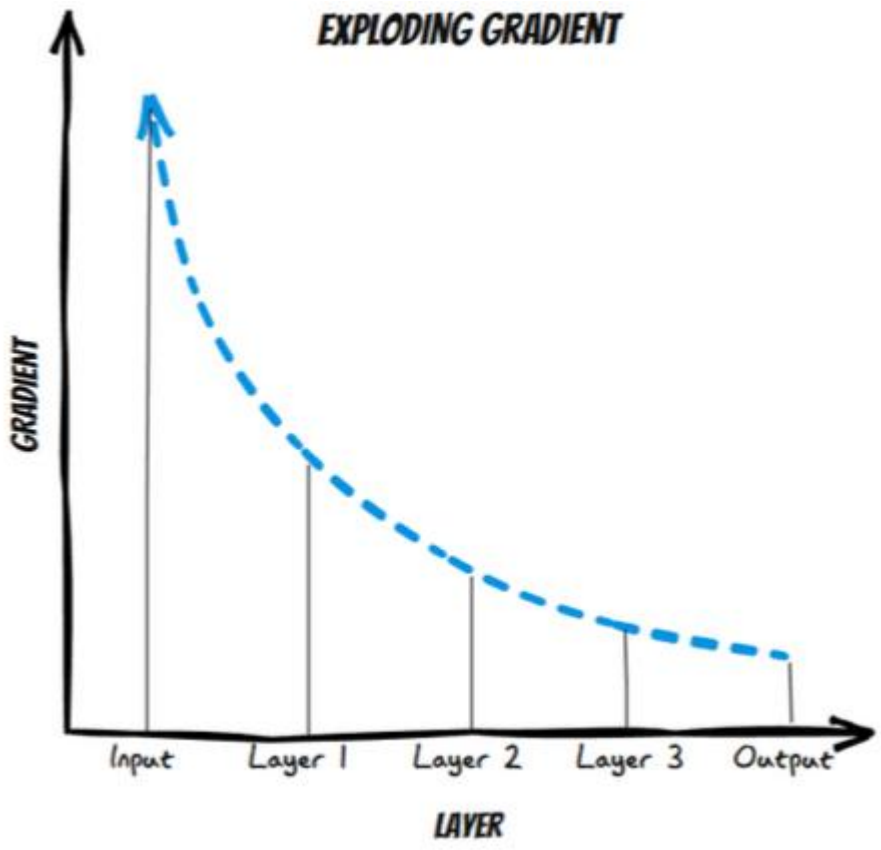

- Usando funções de ativação ReLU e suas variantes, reduzimos o problema do desaparecimento do gradiente.
- Porém, um ***outro problema surge*** quando as ***ativações são positivas*** e os ***pesos têm valores maiores do que 1***.
- Caso os pesos sejam inicializados (em geral, de forma aleatória) com ***valores maiores do que 1***, haverá a ***multiplicação de vários valores assim***, ***resultando em valores de gradiente muito grandes nas camadas iniciais***.

Explosão do gradiente

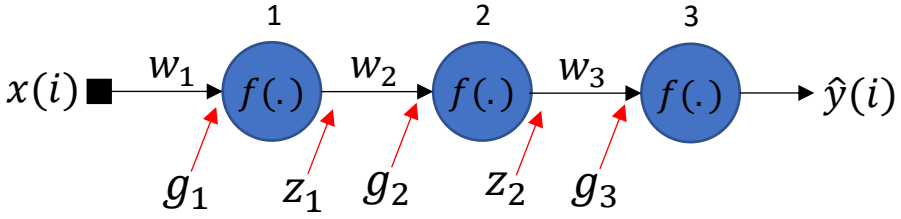

$$\frac{\partial g_3}{\partial z_2} = \frac{\partial f(g_2)w_3}{\partial f(g_2)} = w_3$$

$$\frac{\partial g_2}{\partial z_1} = \frac{\partial f(xw_1)w_2}{\partial f(xw_1)} = w_2$$

$$\frac{\partial J_e}{\partial w_1} = \frac{\partial J_e}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial g_3} \frac{\partial g_3}{\partial z_2} \frac{\partial z_2}{\partial g_2} \frac{\partial g_2}{\partial z_1} \frac{\partial z_1}{\partial g_1} \frac{\partial g_1}{\partial w_1}.$$

- Se os elementos do vetor gradiente tiverem ***magnitudes muito grandes***, os ***pesos da rede podem sofrer atualizações extremamente grandes***, o que leva a ***instabilidades numéricas*** e a um ***treinamento ineficaz*** ou até mesmo à ***divergência***.

Formas de se minimizar a dissipação e a explosão do gradiente

- Além do uso de funções de ativação ReLU ou de suas variantes, outras formas de se minimizar esses problemas são:
  - **Inicialização apropriada dos pesos**: garante que a ***variância das ativações permaneça a mesma ao longo de todas as camadas***. Isso garante que o gradiente retropropagado não tenha multiplicações com valores muito pequenos ou muito grandes em qualquer camada, ajudando a ***mitigar ambos os problemas***.
  - **Normalização de batch**: ***padroniza as ativações*** das camadas da rede e, na sequência, as ***desloca e escalona***, mantendo-as dentro de intervalos que ***minimizam ambos os problemas***.
  - **Poda do gradiente**: ***limita (poda) os valores dos gradientes*** durante o treinamento para que eles não excedam algum limite pré-definido, ***mitigando apenas o problema da explosão do gradiente***.

Anexo II: Adam

Adaptive Moment Estimation (Adam)

Um passo adaptativo para cada elemento do vetor gradiente.

$$a \leftarrow a - \boxed{\frac{\alpha_0}{\sqrt{\hat{v} + \varepsilon}}} \hat{m}$$

$$\hat{m} = {}^{m}/_{(1 - \beta_1{}^t)}$$

$$\hat{v} = {}^{v}/_{(1 - \beta_2{}^t)}$$

ε é um valor pequeno, e.g., 1e-8, que garante que não ocorra divisão por zero.

Estimativa do momento de primeira ordem (média).

$$m \leftarrow \beta_1 m + (1 - \beta_1)\nabla J_e(a)$$

$$v \leftarrow \beta_2 v + (1 - \beta_2)[\nabla J_e(a)]^2$$

Estimativa do momento de segunda ordem (variância não-centralizada).

- Aplica passos de aprendizado ***independentes*** e ***adaptativos*** a cada elemento do vetor gradiente.
- Usa ***médias móveis exponencialmente decrescentes*** dos gradientes anteriores e de seus quadrados para atualizar os pesos do modelo.
- A média dos gradientes anteriores suaviza as atualizações e acelera a convergência, principalmente quando usado com ***estimativas estocásticas do vetor gradiente.***

Adaptive Moment Estimation (Adam)

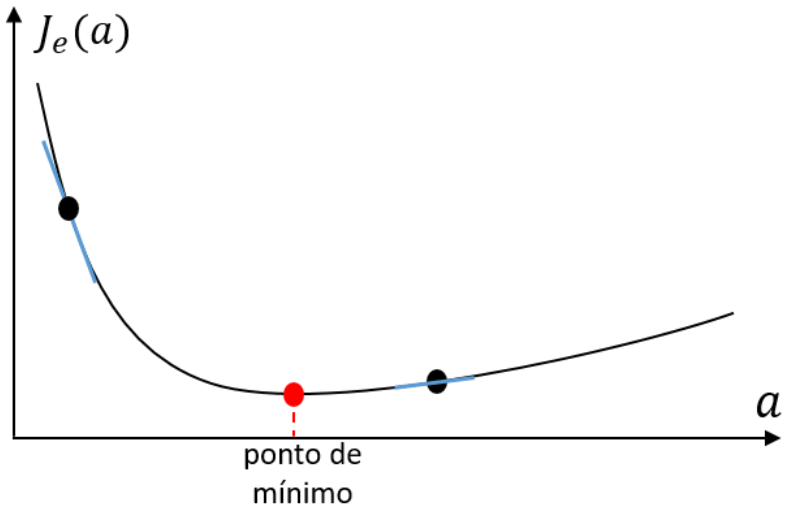

- A média dos quadrados é usada para reduzir o valor dos passos individuais.
- Em regiões íngremes, reduz rapidamente o passo de aprendizagem, pois os valores das derivadas (taxa de variação) são grandes.
  - Isso evita que ultrapasse o mínimo.
- Em regiões planas ou quase, diminui o passo de aprendizagem muito lentamente, pois as derivadas são muito pequenas.
  - Passo permanece com valor grande, fazendo com que se caminhe mais rapidamente por essas regiões.

Figuras

Coletar Dados
EDA
Pré-Processa mento
Projetar modelo
Treinar modelo
Avaliar e otimizar
Inferência

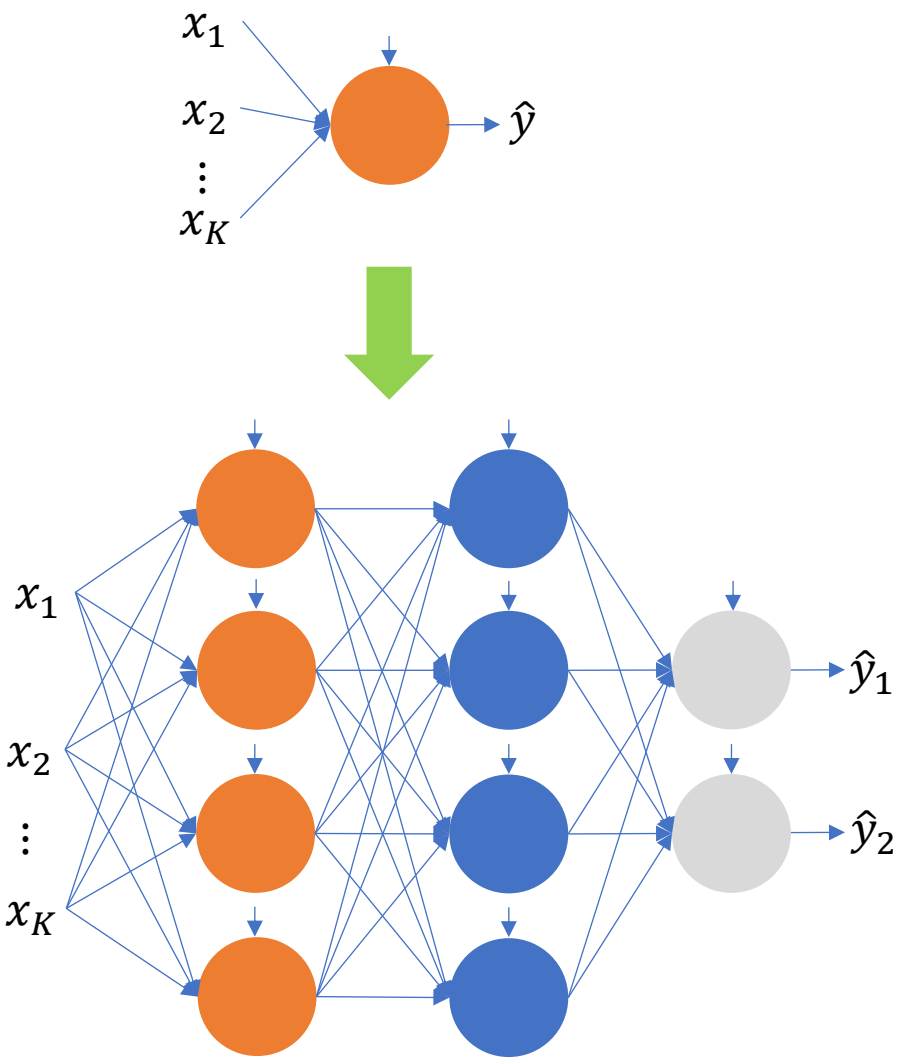
x_1
x_2
$\vdots$
x_K
$\hat{y}$
x_1
x_2
$\vdots$
x_K
$\hat{y}_1$
$\hat{y}_2$

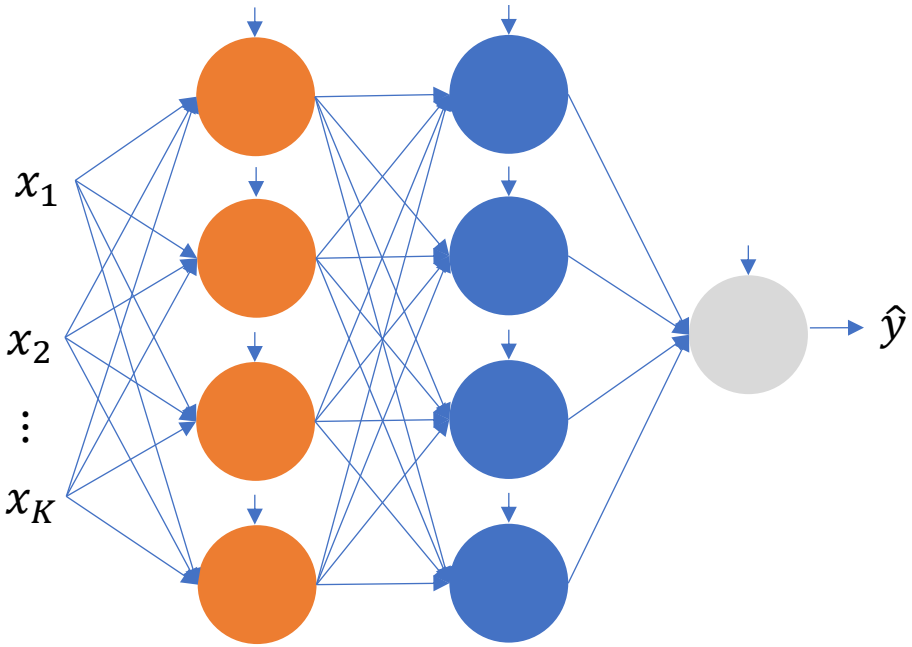
x_1
x_2
$\vdots$
x_K
$\hat{y}$

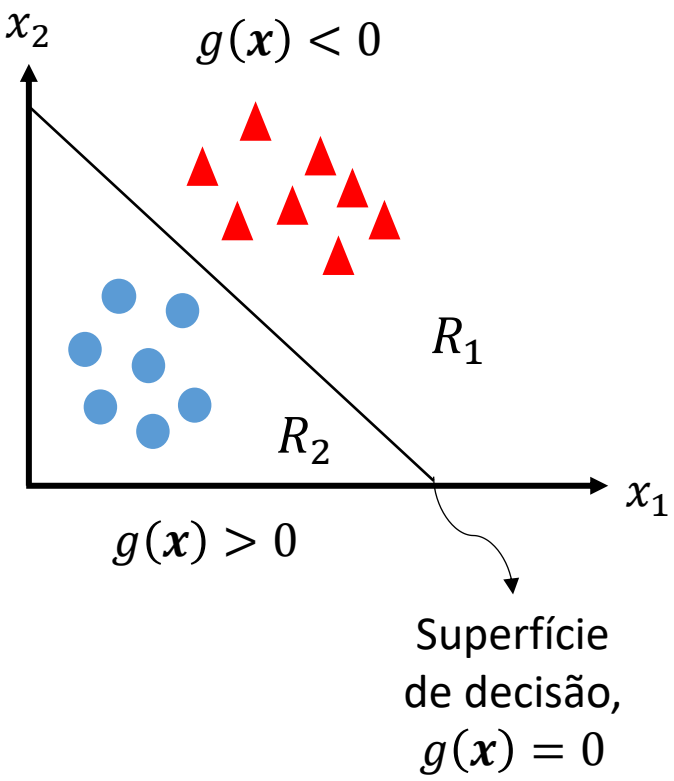
x_2
$g(\boldsymbol{x}) < 0$
R_1
R_2
x_1
$g(\boldsymbol{x}) > 0$
Superfície de decisão, $g(\boldsymbol{x}) = 0$

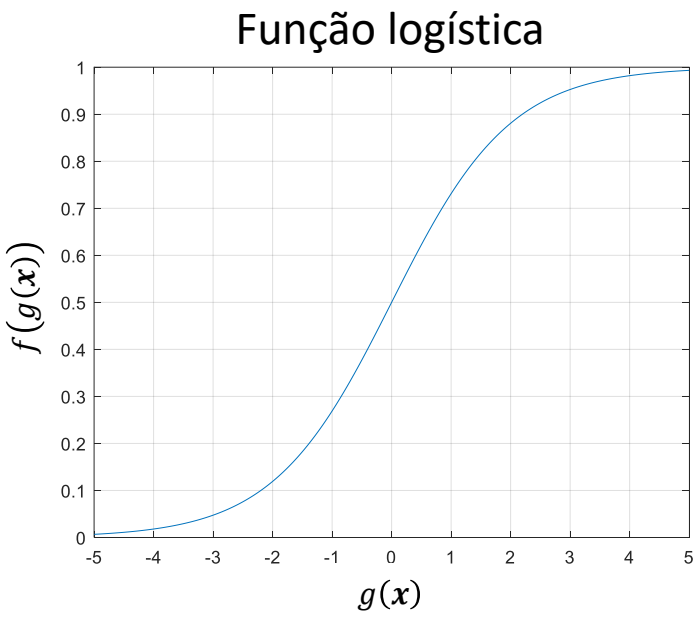
Função logística
$f(g(\boldsymbol{x}))$
$g(\boldsymbol{x})$
1
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.2
0.1
0
-5
-4
-3
-2
-1
0
1
2
3
4
5

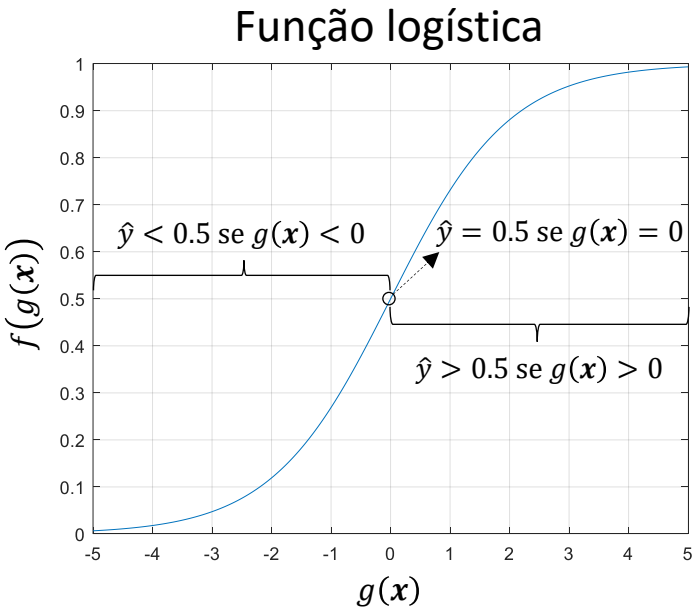
Função logística
$\hat{y} < 0.5$ se $g(\boldsymbol{x}) < 0$
$\hat{y} = 0.5$ se $g(\boldsymbol{x}) = 0$
$\hat{y} > 0.5$ se $g(\boldsymbol{x}) > 0$
$f(g(\boldsymbol{x}))$
$g(\boldsymbol{x})$

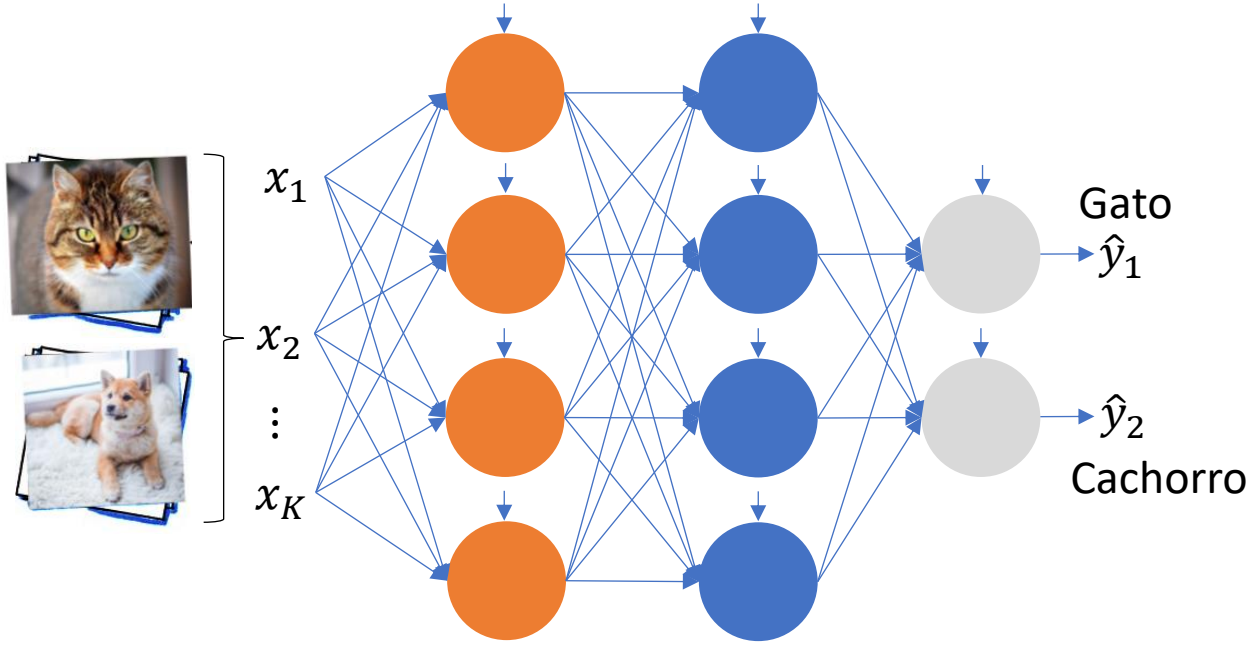
x_1
x_2
$\vdots$
x_K
Gato
$\hat{y}_1$
$\hat{y}_2$
Cachorro

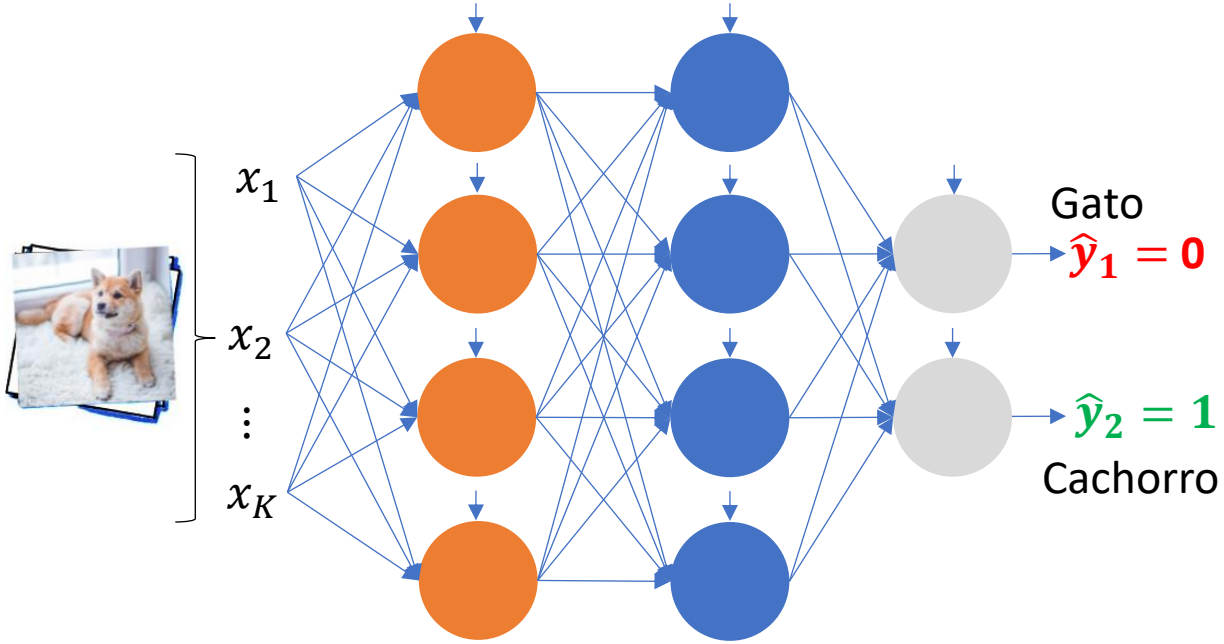
x_1
x_2
$\vdots$
x_K
Gato
$\hat{y}_1 = 0$
$\hat{y}_2 = 1$
Cachorro

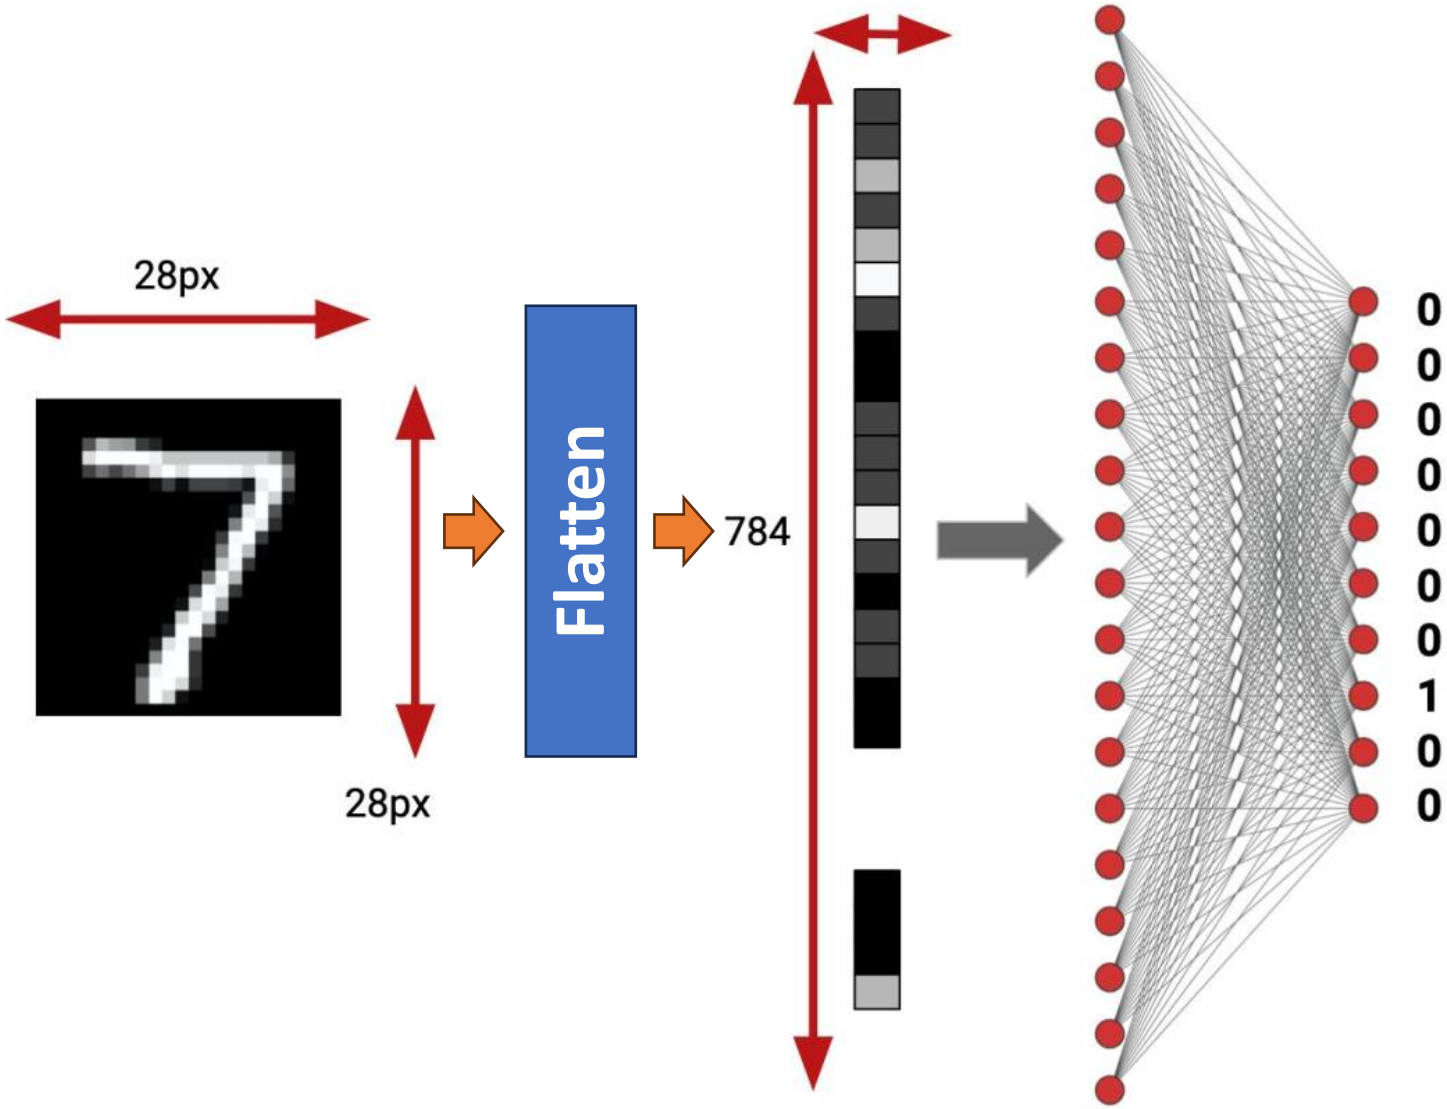
28px
28px
Flatten
784
0
0
0
0
0
0
0
1
0
0

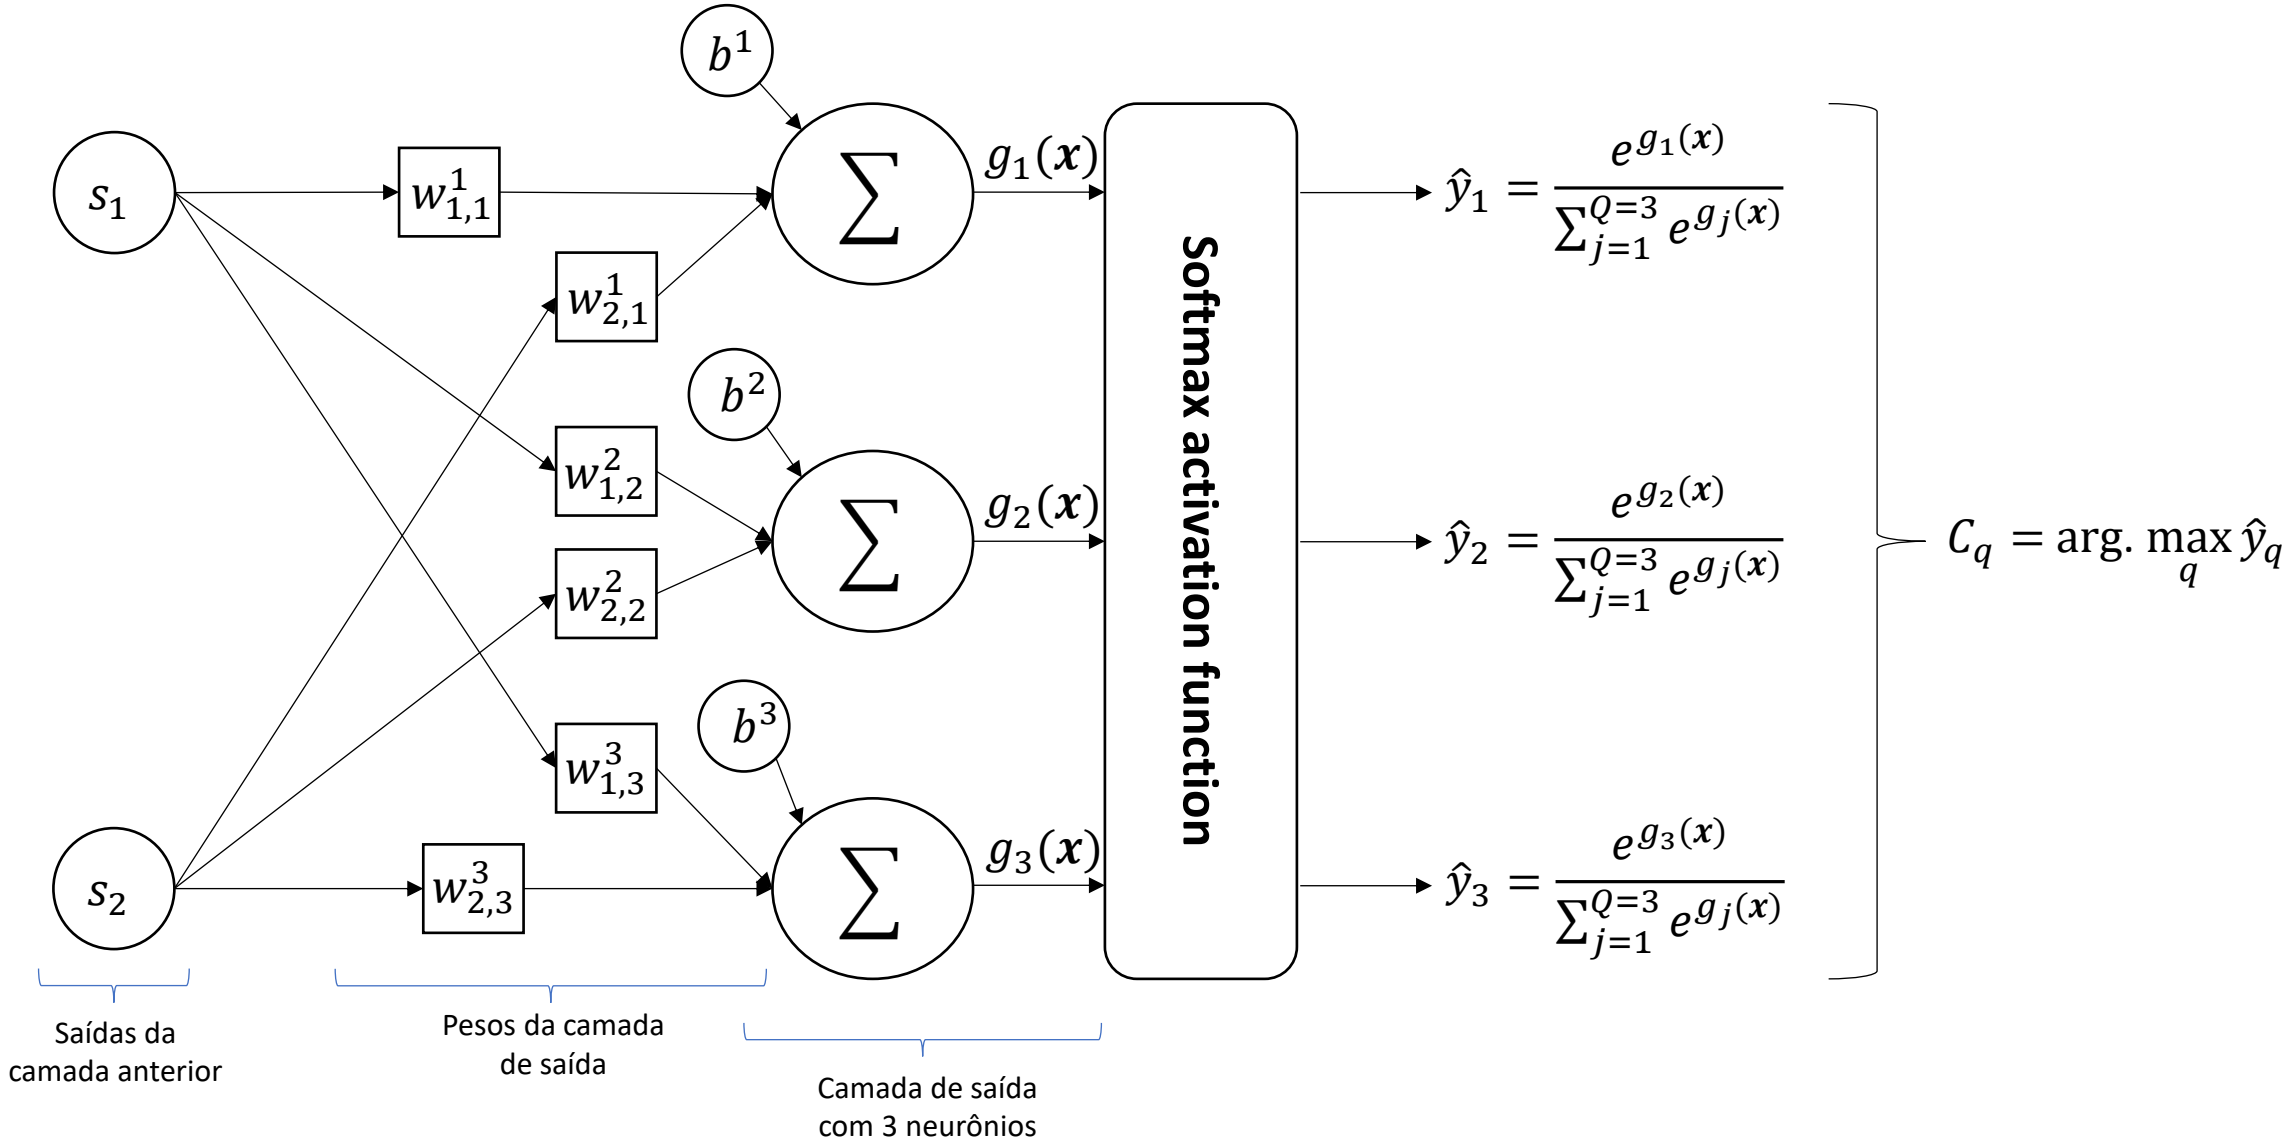
s_1
s_2
$w_{1,1}^1$
$w_{2,1}^1$
$w_{1,2}^2$
$w_{2,2}^2$
$w_{1,3}^3$
$w_{2,3}^3$
b^1
b^2
b^3
$\sum$
$g_1(\boldsymbol{x})$
$g_2(\boldsymbol{x})$
$g_3(\boldsymbol{x})$
Softmax activation function
$\hat{y}_1 = \frac{e^{g_1(\boldsymbol{x})}}{\sum_{j=1}^{Q=3} e^{g_j(\boldsymbol{x})}}$
$\hat{y}_2 = \frac{e^{g_2(\boldsymbol{x})}}{\sum_{j=1}^{Q=3} e^{g_j(\boldsymbol{x})}}$
$\hat{y}_3 = \frac{e^{g_3(\boldsymbol{x})}}{\sum_{j=1}^{Q=3} e^{g_j(\boldsymbol{x})}}$
$C_q = \arg.\max_q \hat{y}_q$
Saídas da camada anterior
Pesos da camada de saída
Camada de saída com 3 neurônios

Ativações da camada de saída

Função de ativação *softmax*

Probabilidades

$$
\begin{array}{c}
g_1(\boldsymbol{x}) \\
g_2(\boldsymbol{x}) \\
g_3(\boldsymbol{x}) \\
g_4(\boldsymbol{x}) \\
g_5(\boldsymbol{x})
\end{array}
\begin{bmatrix} 1.3 \\ 5.1 \\ 2.2 \\ 0.7 \\ 1.1 \end{bmatrix}
\longrightarrow
\boxed{\frac{e^{g_i(\boldsymbol{x})}}{\sum_{j=1}^{Q} e^{g_j(\boldsymbol{x})}}}
\longrightarrow
\begin{bmatrix} 0.01 \\ 0.9 \\ 0.05 \\ 0.01 \\ 0.02 \end{bmatrix}
$$

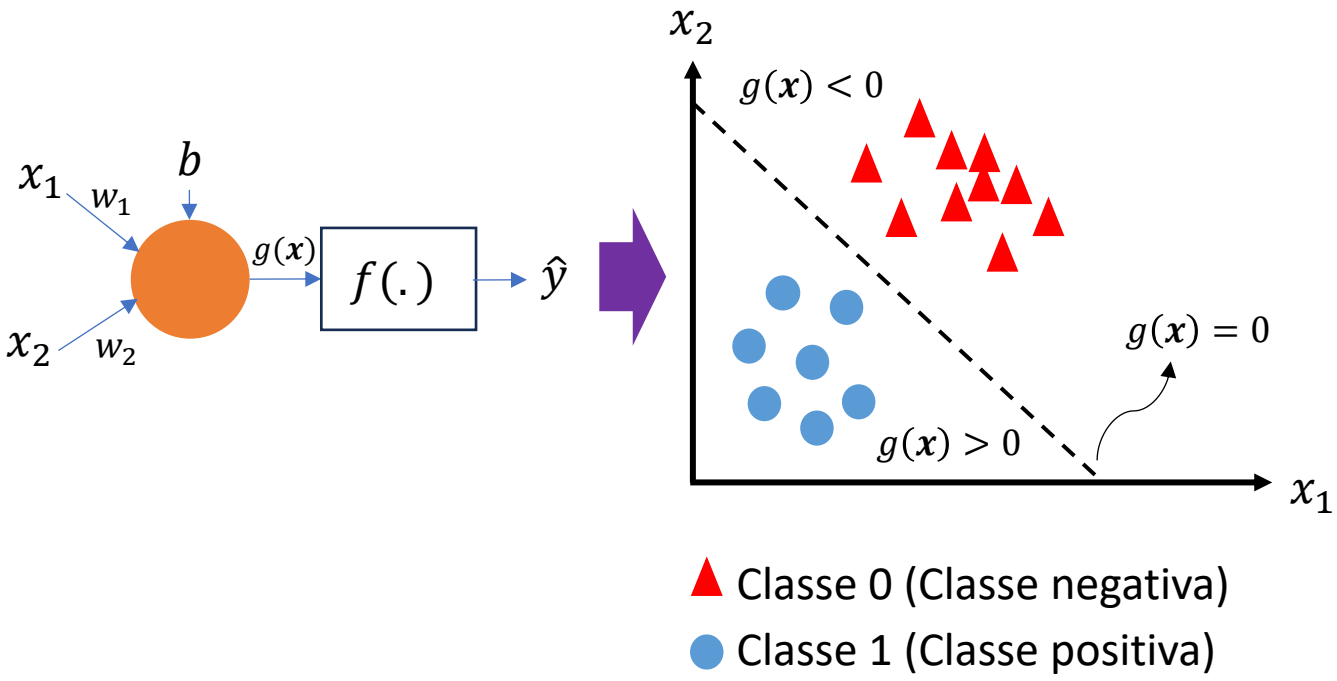
x_1
w_1
b
x_2
w_2
$g(\boldsymbol{x})$
$f(.)$
$\hat{y}$
x_2
$g(\boldsymbol{x}) < 0$
$g(\boldsymbol{x}) = 0$
$g(\boldsymbol{x}) > 0$
x_1
Classe 0 (Classe negativa)
Classe 1 (Classe positiva)