


TP557 - Tópicos avançados em IoT e Machine Learning:

Métricas para análise de classificadores



Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

O que vamos ver?

- Anteriormente, discutimos *problemas* que podemos nos deparar quando trabalhando com modelos de ML: *subajuste* e *sobreajuste*.
- Vimos como a *divisão do conjunto total de amostras* em conjuntos de treinamento, validação e teste pode nos *ajudar a analisar o desempenho de um modelo* de ML e entender se o modelo está *subajustando*, *sobreajustando* ou *generalizando*.
- Para fazer a análise do desempenho de um classificador, usamos apenas a acurácia.
- Porém, existem outras métricas que podem ser usadas para se medir a qualidade de um classificador.
- Neste tópico, veremos algumas outras métricas.

Matriz de confusão

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \dots & C_{1Q} \\ C_{21} & C_{22} & & C_{2Q} \\ & \vdots & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \dots & C_{QQ} \end{bmatrix}$$

- O nome, ***matriz de confusão*** mostra o quanto um classificador está se ***confundindo***.
- A matriz permite verificar quais classes o ***classificador*** tem ***maior dificuldade em classificar***.
- A ***matriz de confusão contabiliza o número de classificações corretas e incorretas*** para cada uma das Q classes existentes.
- É uma ***matriz quadrada*** com dimensões $\mathbb{R}^{Q \times Q}$.

Matriz de confusão

Predições: classes a que os exemplos foram atribuídos

$$\begin{bmatrix} C_{11} & C_{12} & \dots & C_{1Q} \\ C_{21} & C_{22} & & C_{2Q} \\ & \vdots & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \dots & C_{QQ} \end{bmatrix}$$

Rótulos: classes a que realmente pertencem os exemplos

Matriz de confusão

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \cdots & C_{1Q} \\ C_{21} & C_{22} & \cdots & C_{2Q} \\ \vdots & & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \cdots & C_{QQ} \end{bmatrix}$$

- A **diagonal principal** de $\mathbf{C}$ fornece o número de **classificações corretas**.
- A q -ésima **linha** indica o **total de exemplos que foram classificados como pertencentes a q -ésima classe**, incluindo exemplos que pertencem e não pertencem à classe.
- A q -ésima **coluna** indica o **total de exemplos que realmente pertencem à q -ésima classe**, incluindo classificações corretas e incorretas.

Matriz de confusão

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \dots & C_{1Q} \\ C_{21} & C_{22} & \dots & C_{2Q} \\ \vdots & & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \dots & C_{QQ} \end{bmatrix}$$

Exemplos classificados como pertencentes à classe 1.

Quantidade de exemplos realmente pertencentes à classe 1.

- C_{11} indica quantos exemplos da classe 1 foram corretamente atribuídos à classe 1.
- C_{12} indica quantos exemplos da classe 2 foram atribuídos à classe 1.

Matriz de confusão para caso binário ($Q = 2$)

Classes Estimadas	Classes Verdadeiras	
	- (C_1)	+ (C_2)
- (C_1)	Verdadeiros Negativos (TN)	Falsos Negativos (FN)
+ (C_2)	Falsos Positivos (FP)	Verdadeiros Positivos (TP)

- **Verdadeiros Positivos (TP)**: número de exemplos da classe positiva, C_2 , classificados corretamente.
- **Verdadeiros Negativos (TN)**: número de exemplos da classe negativa, C_1 , classificados corretamente.
- **Falsos Positivos (FP)**: número de exemplos atribuídos à classe positiva, mas que pertencem à classe negativa.
- **Falsos Negativos (FN)**: número de exemplos atribuídos à classe negativa, mas que pertencem à classe positiva.

Matriz de confusão para caso binário ($Q = 2$)

verdadeiro positivo



falso positivo



falso negativo



verdadeiro negativo

Nós podemos calcular algumas métricas de desempenho importantes a partir das informações contidas na matriz de confusão.

Acurácia

$$\text{acurácia} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}}$$

- Acurácia mede a *proporção de exemplos classificados corretamente em relação ao total de exemplos* avaliados.
- Em outras palavras, a acurácia fornece uma indicação de quão bem o modelo está fazendo suas *predições corretas em comparação com todas as previsões feitas*.
- É uma métrica útil para avaliar a *performance geral do modelo*.

Acurácia

$$\text{acurácia} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}}$$

- A **acurácia** é, geralmente, a **primeira escolha** para medir a qualidade de um classificador.
- Entretanto, ela pode ser **enganosa com problemas desbalanceados**.
 - Problemas onde uma ou algumas classes têm muito mais exemplos do que as demais.
- Nesses casos, ela pode nos levar a concluir que um **classificador ruim é muito bom**.

Acurácia

- Analisando a equação da acurácia, o que aconteceria se TP fosse muito maior do que TN, FN e FP?

$$\lim_{TP \rightarrow \infty} \text{acurácia} = \lim_{TP \rightarrow \infty} \left(\frac{TP + TN}{TP + TN + FN + FP} \right) = \frac{TP}{TP} = 1.$$

- O mesmo aconteceria se TN fosse muito maior do que TP, FN e FP
- Portanto, quando temos *classes desbalanceadas, precisamos analisar outras métricas*.
- Ela também é enganosa quando os custos de falsos positivos e falsos negativos não são iguais.

Precisão

$$\text{precisão} = \frac{\text{TP}}{\text{FP} + \text{TP}}$$

TN	FN
FP	TP

- **Precisão** é a proporção de exemplos da classe positiva corretamente classificados (TP) em relação a todos os exemplos atribuídos à classe positiva (TP + FP).
- É uma **boa medida** para determinar a qualidade do classificador **quando os custos de falsos positivos são altos**.
 - Por exemplo, na classificação de *spams* (**verdadeiro positivo**), um **falso positivo** significa que um *ham* (**verdadeiro negativo**) foi classificado como *spam*. O usuário de *email* pode perder *emails* importantes se a **precisão** for baixa.

Recall

$$recall = \frac{TP}{FN + TP}$$

TN	FN
FP	TP

- **Recall** ou sensibilidade é a proporção de exemplos da classe positiva corretamente classificados.
- O *recall* calcula quantos exemplos realmente positivos o classificador captura em relação a todos exemplos positivos.
- É uma **boa medida** para determinar a qualidade de um classificador **quando os custos de falsos negativos são altos**.
 - Por exemplo, na classificação de doenças, se um paciente doente (**verdadeiro positivo**) for classificado como não doente (**falso negativo**). O custo associado ao **falso negativo** será extremamente alto se a doença for contagiosa.

OK, consigo calcular as métricas para problemas binários, mas e quando $Q > 2$?

Matriz de confusão para caso multiclass ($Q > 2$)

Classe C_1 é a positiva.

Classes Preditas	$+(C_1)$	Verdadeiro Positivo (TP)	Falso Positivo (FP)	Falso Positivo (FP)
	$-(C_2)$	Falso Negativo (FN)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)
	$-(C_3)$	Falso Negativo (FN)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)
		$+(C_1)$	$-(C_2)$	$-(C_3)$
		Classes Verdadeiras		

- É possível calcular as métricas anteriores para o cenário multiclass (i.e., $Q > 2$).
- Para isso, basta selecionar, uma vez, cada classe como sendo a classe positiva, enquanto todas as demais classes formam a classe negativa.
- Assim, obtém-se os valores das *métricas para cada uma das Q classes*.
- Vejamos um exemplo para $Q = 3$, ou seja, C_1 , C_2 e C_3 .

Matriz de confusão para caso multiclass ($Q > 2$)

Classe C_2 é a positiva.

Classes Preditas	- (C_1)	Verdadeiro Negativo (TN)	Falso Negativo (FN)	Verdadeiro Negativo (TN)
	+ (C_2)	Falso Positivo (FP)	Verdadeiro Positivo (TP)	Falso Positivo (FP)
	- (C_3)	Verdadeiro Negativo (TN)	Falso Negativo (FN)	Verdadeiro Negativo (TN)
		- (C_1)	+ (C_2)	- (C_3)
		Classes Verdadeiras		

Classe C_3 é a positiva.

Classes Preditas	- (C_1)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)	Falso Negativo (FN)
	- (C_2)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)	Falso Negativo (FN)
	+ (C_3)	Falso Positivo (FP)	Falso Positivo (FP)	Verdadeiro Positivo (TP)
		- (C_1)	- (C_2)	+ (C_3)
		Classes Verdadeiras		

Precisão versus *recall*

$$\text{precisão} = \frac{\text{TP}}{\text{FP} + \text{TP}}$$

$$\text{recall} = \frac{\text{TP}}{\text{FN} + \text{TP}}$$

- A **precisão** não fornece informações a respeito da quantidade de **falsos negativos**.
- Por outro lado, o **recall** não fornece informações a respeito da quantidade de **falsos positivos**.
- Mas e se os **custos associados a falsos positivos e negativos são iguais**?
- Nesse caso, para analisarmos o desempenho de um classificador, precisamos de uma métrica que **combine as duas**.


F1-score

- O F1-score combina as duas métricas em uma única.
- A métrica dá a mesma importância a **precisão** e para o **recall**.
- Valores de F_1 próximos de 1 indicam que o **classificador** obteve ótimos resultados tanto de **precisão** quanto de **recall**.
- Em outras palavras, $F_1 \approx 1$ significa que FN e FP ≈ 0 .

$$F_1 = \frac{TP}{TP + \frac{FN + FP}{2}} = 2 \frac{\text{precisão} \times \text{recall}}{\text{precisão} + \text{recall}}.$$

Exemplo

- Exemplo: Métricas de classificação



Atividades


- Quiz: “***TP557 – Métricas para análise de classificadores***”.
- Exercício: Métricas de classificação

Perguntas?

Obrigado!



Anexo I: Acurácia versus precisão

Acurácia versus precisão



- Em um conjunto de predições:
 - Acurácia é a proximidade das predições em relação aos rótulos, ou seja, o quão perto estão do alvo.
 - Precisão é a proximidade das medidas entre si.
- A precisão é independente da acurácia.
- Isso significa que é possível ter um modelo muito preciso, mas não muito exato, e também é possível ser exato sem ser preciso.

Figuras



verdadeiro positivo



falso positivo



falso negativo



verdadeiro negativo