


TP557 - Tópicos avançados em IoT e Machine Learning:

Métricas para análise de classificadores



Inatel

Felipe Augusto Pereira de Figueiredo
felipe.figueiredo@inatel.br

O que vamos ver?

- Anteriormente, discutimos problemas que podemos nos deparar quando trabalhando com modelos de ML: subajuste e sobreajuste.
- Vimos como a divisão do conjunto total de amostras em conjuntos de treinamento, validação e teste pode nos ajudar a analisar o desempenho de um modelo de ML e entender se o modelo está subajustando, sobreajustando ou generalizando.
- Para fazer esta análise do desempenho de um classificador, usamos apenas a acurácia.
- Porém, existem outras métricas que devem ser usadas para se medir a qualidade de um classificador.
- Neste tópico, veremos algumas outras métricas.

Matriz de confusão

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \dots & C_{1Q} \\ C_{21} & C_{22} & & C_{2Q} \\ & \vdots & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \dots & C_{QQ} \end{bmatrix}$$

- O nome, ***matriz de confusão*** mostra o quanto um classificador está se ***confundindo***.
- A matriz permite verificar quais classes o ***classificador*** tem maior dificuldade em classificar.
- A ***matriz de confusão*** contabiliza o número de classificações corretas e incorretas para cada uma das Q classes existentes.
- É uma matriz quadrada com dimensões $\mathbb{R}^{Q \times Q}$.

Matriz de confusão

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \cdots & C_{1Q} \\ C_{21} & C_{22} & & C_{2Q} \\ & \vdots & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \cdots & C_{QQ} \end{bmatrix}$$

- A diagonal de \mathbf{C} fornece o número de classificações corretas.
- A q -ésima **linha** indica o total de exemplos que foram classificados como pertencentes a q -ésima classe.
- A q -ésima **coluna** indica o total de exemplos que realmente pertencem à q -ésima classe, incluindo classificações corretas e incorretas.

Matriz de confusão

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \dots & C_{1Q} \\ C_{21} & C_{22} & \dots & C_{2Q} \\ \vdots & \vdots & \ddots & \vdots \\ C_{Q1} & C_{Q2} & \dots & C_{QQ} \end{bmatrix}$$

Exemplos classificados como pertencentes à classe 1.

Quantidade de exemplos realmente pertencentes à classe 1.

- C_{11} indica quantos exemplos da classe 1 foram corretamente atribuídos à classe 1.
- C_{12} indica quantos exemplos da classe 2 foram atribuídos à classe 1.

Matriz de confusão para caso binário ($Q = 2$)

Classes Estimadas	Classes Verdadeiras	
	$+(C_2)$	$-(C_1)$
$+(C_2)$	Verdadeiro Positivo (TP)	Falso Positivo (FP)
$-(C_1)$	Falso Negativo (FN)	Verdadeiro Negativo (TN)

- **Verdadeiro Positivo (TP)**: número de exemplos da classe positiva, C_2 , classificados corretamente.
- **Verdadeiro Negativo (TN)**: número de exemplos da classe negativa, C_1 , classificados corretamente.
- **Falso Positivo (FP)**: número de exemplos classificados como positivos, mas que pertencem à classe negativa.
- **Falso Negativo (FN)**: número de exemplos atribuídos à classe negativa, mas que pertencem à classe positiva.

Matriz de confusão para caso binário ($Q = 2$)

verdadeiro positivo



falso positivo



falso negativo



verdadeiro negativo

Matriz de confusão para caso multiclass ($Q > 2$)

Classe C_1 é a positiva.

Classes Estimadas	$+(C_1)$	Verdadeiro Positivo (TP)	Falso Positivo (FP)	Falso Positivo (FP)
	$-(C_2)$	Falso Negativo (FN)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)
	$-(C_3)$	Falso Negativo (FN)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)
		$+(C_1)$	$-(C_2)$	$-(C_3)$
		Classes Verdadeiras		

- É possível estender a análise com a **matriz de confusão** para o cenário multi-classes (i.e., $Q > 2$).
- Basta selecionar, uma vez, cada classe como sendo a classe positiva, enquanto todas as demais classes formam a classe negativa.
- Vejamos um exemplo para $Q = 3$, ou seja, C_1 , C_2 e C_3 .

Matriz de confusão para caso multiclass ($Q > 2$)

Classe C_2 é a positiva.

Classes Estimadas	- (C_1)	Verdadeiro Negativo (TN)	Falso Negativo (FN)	Verdadeiro Negativo (TN)
	+ (C_2)	Falso Positivo (FP)	Verdadeiro Positivo (TP)	Falso Positivo (FP)
	- (C_3)	Verdadeiro Negativo (TN)	Falso Negativo (FN)	Verdadeiro Negativo (TN)
		- (C_1)	+ (C_2)	- (C_3)
		Classes Verdadeiras		

Classe C_3 é a positiva.

Classes Estimadas	- (C_1)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)	Falso Negativo (FN)
	- (C_2)	Verdadeiro Negativo (TN)	Verdadeiro Negativo (TN)	Falso Negativo (FN)
	+ (C_3)	Falso Positivo (FP)	Falso Positivo (FP)	Verdadeiro Positivo (TP)
		- (C_1)	- (C_2)	+ (C_3)
		Classes Verdadeiras		

Acurácia

$$\text{acurácia} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}}$$

- Acurácia mede a proporção de exemplos classificados corretamente em relação ao total de exemplos avaliados.
- Em outras palavras, a acurácia fornece uma indicação de quão bem o modelo está fazendo suas previsões corretas em comparação com todas as previsões feitas.
- É uma métrica útil para avaliar a performance geral do modelo.

Acurácia

- A acurácia é, geralmente, a primeira escolha para medir a qualidade de um classificador.
- Entretanto, ela pode ser enganosa com problemas desbalanceados.
- Analisando a equação abaixo, o que aconteceria se TP fosse muito maior do que TN, FN e FP?

$$\lim_{TP \rightarrow \infty} \text{acurácia} = \lim_{TP \rightarrow \infty} \left(\frac{TP + TN}{TP + TN + FN + FP} \right) = \frac{TP}{TP} = 1.$$

- Portanto, quando temos classes desbalanceadas, precisamos analisar outras métricas.
 - O mesmo aconteceria se TN fosse muito maior do que TP, FN e FP
- Ela também é enganosa quando os custos de falsos positivos e falsos negativos não são iguais.

Precisão

$$\text{precisão} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

- **Precisão** é a proporção de exemplos da classe positiva corretamente classificados (TP) em relação a todos os exemplos atribuídos à classe positiva (TP+FP).
- É uma boa medida para determinar a qualidade do classificador quando os custos de **falsos positivos** são altos.
 - Por exemplo, na classificação de **spams** (**verdadeiro positivo**), um **falso positivo** significa que um **ham** (**verdadeiro negativo**) foi classificado como **spam**. O usuário de email pode perder emails importantes se a **precisão** for baixa.

Acurácia versus precisão



alta precisão, alta acurácia



baixa precisão, alta acurácia



alta precisão, baixa acurácia



baixa precisão, baixa acurácia

- Em um conjunto de medidas:
 - Acurácia é a proximidade das medidas em relação a um valor.
 - Precisão é a proximidade das medidas entre si.

Recall

$$\text{recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

- Recall ou sensibilidade é a proporção de exemplos da classe positiva corretamente classificados.
- **Recall** calcula quantos exemplos realmente positivos o classificador captura em relação a todos exemplos positivos.
- É uma boa medida para determinar a qualidade de um classificador quando houver um alto custo associado a **falsos negativos**.
 - Por exemplo, na classificação de doenças, se um paciente doente (**verdadeiro positivo**) for classificado como não doente (**falso negativo**). O custo associado ao **falso negativo** será extremamente alto se a doença for contagiosa.


F1-score

$$F_1 = \frac{TP}{TP + \frac{FN + FP}{2}}$$
$$= 2 \frac{\text{precisão} \times \text{recall}}{\text{precisão} + \text{recall}}.$$

- A precisão não fornece informações a respeito da quantidade de **falsos negativos**.
- Por outro lado, o recall não fornece informações a respeito da quantidade de **falsos positivos**.
- Portanto, para analisarmos o desempenho de um classificador de forma geral, precisamos de uma métrica que combine as duas, como o F1-score.
- Valores de F_1 próximos de 1 indicam que o **classificador** obteve ótimos resultados tanto de **precisão** quanto de **recall**.

Exemplo

- Exemplo: [Métricas de classificação](#)





Atividades

- Quiz: “***TP557 – Métricas para análise de classificadores***”.
- Exercício: Métricas de classificação

Perguntas?

Obrigado!



verdadeiro positivo



falso positivo



falso negativo



verdadeiro negativo