


# TP557 - Tópicos avançados em IoT e Machine Learning: *Detecção de anomalias*




***Inatel***

Samuel Baraldi Mafra  
samuelbmafra@inatel.br

# Aprendizado não-supervisionado


- Diferentemente do aprendizado supervisionado, no aprendizado não-supervisionado, *não existem rótulos*.
- Esses algoritmos *descobrem padrões ocultos ou agrupamentos de dados* sem a necessidade de rótulos.
- São usados em problemas de
  - Segmentação
  - Agrupamento (i.e., *clusterização*)
  - Redução de dimensionalidade
  - *Detecção de anomalias*

# Aprendizado supervisionado versus não supervisionado




# Clusterização

- A forma mais simples e conhecida de aprendizado não-supervisionado é a clusterização ou agrupamento.
- O objetivo do agrupamento é *dividir os dados em vários grupos ou clusters*, de modo que as amostras dentro de cada grupo sejam *mais comparáveis entre si e diferentes das amostras dentro dos outros grupos*.
- É essencialmente um *agrupamento de amostras com base em quão semelhantes (ou próximos)* e diferentes elas são entre si.



# K-means

- O algoritmo de clusterização mais conhecido é o K-means.
- O objetivo do K-means é simples: *agrupar amostras semelhantes* e descobrir padrões subjacentes.
  - Semelhante aqui é no sentido de *proximidade*.
- Para atingir este objetivo, o K-means procura um número fixo ( $k$ ) de clusters em um conjunto de dados.



# K-means

## K-means pseudo-código

**Entradas:** conjunto de exemplos e número de clusters,  $k$ .

**1. Defina**  $k$  centroides iniciais (geralmente, feito de forma aleatória).

**2. Repita**

a) Calcule a distância de cada exemplo,  $x$ , para cada um dos  $k$  centroides e atribua cada exemplo ao cluster mais próximo.

b) Calcule o novo centroide de cada cluster\*.


**3. Enquanto** as posições dos centroides continuarem mudando.

\*os novos centroides são calculados como a média aritmética (centro geométrico) das amostras pertencentes a cada cluster.

# K-means

## Funcionamento do K-means


1. Define-se o número de clusters,  $K = 3$



# K-means

## Funcionamento do K-means


2. Escolhe-se os centroides para cada cluster de forma aleatória.



# K-means

## Funcionamento do K-means


3. Atribui-se cada amostra ao centróide mais próximo com base na distância euclidiana.



# K-means

## Funcionamento do K-means


4. Recalcula-se o centroide dos clusters.



# K-means

## Funcionamento do K-means


5. Repete-se os passos 3 e 4.



# K-means

## Funcionamento do K-means

5. Repete-se os passos 3 e 4.




# K-means

## Funcionamento do K-means



Repete-se os passos 3-4 até que um dos casos abaixo ocorra:

1. A soma das distâncias entre as amostras e o centroide correspondente seja minimizada
2. Não haja alteração nos centroides
3. O número máximo de iterações seja atingido



# Detecção de anomalias

- A detecção de anomalias é a identificação de itens, eventos ou observações raras que levantam suspeitas por diferirem significativamente da maioria dos dados.
- Exemplos
  - Detecção de spam
  - Detecção de fraude de cartão de crédito
  - Detecção de falhas em equipamentos
  - Detecção de movimentos anômalos




# Detecção de anomalias

- Aplicações

## Real world use cases of anomaly detection

Anomaly detection is influencing business decisions across verticals


|                                                                                                                                                                                |                                                                                                                                                                           |                                                                                                                                                                                               |                                                                                                                                                                               |                                                                                                                                                                                            |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>TELECOM</b><br><br>Detect roaming abuse, revenue fraud, service disruptions                | <b>BANKING</b><br><br>Flag abnormally high purchases/deposits, detect cyber intrusions   | <b>FINANCE &amp; INSURANCE</b><br><br>Detect and prevent out of pattern or fraudulent spend, travel expenses | <b>HEALTHCARE</b><br><br>Detect fraud in claims and payments; events from RFID and mobiles | <b>MANUFACTURING</b><br><br>Detect abnormal machine behavior to prevent cost overruns                   |
| <b>TRANSPORTATION</b><br><br>Ensure external communications to the vehicle are not intrusion | <b>SOCIAL MEDIA</b><br><br>Detect compromised accounts, bots that generate fake reviews | <b>NETWORKING</b><br><br>Detect intrusion into networks, prevent theft of source code or IP                 | <b>SMART HOUSE</b><br><br>Detect energy leakage, standardize smart sensor datasets        | <b>VIDEO SURVEILLANCE</b><br><br>Detect or track objects and persons of interest in monotonous footage |

- Disrupção de serviços de telecom
- Compras fraudulentas
- Fraudes em pagamentos e pedidos de exames
- Comportamento anormal de máquinas
- Contas comprometidas
- Invasões em redes
- Vazamentos de água e energia
- Identificar objetos em imagens sem variação

# Detecção de anomalias

- Algoritmos

- K-means usando a área do centroide
- Isolation Forest
- One-Class SVM
- Local Outlier Factor
- Etc.



# K-means


- Exemplo: Escolha de Locais para centros de distribuição



[https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/examples/k means centros de distribuição.ipynb](https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/examples/k%20means%20centros%20de%20distribuicao.ipynb)

# K-means

Como escolher o K ótimo?



$$WSS = \sum_{i=1}^{N_c} \sum_{x \in C_i} d(x, \bar{x}_{C_i})^2$$

# Detecção de anomalias

Movimentação de containers ao longo do ciclo logístico



# Detecção de anomalias


Movimentação de containers ao longo do ciclo logístico

Classificação de 5 estados do container

- Parado
- Sendo erguido
- No mar
- No caminhão
- **Anomalia** (e.g., container caindo no mar, empilhadeira tombando)

# Detecção de anomalias

## Detecção de anomalias com K-means




[https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/examples/k\\_means\\_anomaly\\_detection.ipynb](https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/examples/k_means_anomaly_detection.ipynb)

# Detecção de anomalias

Trabalho:


Incluir no Edge Impulse possíveis anomalias nos dados do ciclo logístico, e.g., quedas.



# Detecção de anomalias

Trabalho:

Se baseie no seguinte tutorial: <https://docs.edgeimpulse.com/docs/tutorials/end-to-end-tutorials/time-series/continuous-motion-recognition>



Acompanhamento do trabalho final